Comparação de Serviços de IA em Nuvem

Etapa 2 — Avaliação Prática

Análise de sentimento · Azure Language x Google Cloud Natural Language

115 textos · coleta de 19/10/2026

Davi Fonseca Passos · Rafael Fonseca Pessoa · Lucca Melo Nunes

Mestrado em Ciência da Computação — UNIFOR · Computação em Nuvem

Pergunta, escopo e serviços comparados

Diante dos mesmos textos em português, como Azure e Google se comparam em qualidade, sucesso, custo e latência?

MICROSOFT AZURE

- Azure Language — Sentiment analysis
- SDK azure-ai-textanalytics 5.4.0 · pt-BR
- East US, tier F0 (gratuito)
- Rodou no laptop do Rafael

GOOGLE CLOUD

- Cloud Natural Language API — analyzeSentiment
- SDK google-cloud-language 2.21.0 · pt
- Global, faixa gratuita
- Rodou no laptop do Davi

- Categoria: análise de sentimento (NLP) — equivalência direta; formato de resposta difere (classe pronta x número contínuo).
- Orçamento de US$ 0: tudo dentro das franquias gratuitas.

A AWS ficou fora: o Comprehend exige plano pago, o que conflita com o orçamento de US$ 0.

Os dados: B2W-Reviews01

Avaliações reais de clientes da Americanas.com (jan–mai/2018), licença CC BY-NC-SA 4.0.

Etapa	Resultado
Volume original	132.373 avaliações
Excluídos: vazios (3.275), duplicados (4.154), dado pessoal (18)	124.926 elegíveis
Sorteio estratificado por estrelas, semente fixa	30 de piloto + 300 candidatos ao teste
Conjunto final de teste	115 textos: 50 positivos, 50 negativos, 15 neutros

As estrelas NÃO são o gabarito — reduzir 5 estrelas a 3 classes pode levar a conclusões erradas. O gabarito é anotação humana.

O gabarito: anotação de 330 textos

Dois anotadores independentes, sem ver estrelas nem respostas das APIs.

87,0%	0,791	43
concordância bruta	kappa de Cohen (A × B)	divergências discutidas

- Teste: 115 textos (50 pos., 50 neg., 15 neutros — neutro ficou abaixo da meta de 50). Piloto: 30. Exploratório (misto): 39.
- Divergências: prevalece o anotador humano (B).

Metodologia: respostas normalizadas, condições controladas

	Como funciona
Azure	Devolve classe pronta; tradução direta (mixed → misto)
Google	Devolve só score (−1 a +1): > 0,25 positivo · < −0,25 negativo · senão neutro (limiar é escolha do grupo)
Igual nos dois	Textos, gabarito, normalização, tentativas, timeout, versões de SDK, aquecimento
Diferente	Máquina, rede e horário → qualidade comparável; latência NÃO é comparável entre provedores

1 texto por chamada, timeout 30s, até 3 tentativas só em erro transitório; retries automáticos dos SDKs desligados (o do Google tentaria por até 600s e esconderia falhas).

Métricas usadas na análise

Aspecto	Métrica
Qualidade	Acurácia, precisão/revocação/F1 por classe, macro-F1, matriz de confusão
Diferença entre provedores	McNemar exato + kappa entre previsões (mesmos textos)
Sucesso	Por tentativa e por texto
Latência	Mediana e p95, sem a chamada de aquecimento
Custo	Unidades × tarifa, com e sem franquia

93 testes offline passando; 0 erros em 374 chamadas no experimento inteiro, sem nenhuma nova tentativa.

Resultado principal: empate estatístico

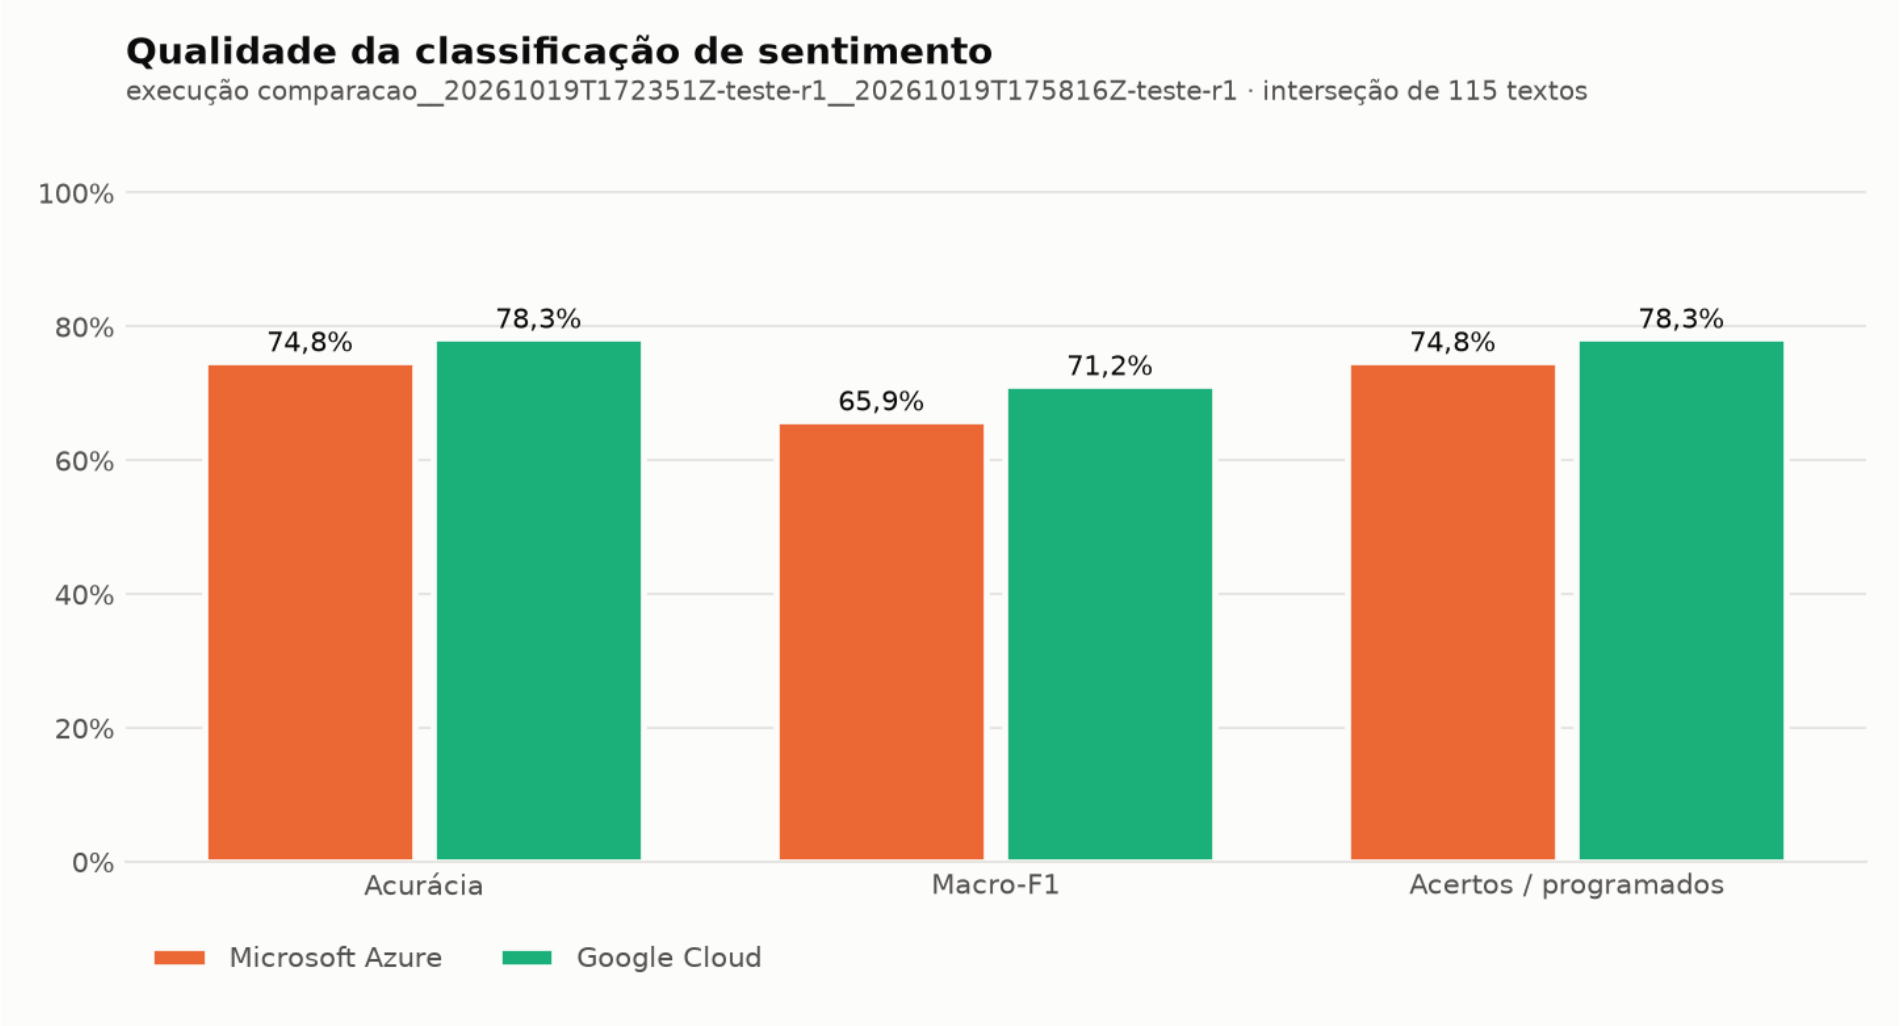
115 textos — todas as chamadas funcionaram nos dois provedores.

74,8%	78,3%	0,541
acurácia Azure (3 classes)	acurácia Google (3 classes)	McNemar (p)

- Diferença de 3,5 pontos NÃO é estatisticamente significativa.
- Azure acertou sozinha 10, Google sozinho 14, os dois erraram 15, os dois acertaram 76.
- Sem a classe neutra (100 textos): Azure 82,0% x Google 81,0% — ainda empate (p = 1,000).

Qualidade em gráfico: acurácia e macro-F1

Mesmos 115 textos nos dois provedores — diferença não significativa (McNemar p = 0,541).



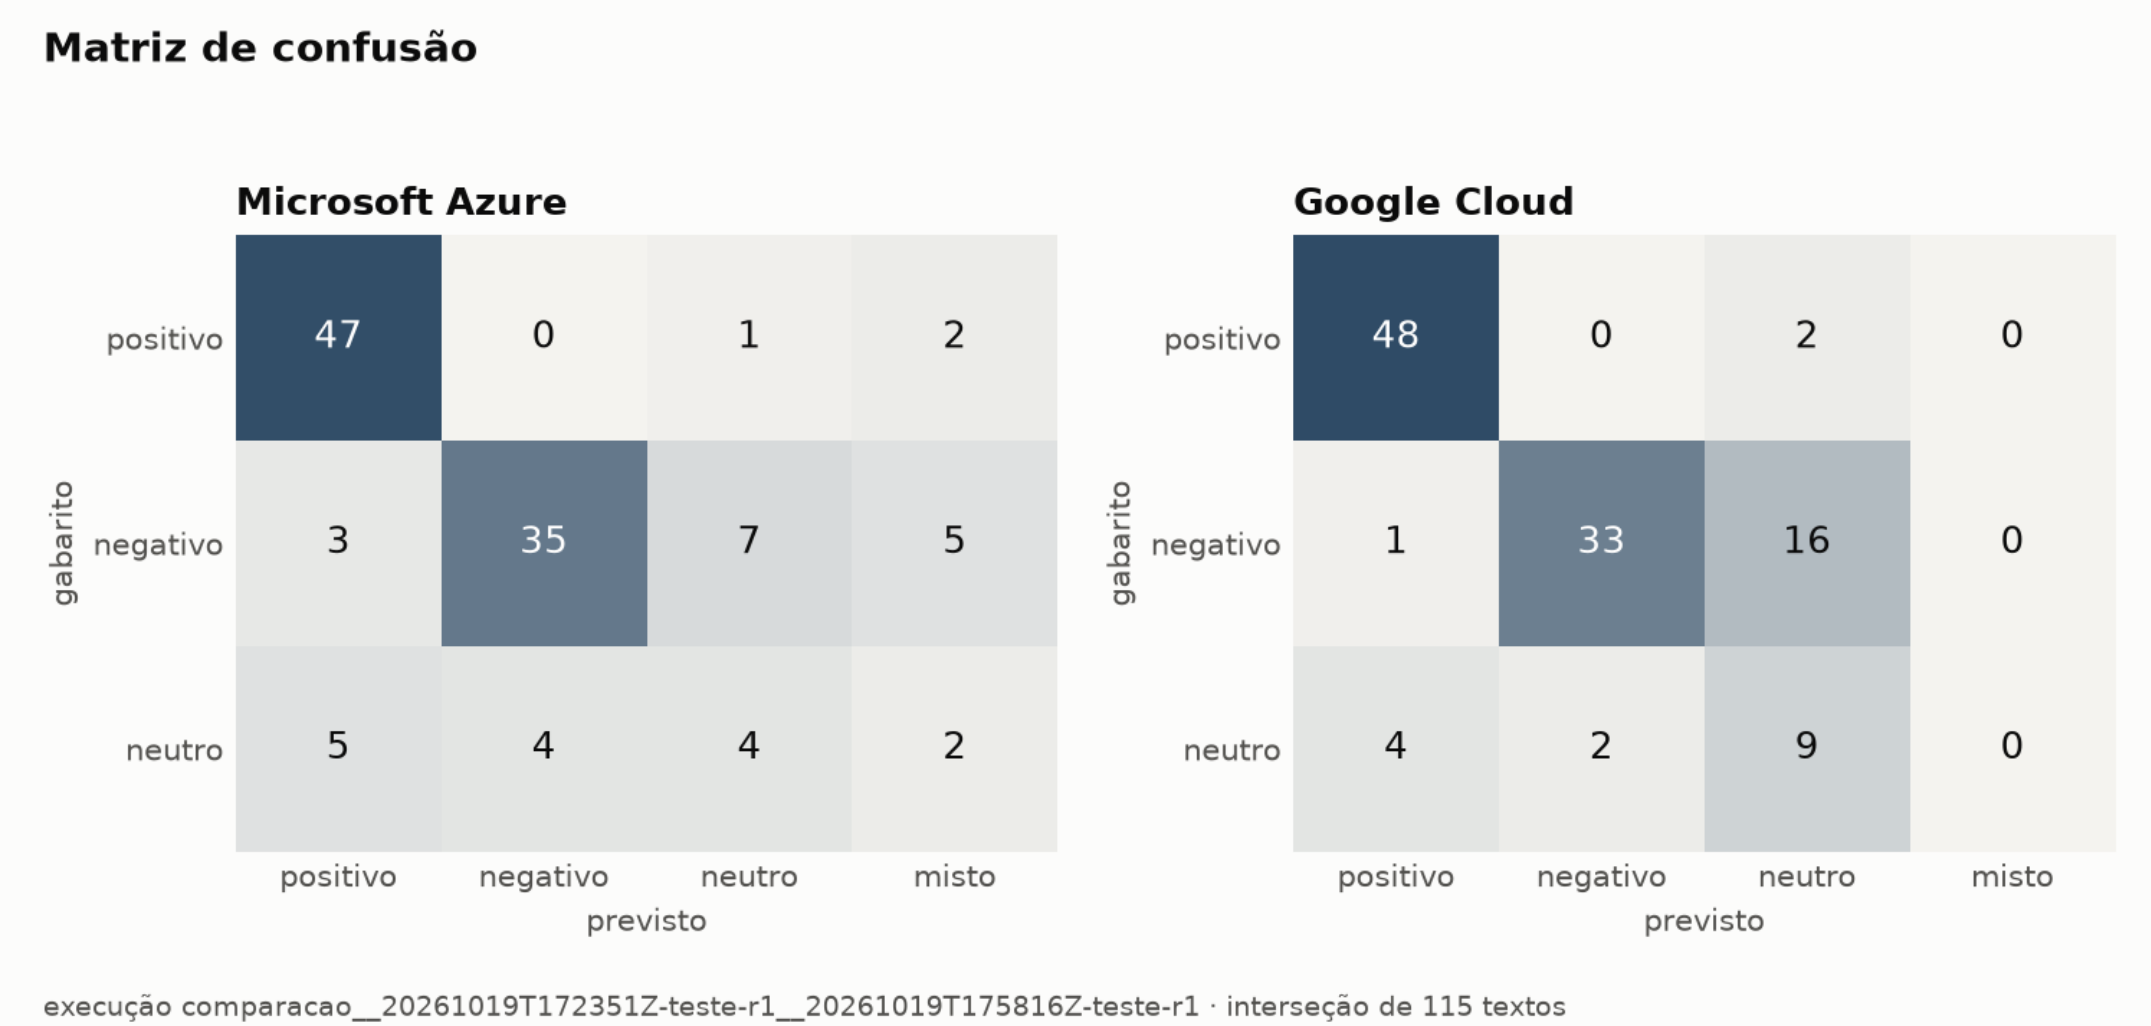
Onde cada um erra, por classe

Classe (suporte)	Azure — prec. / rev. / F1	Google — prec. / rev. / F1
positivo (50)	85,5% / 94,0% / 0,895	90,6% / 96,0% / 0,932
negativo (50)	89,7% / 70,0% / 0,787	94,3% / 66,0% / 0,776
neutro (15)	33,3% / 26,7% / 0,296	33,3% / 60,0% / 0,429

O Google manda 16 dos 50 negativos para 'neutro': reclamações factuais sem palavra de emoção ("veio faltando uma peça"). A Azure espalha os erros entre neutro, misto e positivo. Nenhum dos dois é confiável para a classe neutra.

Matriz de confusão

Linhas: gabarito · colunas: previsão. O erro mais frequente do Google é negativo → neutro (16 textos).



Sucesso das chamadas e custo

	Azure	Google
Sucesso por tentativa / por texto	100% · 115/115	100% · 115/115
Erros de limite, timeout ou servidor	0	0
Unidades usadas no experimento (piloto + teste + exploratório)	187	187
Franquia mensal	5.000	5.000
Custo estimado com franquia	US$ 0,00	US$ 0,00

Menos de 4% da franquia usada. Diferença está na garantia: o F0 da Azure recusa ao esgotar a cota; o Google exige faturamento. Custo observado: a conferir no console.

Latência — cada provedor isoladamente

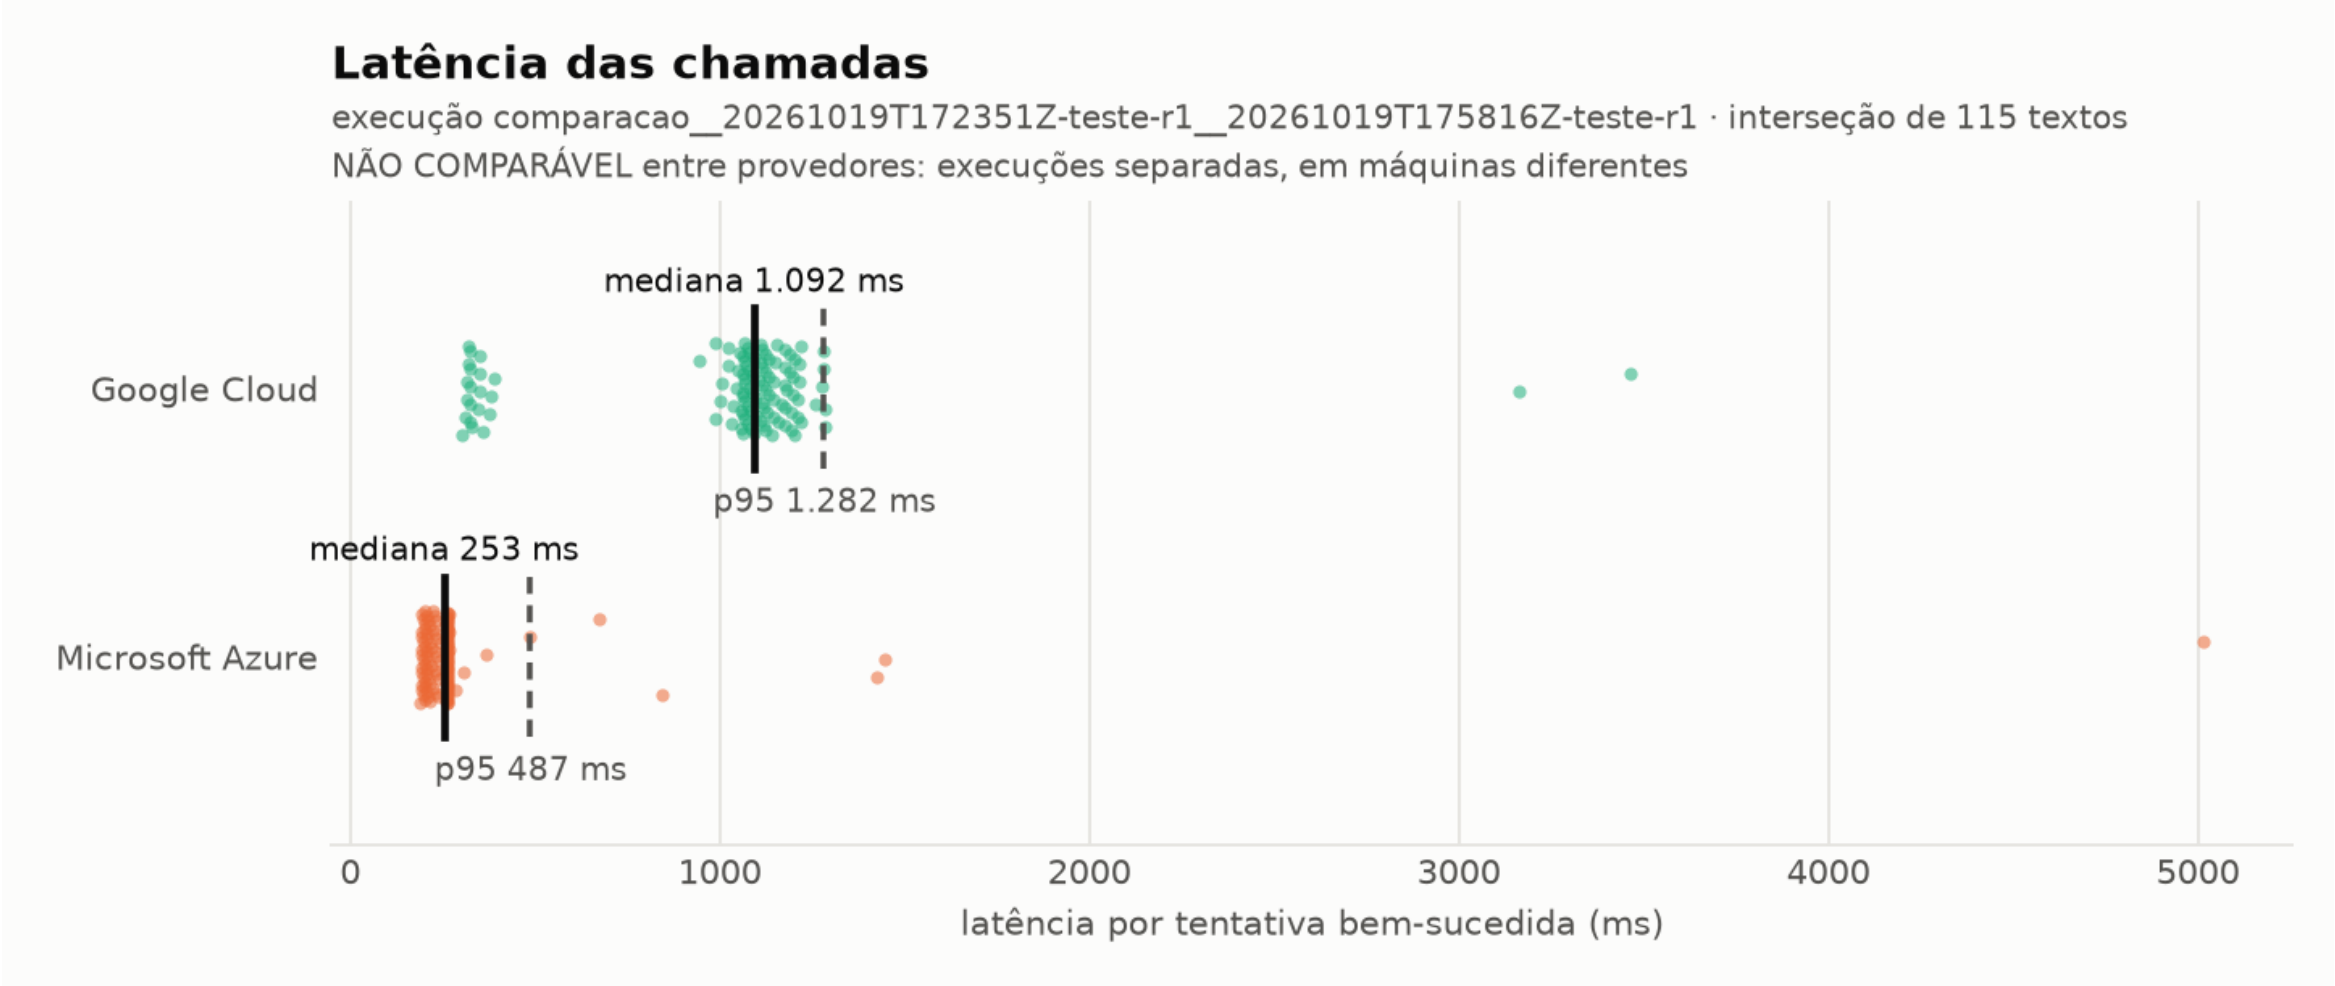
Não comparar entre si: máquinas e redes diferentes.

	Azure	Google
Mediana	253 ms	1.092 ms
p95	487 ms	1.282 ms
Mínimo / máximo	190 / 5.015 ms	301 / 3.465 ms
Aquecimento (1ª chamada, fora da medida)	865 ms	1.646 ms

Nos dois, a 1ª chamada é mais lenta (conexão + autenticação). No Google, 20 das 115 chamadas ficaram perto de 300ms e o resto perto de 1,1s — causa não investigada.

Latência: distribuição das chamadas

Cada ponto é uma chamada. Não comparar entre si: máquinas e redes diferentes.



Os 39 textos ambíguos (gabarito 'misto')

Elogio e crítica sem predominância — analisados à parte da métrica principal.

Previsão	Azure	Google
misto	10 (26%)	não existe no Google
neutro	0	24 (62%)
positivo	21 (54%)	11 (28%)
negativo	8 (21%)	4 (10%)

O Google empurra a ambiguidade para o zero (62% viram neutro). A Azure reconhece parte dos mistos (26%), mas prefere declarar um lado.

Confronto com a Etapa 1

13 expectativas registradas ANTES da coleta. Nenhuma foi contrariada.

Expectativa da Etapa 1	Conclusão
Azure devolve classe pronta; Google só um número	Confirma
'Mixed' da Azure aparece em positivos/negativos do gabarito	Confirma
Mistos do Google caem perto de zero	Confirma e complementa (também em negativos factuais)
Mesmo número de unidades cobradas para textos curtos	Confirma
Configuração: Azure simples, Google com mais passos	Complementa (4 obstáculos não documentados)

Os testes confirmam a Etapa 1 no formato das respostas e no custo, e complementam no esforço real de configurar o Google e no score com reclamações sem emoção.

Conclusões

- Qualidade: empate neste conjunto — decidir por outros critérios.
- Erram de jeitos diferentes: Google ignora reclamações factuais; Azure às vezes declara 'mixed' em negativos claros.
- Nenhum é confiável para a classe neutra. Custo e confiabilidade não diferenciam neste volume.
- Azure: classe pronta, configuração simples, teto de custo garantido (F0). Risco: análise de sentimento encerra em 2029.
- Google: score contínuo para definir o próprio corte; integração mais trabalhosa.

Repositório público: github.com/DaviFPassos/Teste_comparativo_nuvem