Comparação de Serviços de Inteligência Artificial em Nuvem

AWS × Microsoft Azure × Google Cloud — Síntese da Etapa 1 (análise documental)

AWS | Azure | Google Cloud

Mestrado em Informática Aplicada (PPGIA) — Universidade de Fortaleza (Unifor)
Davi Fonseca Passos · Rafael Fonseca Pessoa · Lucca Melo Nunes

Objetivo e perspectiva do trabalho

- Perspectiva de quem decide integrar um serviço de IA pronto à aplicação — não de quem estuda o modelo por trás dele
- Perguntas que orientam cada capítulo: o que o serviço faz, como se chama, o que aceita de entrada, o que devolve, como se autentica
- ...que limites impõe, quanto custa, e em que situação compensa escolher um em vez de outro
- Esta etapa é documental: nenhum código foi executado — a execução real fica para a Etapa 2

Metodologia e fontes de preço

- Toda afirmação técnica e todo preço vêm de documentação oficial, consultada em 23–24/09/2026, com URL e data registradas
- Informação não localizada vira pendência declarada — nunca é preenchida por estimativa
- Preços via AWS Price List API e Azure Retail Prices API: as páginas comerciais da Azure e do Google carregam a tabela por JavaScript e mostram só "$-" no conteúdo estático
- Exemplos de código adaptados da documentação oficial, não executados — permitido nesta etapa pelo enunciado; nenhuma credencial embutida

Região de referência: AWS us-east-1 · Azure East US · Google global (texto/imagem) e us-central1 (áudio) — us-central1 não é US East, e essa diferença fica registrada como limitação

Critérios de seleção das categorias

- Diversidade de domínio de entrada: texto, imagem e áudio — evita comparar 3 funcionalidades do mesmo domínio (ex.: sentimento + entidades + frases-chave seriam todas NLP)
- Relevância para quem integra IA a um produto: classificar opinião de usuário, indexar/moderar imagens, transcrever áudio — as 3 são consumíveis por API, sem treinar modelo próprio
- Existência de oferta equivalente nos 3 provedores nas 3 categorias

Categorias descartadas: tradução automática (domínio próximo demais de NLP), OCR (sobreposição com visão) e modelos generativos (preço por token volátil)

Três categorias, nove serviços

Categoria	AWS	Microsoft Azure	Google Cloud	Operação comparada
NLP / texto	Amazon Comprehend	Azure Language	Cloud Natural Language API	Sentimento de documento
Visão computacional	Amazon Rekognition	Azure Vision	Cloud Vision API	Detecção de rótulos
Fala para texto	Amazon Transcribe	Azure Speech	Cloud Speech-to-Text V2	Transcrição em lote

- Todos pré-treinados: chamada de API, sem treinar modelo próprio
- Oferta equivalente nos 3 provedores nas 3 categorias

Equivalência tem limites

- O formato de saída do sentimento diverge nos 3: AWS devolve 4 classes com score; Azure devolve rótulo por documento e por sentença; Google não devolve classe alguma
- Os vocabulários de rótulos de imagem não têm equivalência oficial entre provedores, e as escalas de confiança diferem (0–100 na AWS, 0–1 nos demais)
- "Lote" significa compromissos de tempo diferentes em cada provedor na transcrição de áudio — isso afeta diretamente a comparação de preço

A comparação é entre serviços concorrentes, não idênticos — esses 3 limites reaparecem em cada capítulo

Sentimento de documento: operação e entrada

- Caso de uso: priorizar atendimento e medir satisfação a partir de avaliações e comentários, sem treinar modelo próprio

Aspecto	AWS	Azure	Google
Operação síncrona	DetectSentiment	REST API ou client library	analyzeSentiment
Tamanho máx. do documento	5 KB (UTF-8)	5.120 caracteres	1.000.000 bytes / 100.000 tokens
Documentos por requisição	1 (até 25 em BatchDetectSentiment)	10	1
Tamanho máx. da requisição	—	1 MB	—

Análise de sentimento: o que cada um entrega

AWS

- 4 classes: POSITIVE, NEGATIVE, NEUTRAL, MIXED — com score para cada uma
- MIXED é classe própria do modelo, pode sair de uma única frase
- pt genérico (sem variante) — 12 idiomas no total

Azure

- Rótulo por documento e por sentença, 3 scores de confiança
- mixed é composto: exige sentença positiva + negativa no mesmo doc
- Única que distingue pt-BR de pt-PT — 94 idiomas; única com contêiner Docker

Google Cloud

- Não devolve classe — só score (-1 a +1) e magnitude
- O programador define os limiares de positivo/neutro/negativo
- pt genérico — 16 idiomas no total

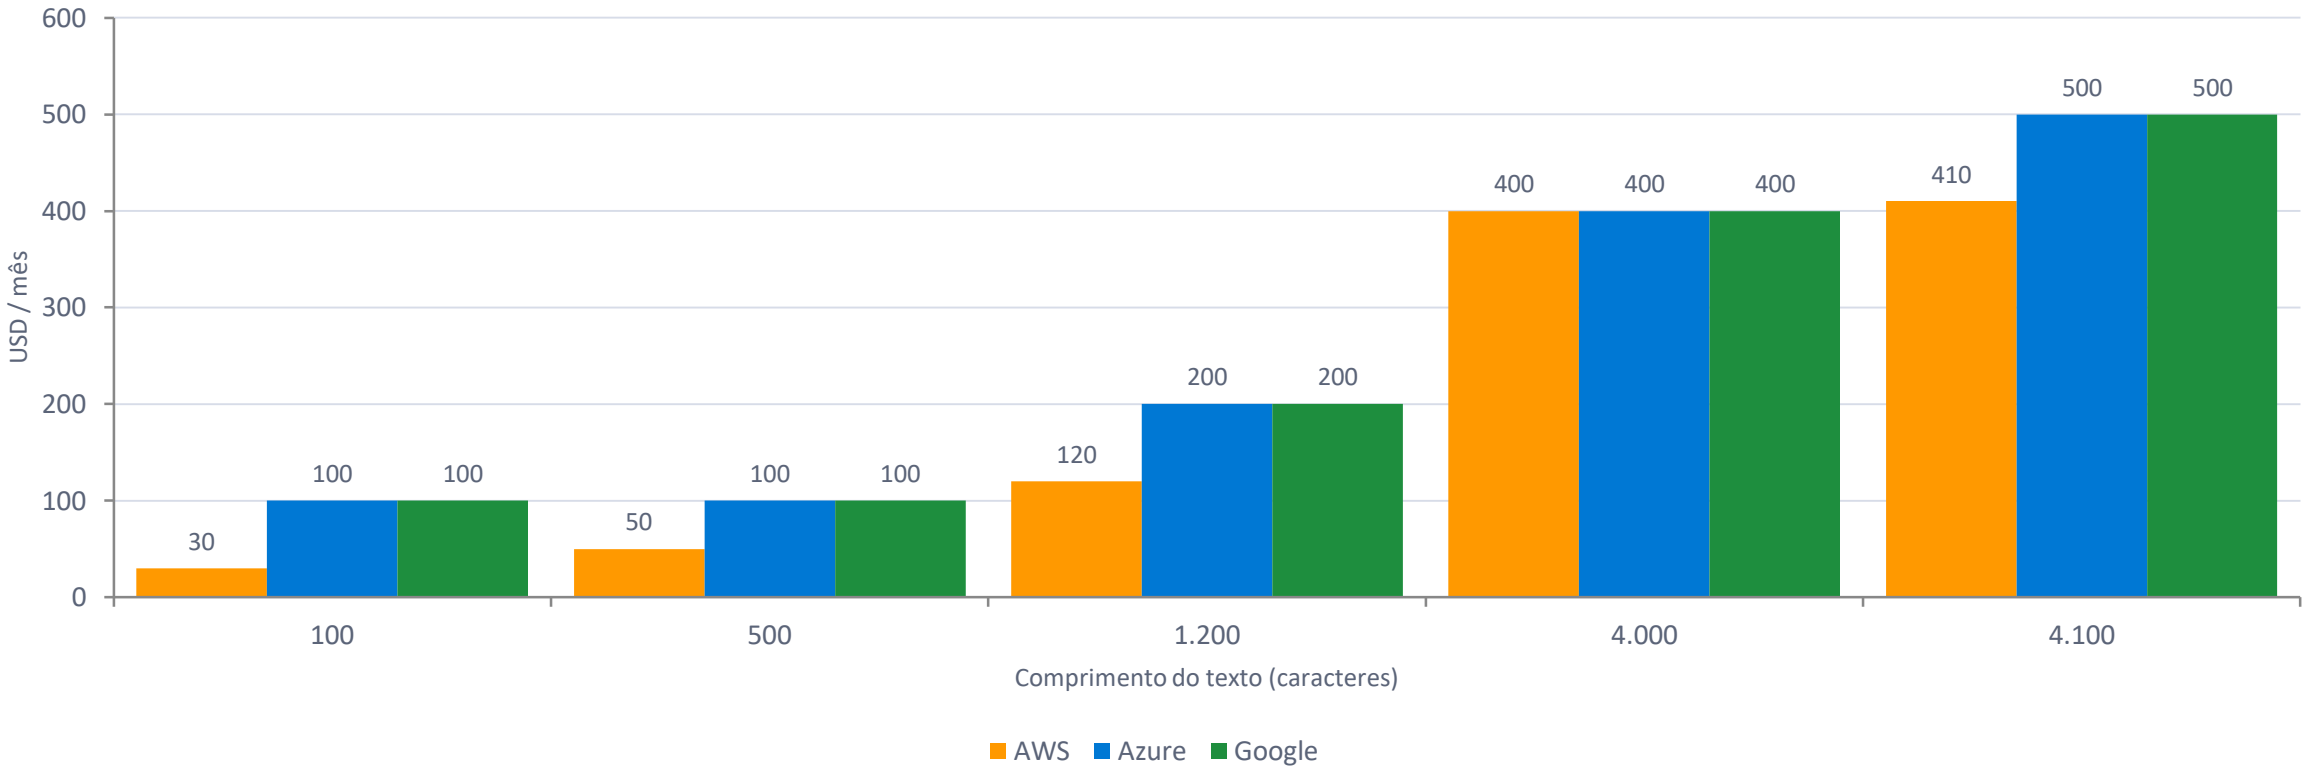
Encerramento anunciado: sentimento e opinion mining da Azure se aposentam em 31/03/2029

Limites, autenticação e situação do serviço

Aspecto	AWS	Azure	Google
Limite de requisições	Throttling dinâmico, sem número fixo publicado	S0/F0: 100 req/s e 300/min	600 req/min e 800.000/dia
Regiões	13 regiões; nenhuma no Brasil	Endpoint regional; East US disponível	API global
Autenticação	Credenciais IAM	Chave + endpoint, ou Microsoft Entra ID	Application Default Credentials ou chave
Situação do serviço	Nenhum aviso de descontinuação	Sentimento se aposenta em 31/03/2029	Nenhum aviso (só v1beta1, encerrada em 2019)

O throttling dinâmico da AWS é a diferença prática mais relevante: não há número publicado para dimensionar a aplicação

Custo de sentimento: a unidade pesa mais que o preço



100.000 documentos/mês, sem franquia — em 100 caracteres a AWS cobra 30% do que cobram os concorrentes (-70%); o empate em 3.901–4.000 é uma janela de 100 caracteres, não um ponto isolado

NLP — franquias

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	50.000 unidades/mês por API	Promocional, 12 meses	Sim, só no 1º ano
Azure	5.000 registros/mês	Tier F0 separado	Não — recurso à parte, sem abatimento no tier pago
Google	5.000 unidades/mês	Primeira faixa da tabela	Sim, permanente

No cenário de 100 caracteres: $25 na AWS (só no 1º ano), $100 na Azure (sem abatimento) e $95 no Google (permanente)

Detecção de rótulos: operação e entrada

- Caso de uso: indexar e tornar pesquisável um acervo de imagens, alimentar filtros de catálogo, fazer triagem antes de revisão humana

Aspecto	AWS	Azure	Google
Operação	DetectLabels (GENERAL_LABELS)	Tags via Analyze Image	LABEL_DETECTION via images:annotate
Formatos aceitos	Apenas PNG e JPEG	JPEG, PNG, GIF, BMP, WEBP, ICO, TIFF, MPO	JPEG, PNG, GIF, BMP, WEBP, RAW, ICO
Tamanho máximo	15 MB (S3) / 5 MB (bytes)	< 20 MB (versão 4.0)	20 MB; requisição JSON até 10 MB
Origem da imagem	Bucket S3 ou bytes	Bytes ou URL da imagem	Base64, gs:// ou URL remota

Detecção de rótulos em imagem

AWS

- Única com taxonomia: Parents, Aliases, Categories e filtros no servidor
- Escala de confiança 0–100
- Apenas PNG e JPEG — a mais restritiva na entrada

Azure

- Lista plana de tags, escala 0–1
- Única com lista fechada de regiões para a própria funcionalidade
- Image Analysis 4.0 encerra em 25/09/2028; 4 recursos em preview já saíram em 2025

Google Cloud

- Mais formatos aceitos: RAW, WEBP, GIF, BMP, ICO além de PNG/JPEG
- Única com identificador estável (mid) ligado ao Knowledge Graph
- Escala de confiança 0–1

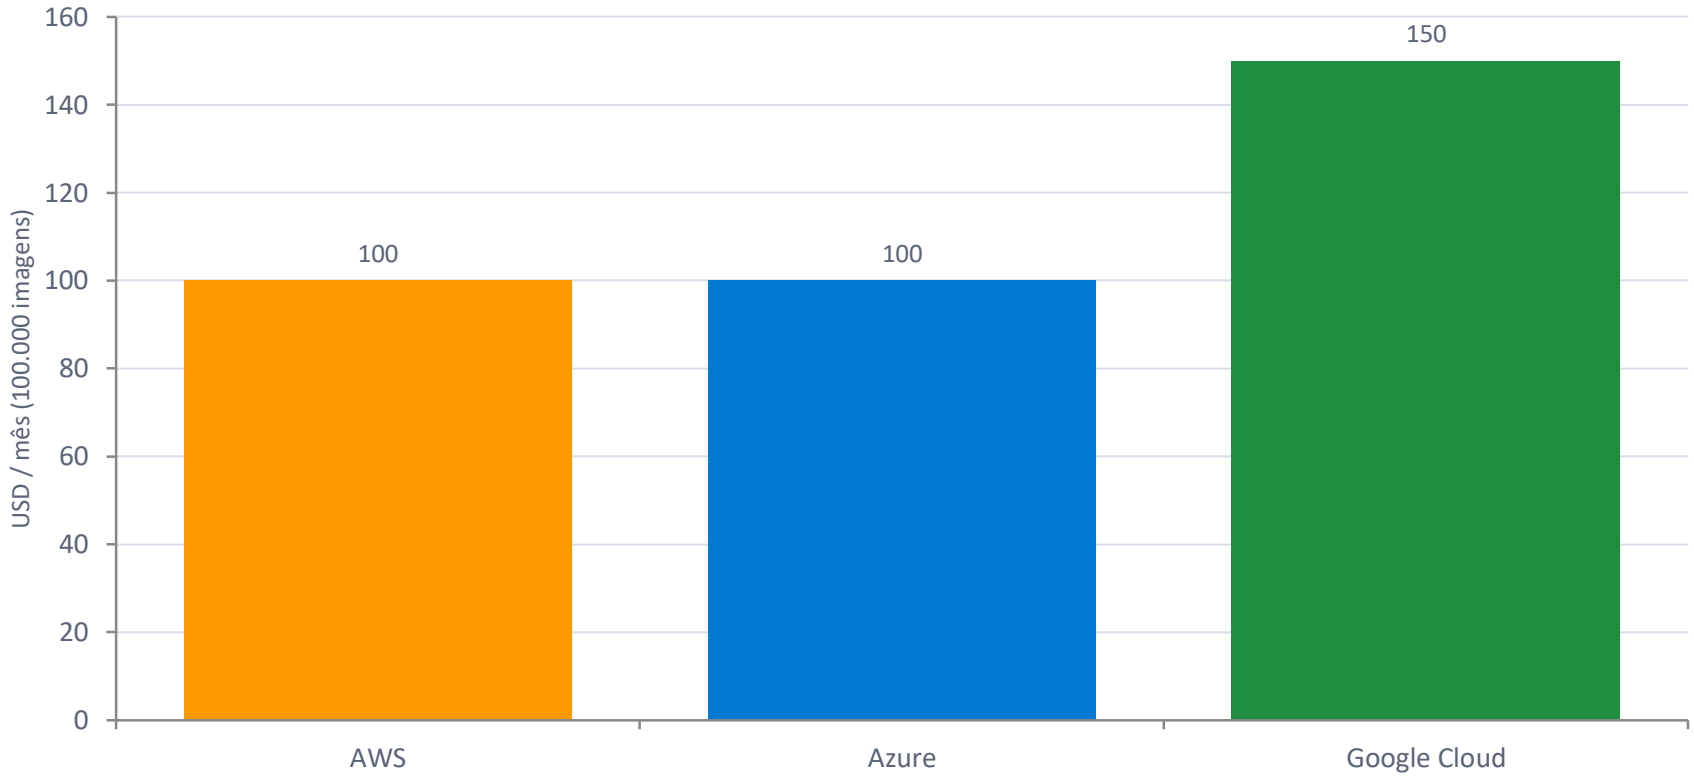
Vocabulários de rótulos não têm equivalência oficial entre provedores — trocar de provedor exige recalibrar limiares e remapear termos

Limites, autenticação e situação do serviço

Aspecto	AWS	Azure	Google
Processamento em massa	Image Bulk Analysis: até 10.000 imagens/lote	—	—
Limite de requisições	TPS ajustável via Service Quotas	Conforme o tier do recurso	Cotas por projeto
Autenticação	Credenciais IAM (+ leitura no S3)	Chave + endpoint do recurso	Application Default Credentials ou chave
Situação do serviço	Nenhum aviso	Image Analysis 4.0 encerra 25/09/2028	Nenhum aviso

A Azure é a única com restrição de região documentada para a própria funcionalidade — AWS e Google não impõem essa barreira

Custo de detecção de rótulos: a categoria mais previsível



A unidade de cobrança é praticamente a mesma nos 3 (uma imagem) — sem efeito de granularidade. AWS e Azure empatam em $100; Google fica 50% acima, em $150

Visão — franquias

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	1.000 imagens/mês	Promocional, 12 meses	Sim, só no 1º ano
Azure	5.000 transações/mês (20/min)	Tier F0 separado	Não — a cota mensal (5% do necessário) já impede sozinha
Google	1.000 unidades/mês	Primeira faixa, permanente	Sim, permanente

No cenário de 100 mil imagens: $99 (AWS, só no 1º ano), $100 (Azure, sem abatimento) e $148,50 (Google, permanente)

Transcrição em lote: operação e entrada

- Caso de uso: gerar legendas, permitir busca textual e alimentar análises posteriores — inclusive análise de sentimento

Aspecto	AWS	Azure	Google
Operação em lote	StartTranscriptionJob	Transcription_Create	BatchRecognize
Formatos	AMR, FLAC, M4A, MP3, MP4, Ogg, WebM, WAV	WAV, MP3, OPUS/OGG, FLAC, WMA, AAC, AMR, WebM	Formatos suportados pela API v2
Origem do áudio	Obrigatoriamente bucket S3	URI público, SAS ou Blob Storage	Cloud Storage (gs://)
Canais de áudio	Mono e estéreo (máx. 2)	—	—

Transcrição em lote: a urgência é a variável escondida

AWS

- Exige áudio em bucket do Amazon S3
- Não publica expectativa de prazo — fila é só uma opção do cliente
- Não expõe escolha de modelo na transcrição em lote padrão

Azure

- Única que aceita URI público como origem do áudio
- Publica expectativa de latência: p90 < 6h, mas admite até 24h em pico
- Caminho mais elaborado de isolamento de armazenamento (identidade gerenciada)

Google Cloud

- Dois preços/prioridades: padrão e dynamic batch (menor urgência)
- Perfis de modelo prontos por tipo de áudio: chirp_3, telephony, long, short
- Diarização disponível no modelo chirp_3

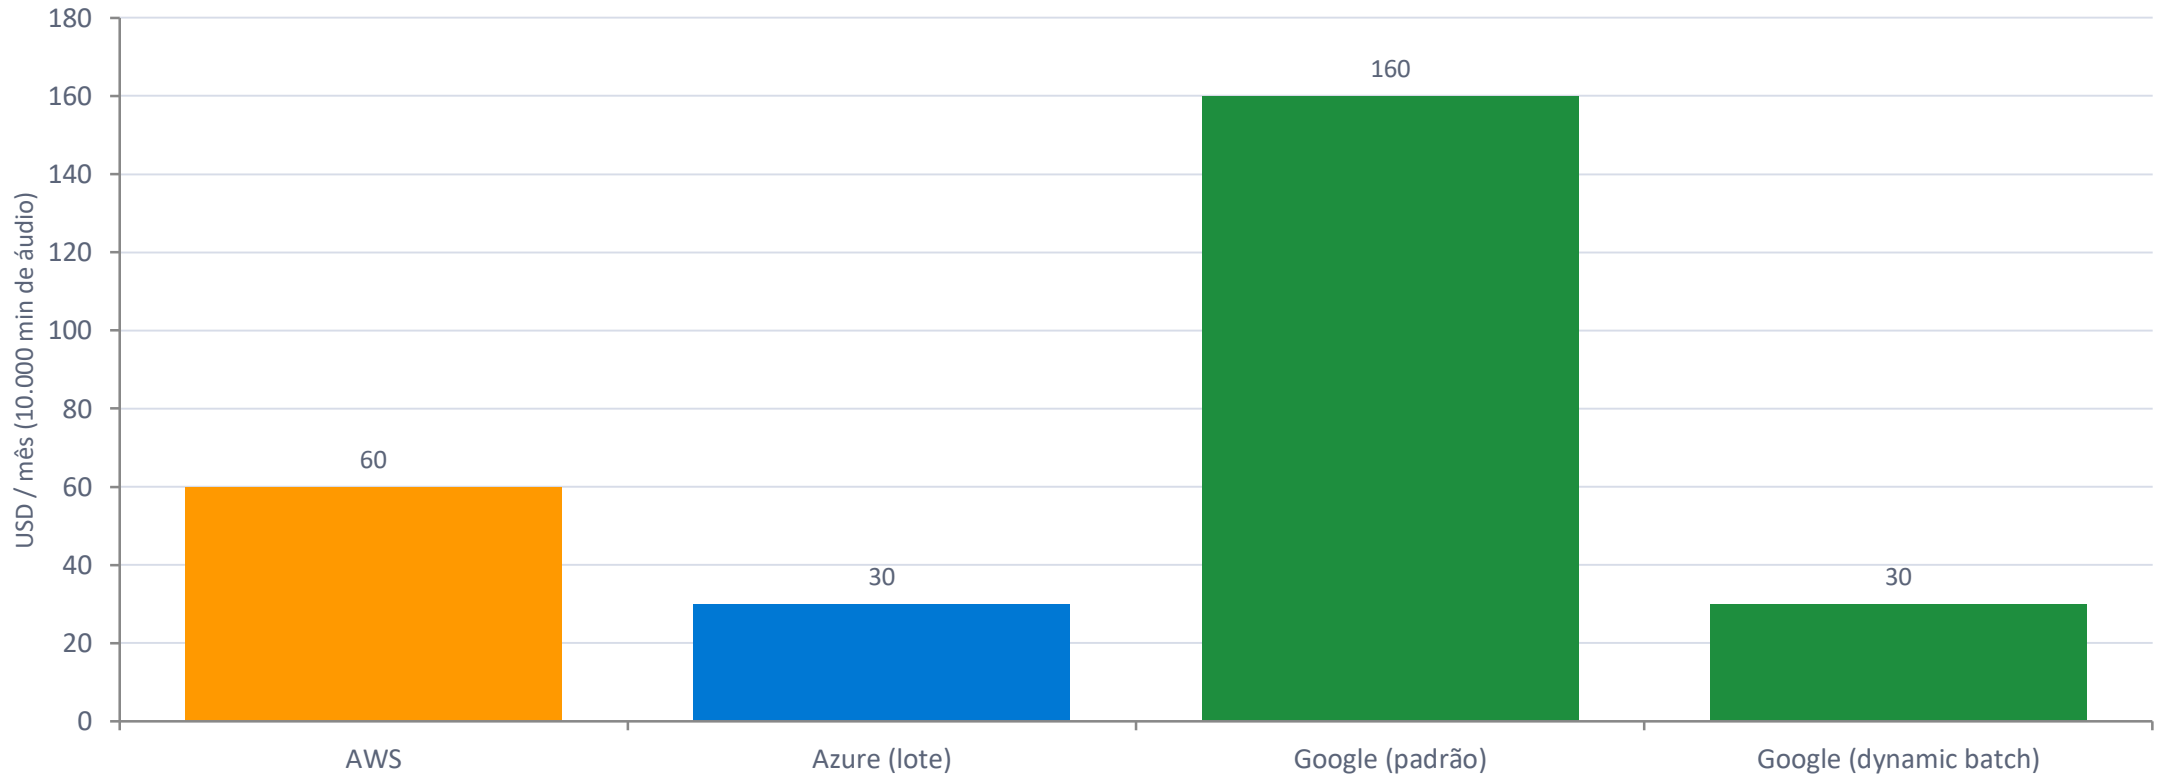
Os 3 provedores distinguem pt-BR formalmente nesta categoria — diferente do NLP, onde só a Azure faz essa distinção

Latência, limites e situação do serviço

Aspecto	AWS	Azure	Google
Agendamento	Fila opcional do cliente	Best-effort: p90 < 6h, até 24h em pico	Operação de longa duração
Limites de entrada	Não localizados (página inacessível)	1 GB/arquivo; 1.000 arquivos/requisição	Não localizados para o BatchRecognize
Retenção do resultado	Bucket padrão apagado em 90 dias	timeToLiveHours: 6h a 31 dias	Cloud Storage ou resposta da operação
Situação do serviço	Nenhum aviso	Nenhum aviso	Nenhum aviso

Única das 3 categorias sem nenhum aviso de descontinuação em nenhum dos provedores — nas outras duas, a Azure tem encerramento anunciado

Custo de transcrição: depende da urgência aceita



Comparar $30 da Azure com $160 do Google padrão compara urgências diferentes. Em menor urgência, Azure e Google empatam em $30 — a AWS cobra o dobro sem oferecer um modo mais barato

Fala — franquias

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	60 minutos/mês	Promocional, 12 meses	Sim, só no 1º ano ($59,64 em vez de $60)
Azure	5 horas/mês	Tier F0 — lote "não disponível para F0"	Não — a operação nem existe nesse tier
Google	—	Não localizada para a V2 (a de 60 min é da V1)	Pendência, não zero

Abater as 5h do F0 da Azure produziria $29,10 em vez dos $30 corretos — por isso a comparação principal usa sempre preços sem franquia

O que atravessa as três categorias

Não há vencedor único

Em NLP o parâmetro é o comprimento do texto; em visão, o volume mensal; em fala, a tolerância a fila — quem decide é a aplicação, não o provedor

A granularidade da unidade pesa mais que o preço unitário

O achado mais transferível do trabalho: preços unitários equivalentes, mas blocos de cobrança diferentes mudam o resultado em até 3,3×

Azure é a mais completa tecnicamente e a mais arriscada no calendário

Única com 94 idiomas, Docker local, URI público de áudio — e única com 2 encerramentos anunciados entre as 9 ofertas

O custo de troca entre provedores é alto

Formato de saída, escala de confiança e arquitetura de entrada diferem — trocar não é só trocar o endpoint

Franquia gratuita não é desconto

- As 3 nuvens anunciam "camada gratuita", e as 3 querem dizer coisas diferentes:

Provedor	O que é	Entra no cenário?
AWS	Free Tier promocional, na mesma conta e no mesmo tier da operação	Sim, só nos 12 primeiros meses
Azure	Tier F0, um recurso separado do tier pago, com cota e limites próprios	Não — e na transcrição em lote o F0 nem oferece a operação
Google	Primeira faixa da própria tabela, cobrada a $0,00	Sim, permanente

Por isso a comparação principal deste trabalho usa sempre preços sem franquia: é a única base que significa a mesma coisa nos 3 provedores

O que vem na Etapa 2

- Esta etapa é documental: não mede acerto, latência nem taxa de erro — os exemplos de código não foram executados
- Etapa 2: executar de fato (análise de sentimento em pt-BR), com dataset e gabarito próprios
- Medir: acurácia / macro-F1, latência, taxa de sucesso e custo real por código
- Confrontar os resultados experimentais com as expectativas documentais desta etapa

Repositório completo (código, dados, gráficos e capítulos):

github.com/DaviFPassos/Teste_comparativo_nuvem

Obrigado!