

Comparação de Serviços de Inteligência Artificial em Nuvem

Etapa 1 — Análise Comparativa

Disciplina: Computação em Nuvem

Programa: Mestrado em Ciência da Computação — Universidade de Fortaleza (UNIFOR)

Integrantes:

- Davi Fonseca Passos
- Rafael Fonseca Pessoa
- Lucca Melo Nunes

Provedores analisados: Amazon Web Services · Microsoft Azure · Google Cloud

Região dos preços: `us-east-1` (AWS) · `East US` (Azure) · global em NLP e visão e `us-central1` em fala (Google Cloud)

Moeda: USD · **Preços consultados em:** 23/09/2026

Repositório público (código, dados, gráficos e capítulos completos):

https://github.com/DaviFPassos/Teste_comparativo_nuvem

1. Introdução

Este relatório apresenta a análise comparativa de serviços de inteligência artificial oferecidos por **Amazon Web Services (AWS)**, **Microsoft Azure** e **Google Cloud**, sob a perspectiva de um desenvolvedor que precisa escolher entre eles para incorporá-los a uma aplicação.

A perspectiva adotada é deliberadamente a de quem **consome** o serviço, e não a de quem estuda o modelo por trás dele. As perguntas que orientam cada capítulo são as de uma decisão de integração: o que o serviço faz, como se chama, o que aceita de entrada, o que devolve, como se autentica, que limites impõe, quanto custa e em que situação compensa.

Como este relatório foi construído

Toda afirmação técnica e todo preço vêm de **documentação oficial dos provedores**, consultada **entre 23 e 26 de setembro de 2026** — a data exata de cada fonte está registrada em `referencias/fontes.md`. Todos os preços foram consultados em 23/09/2026; algumas confirmações técnicas complementares foram feitas em 26/09/2026, durante a revisão do relatório. Onde uma informação não foi localizada, ela aparece como **pendência declarada** — nunca preenchida por estimativa.

Duas decisões metodológicas merecem registro:

Os preços vieram das APIs públicas de preço dos provedores, não das páginas comerciais. As páginas de preço da Azure e do Google entregam suas tabelas por JavaScript, exibindo apenas `$-` no conteúdo estático. Em vez de recorrer a fontes secundárias, os valores foram obtidos da *AWS Price List API* e da *Azure Retail Prices API* — ambas públicas e mantidas pelos próprios provedores — e das tabelas servidas pela página de preços do Google.

Os exemplos de código não foram executados. A seção 3 do enunciado permite isso explicitamente nesta etapa, e cada arquivo declara esse estado. Nenhum resultado de execução, medição de latência ou taxa de acerto é apresentado neste relatório: tudo isso é objeto da Etapa 2.

Região, moeda e data

Parâmetro	Valor
AWS	<code>us-east-1</code> (N. Virginia) nas três categorias
Microsoft Azure	<code>East US</code> nas três categorias
Google Cloud	Preço global em Natural Language e Vision; <code>us-central1</code> (Iowa) em Speech-to-Text
Moeda	USD
Data de consulta dos preços	23/09/2026

US East foi escolhida por ser a região de referência das tabelas da AWS e da Azure e por ter as nove ofertas disponíveis. Duas das APIs do Google comparadas (Natural Language e Vision) têm **preço global, não regional**.

Uma ressalva explícita sobre a terceira. A tabela da Cloud Speech-to-Text V2 é regional, e o preço utilizado é o de `us-central1 (Iowa)` — que é US Central, **não** US East. Essa é a única linha do trabalho em que a região do Google não coincide com a das outras duas, e ela está registrada assim em `custos/premissas.csv` e na lista de limitações, em vez de ser apresentada como se fosse a mesma região.

2. Seleção das categorias e critérios

O enunciado (seção 2) determina que a seleção "deverá privilegiar a relevância para o desenvolvimento de aplicações e a diversidade de funcionalidades", evitando "selecionar vários serviços pertencentes essencialmente ao mesmo domínio de aplicação".

O grupo selecionou **três categorias**, aplicando três critérios:

1. Diversidade de domínio de entrada. As categorias tratam modalidades diferentes — **texto, imagem e áudio**. Isso evita o erro que o próprio enunciado adverte: analisar sentimento, entidades e

frases-chave seria comparar três *funcionalidades do mesmo domínio* (processamento de linguagem natural), não três categorias distintas.

2. Relevância para quem integra IA a uma aplicação. As três resolvem problemas correntes de produto — classificar opinião de usuários, indexar e moderar imagens, transcrever áudio — e todas são consumíveis por API ou SDK com modelos pré-treinados, sem treinar modelo próprio.

3. Existência de oferta concorrente nos três provedores. O enunciado exige pelo menos dois provedores por categoria e recomenda incluir os três quando houver equivalência. Nas três categorias há oferta gerenciada equivalente na AWS, na Azure e no Google Cloud, de modo que **os três entram em todas as comparações**.

Categorias e serviços comparados

Categoria	AWS	Microsoft Azure	Google Cloud	Operação comparada
NLP / análise de texto	Amazon Comprehend	Azure Language in Foundry Tools	Cloud Natural Language API	Sentimento de documento
Visão computacional	Amazon Rekognition	Azure Vision in Foundry Tools	Cloud Vision API	Deteção de rótulos
Fala para texto	Amazon Transcribe	Azure Speech in Foundry Tools	Cloud Speech-to-Text V2	Transcrição em lote

Categorias consideradas e descartadas: **tradução automática** (domínio de entrada próximo demais de NLP), **análise de documentos/OCR** (sobreposição com visão computacional) e **modelos generativos** (comparação dominada pela escolha de modelo, com preços por token de alta volatilidade).

Nomenclatura atualizada

Durante a pesquisa constatou-se que **a Microsoft reorganizou suas ofertas de IA sob a marca Foundry Tools**. Os nomes usados neste relatório são os vigentes em setembro de 2026; os nomes anteriores (Azure AI Language, Text Analytics, Azure AI Vision, Azure AI Speech) aparecem entre parênteses na primeira ocorrência de cada capítulo.

Equivalência e seus limites

A comparação é entre serviços **concorrentes**, não idênticos. Três limites à equivalência foram identificados já na seleção e são retomados nos capítulos:

- O formato de saída do sentimento diverge nos três.** A AWS retorna uma de quatro classes, com um score para cada uma. A Azure retorna rótulo em nível de documento e de sentença, com três scores de confiança — mas **quatro** rótulos possíveis no documento, porque `mixed` aparece quando há sentenças positivas e negativas. O Google não retorna classe alguma, apenas `score` e `magnitude`.

- **Os vocabulários de rótulos de imagem não têm equivalência oficial**, e as escalas de confiança diferem (0-100 na AWS, 0-1 nos demais).
- **"Lote" significa compromissos de tempo diferentes** em cada provedor na transcrição de áudio, o que afeta diretamente a comparação de preço.

3. NLP / análise de texto: análise de sentimento

- **Operação comparada:** sentimento em nível de documento, sobre o mesmo texto em português (0 atendimento foi excelente.)
- **Modo de chamada:** síncrono, um documento por chamada
- **Data da consulta às fontes:** 23/09/2026
- **Região de referência:** US East (us-east-1 / East US / global no caso do Google)

1. Objetivo da categoria e caso de uso

Análise de sentimento classifica a opinião predominante expressa em um texto. O caso de uso típico é processar avaliações de clientes, comentários de suporte ou menções em redes sociais para priorizar atendimento ou medir satisfação, sem que a equipe precise treinar um modelo próprio.

Todos os três provedores oferecem essa funcionalidade em modelos **pré-treinados**, acessíveis por chamada de API: o desenvolvedor envia texto e recebe uma avaliação de sentimento, sem etapa de treinamento, rotulagem ou hospedagem de modelo.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação síncrona de documento único
AWS	Amazon Comprehend	DetectSentiment
Microsoft Azure	Azure Language in Foundry Tools (antes Azure AI Language / Text Analytics)	Análise de sentimento via REST API ou client library
Google Cloud	Cloud Natural Language API (v1)	analyzeSentiment

Cada provedor também oferece modos adicionais, que **não** entram na comparação por não serem equivalentes em carga: BatchDetectSentiment (até 25 documentos) e StartSentimentDetectionJob (assíncrono) na AWS; requisições assíncronas em lote na Azure; processamento de textos longos no Google.

3. Comparação técnica

As tabelas abaixo comparam entradas, saídas, formas de acesso, autenticação, limites e avisos oficiais dos três serviços. O capítulo completo — com a fonte oficial de cada afirmação e as pendências de verificação — está em [etapa1/nlp.md](#).

3.1 Funcionalidades, entradas e saídas

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Formato da saída	Uma classe entre <code>POSITIVE</code> , <code>NEGATIVE</code> , <code>NEUTRAL</code> e <code>MIXED</code> , mais <code>SentimentScore</code> com um score para cada uma das quatro classes	Rótulo <code>positive</code> , <code>neutral</code> , <code>negative</code> ou <code>mixed</code> — este último só em nível de documento ; três scores de confiança de 0 a 1 (positivo, neutro e negativo), que somam 1	Não retorna classe. Devolve <code>score</code> (de $-1,0$ a $+1,0$) e <code>magnitude</code> (intensidade acumulada, não normalizada)
Granularidade	Documento	Documento e sentença (ambos na mesma resposta)	Documento e sentença
Classe para texto ambíguo	<code>MIXED</code> é uma classe do próprio modelo , distinta de <code>NEUTRAL</code> , com score próprio em <code>SentimentScore</code>	<code>mixed</code> existe em nível de documento , mas é composto a partir das sentenças : sai quando há ao menos uma sentença positiva e ao menos uma negativa. Não tem score de confiança próprio	Não há classe; cabe ao desenvolvedor definir limiares
Codificação de entrada	UTF-8	Texto (string única por documento)	UTF-8
Tamanho máximo do documento	5 KB por documento na operação síncrona de sentimento	5.120 caracteres por documento (síncrono), medidos por <code>StringInfo.LengthInTextElements</code>	1.000.000 bytes de conteúdo; até 100.000 tokens por requisição

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Documentos por requisição	1 (DetectSentiment); até 25 em BatchDetectSentiment	10 documentos por requisição em análise de sentimento	1 documento por requisição
Tamanho máximo da requisição	—	1 MB	—

O contraste mais importante para quem integra: **a AWS e a Azure entregam uma decisão pronta (uma classe), enquanto o Google entrega apenas um número contínuo.** Usar o Google exige que a aplicação defina os limiares que separam positivo, neutro e negativo — uma decisão de produto que os outros dois já tomam pelo desenvolvedor. Além disso, `magnitude` (Google) e `SentimentScore` (AWS) e confiança (Azure) são grandezas diferentes e não podem ser comparadas entre si.

Como a Azure decide o rótulo do documento. A documentação oficial publica a regra, e ela **não** é "o maior dos três scores":

Sentenças do documento	Rótulo devolvido para o documento
Ao menos uma positiva, as demais neutras	<code>positive</code>
Ao menos uma negativa, as demais neutras	<code>negative</code>
Ao menos uma positiva e ao menos uma negativa	<code>mixed</code>
Todas neutras	<code>neutral</code>

São, portanto, **três scores de confiança e quatro rótulos possíveis** no nível do documento. Isso muda a leitura da comparação: **dois dos três provedores rotulam texto ambíguo** — o que difere é o caminho. Na AWS, `MIXED` é uma classe do próprio modelo, com score próprio, e pode sair de um documento de uma única frase. Na Azure, `mixed` é composto a partir dos rótulos das sentenças, o que exige sentenças de sinais opostos no mesmo documento e não vem acompanhado de score próprio. O Google não rotula.

3.2 Suporte a português

Provedor	Códigos aceitos	Total de idiomas na operação
Amazon Comprehend	pt (Português, sem distinção de variante)	12 idiomas, e o sentimento cobre todos eles
Azure Language	pt-BR (Português do Brasil) e pt-PT (Português de Portugal); pt também é aceito	94 códigos de idioma
Cloud Natural Language	pt (Português, sem distinção de variante)	16 idiomas na análise de sentimento

Diferença relevante para aplicações brasileiras: apenas a Azure distingue formalmente o português do Brasil do português de Portugal na análise de sentimento. AWS e Google tratam "português" como um único idioma. A documentação não afirma que essa distinção produza resultado melhor em textos brasileiros — isso seria uma conclusão experimental, fora do escopo desta etapa.

3.3 Formas de acesso, autenticação e configuração

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Acesso	API REST, AWS SDKs (Python/boto3, Java, .NET, Node.js, Ruby...), AWS CLI	REST API, client libraries (C#, Java, JavaScript, Python), contêiner Docker para execução local	REST (POST <code>.../v1/documents:analyzeSentiment</code>), gRPC, client libraries
Autenticação	Credenciais IAM (chave de acesso/secreto ou role), resolvidas pela cadeia padrão do SDK	Chave do recurso + endpoint próprios do recurso criado, ou Microsoft Entra ID	Conta de serviço com Application Default Credentials (<code>GOOGLE_APPLICATION_CREDENTIALS</code>) ou chave de API
Endpoint	Regional (<code>comprehend.us-east-1.amazonaws.com</code>)	Endpoint próprio do recurso, vinculado à região escolhida na criação	<code>language.googleapis.com</code> (global)

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Configuração mínima	Região + credenciais	Criar um recurso <i>Azure Language in Foundry Tools</i> , obter chave e endpoint	Projeto com a API habilitada + credenciais

A Azure é a única das três que oferece **execução em contêiner local** da análise de sentimento, o que importa em cenários com restrição de saída de dados. Em contrapartida, é a única que exige criar previamente um recurso e administrar um par chave/endpoint específico dele.

3.4 Limites operacionais e de taxa

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Limite de requisições	<i>Throttling</i> dinâmico: a AWS ajusta a vazão conforme a banda de processamento disponível, sem número fixo publicado para o modo síncrono	Depende do tier: S/Multi-service 1.000 req/s; S0/F0 100 req/s e 300 req/min	600 requisições/minuto e 800.000 requisições/dia
Regiões	13 regiões, incluindo US East (N. Virginia) e US East (Ohio); não há região no Brasil na lista publicada	Endpoint regional; East US disponível	API global
Previsibilidade de vazão	Baixa: não há cota publicada para planejar	Alta: cota explícita por tier	Alta: cota explícita

O *throttling* dinâmico da AWS é uma diferença prática relevante: não é possível dimensionar a aplicação a partir de um número publicado, e a própria documentação recomenda implementar limitação de taxa no cliente e ativar alertas de cobrança.

3.5 Situação do serviço (avisos oficiais)

Provedor	Aviso na documentação oficial
AWS	Nenhum aviso de descontinuação encontrado.

Provedor	Aviso na documentação oficial
Azure	" Sentiment analysis and opinion mining retire from Azure Language on March 31, 2029 ", com recomendação de migrar cargas existentes e direcionar novos projetos ao Microsoft Foundry.
Google	Nenhum aviso de descontinuação na página do <code>analyzeSentiment</code> . A única descontinuação oficial da API é a da versão <code>v1beta1</code> , encerrada em 27/12/2019 , que não atinge a <code>v1</code> em uso.

Este é um critério de decisão concreto: escolher a análise de sentimento da Azure hoje significa assumir uma migração antes de **31/03/2029**.

4. Exemplos de código

Os três exemplos executam a **mesma operação** sobre o **mesmo texto**, e estão em:

`exemplos/nlp/aws_comprehend.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
def detectar_sentimento(texto: str, idioma: str = IDIOMA) -> dict:
    """Envia um documento e devolve a resposta completa do DetectSentiment."""
    cliente = boto3.client("comprehend", region_name=REGIAO)
    return cliente.detect_sentiment(Text=texto, LanguageCode=idioma)
```

`exemplos/nlp/azure_language.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
# A API recebe uma LISTA de documentos, mesmo para um único texto.
resultados = cliente.analyze_sentiment(documents=[TEXT0], language=IDIOMA)
```

`exemplos/nlp/google_natural_language.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
documento = language_v1.Document(
    content=TEXT0,
    type_=language_v1.Document.Type.PLAIN_TEXT,
    language=IDIOMA,
)

resposta = cliente.analyze_sentiment(
    request={"document": documento, "encoding_type":
language_v1.EncodingType.UTF8}
)
```

Estado de validação: os três exemplos são **ilustrativos e não foram executados pelo grupo**. Foram adaptados da documentação oficial de cada provedor, conforme permitido pela seção 3 do enunciado ("Nesta etapa, os exemplos não precisam ter sido desenvolvidos ou executados pelo grupo"). Cada arquivo declara sua dependência, a fonte da adaptação e o mecanismo de autenticação. Nenhuma credencial está embutida no código: todos leem variáveis de ambiente.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Regra de contagem	Preço na primeira faixa
Amazon Comprehend	Unidade de 100 caracteres	<code>ceil(caracteres/100)</code> , com mínimo de 3 unidades (300 caracteres) por requisição	\$0,0001 por unidade (até 10M de unidades/mês)
Azure Language	Registro de texto de 1.000 caracteres	<code>ceil(caracteres/1000)</code> por documento	\$1,00 por 1.000 registros (até 0,5M de registros/mês)
Cloud Natural Language	Unidade de 1.000 caracteres Unicode	<code>ceil(caracteres/1000)</code> , com mínimo de 1 unidade por requisição	\$1,00 por 1.000 unidades (de 5 mil a 1M de unidades/mês)

Todos os preços acima são de **US East, em USD, consultados em 23/09/2026**, e estão em `custos/premissas.csv` com a URL da fonte. Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API* — ambas APIs públicas oficiais dos próprios provedores, usadas porque as páginas comerciais de preço entregam as tabelas por JavaScript.

A regra de contagem do Google foi confirmada pelo exemplo da própria página de preços: 800, 1.500 e 600 caracteres são cobrados como $1 + 2 + 1 = 4$ **unidades**, ou seja, arredondamento para cima com mínimo de uma unidade.

A diferença de unidade é o fator que mais afeta o custo comparado: **embora 100 caracteres correspondam a uma unidade, a AWS cobra o mínimo de três unidades por documento; a Azure e o Google cobram uma unidade inteira de 1.000 caracteres**. O efeito disso sobre o custo real é calculado na seção 6 deste capítulo, nos cinco comprimentos analisados.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

100.000 documentos por mês, submetidos um por chamada síncrona, em cinco comprimentos: **100, 500, 1.200, 4.000 e 4.100 caracteres**. A quantidade é hipotética e declarada como tal; o que importa é que **é idêntica nos três provedores**, como exige a seção 4 do enunciado. Os comprimentos existem para expor o efeito do tamanho da unidade de cobrança, e o de 4.100 entra especificamente para testar se o empate que aparece em 4.000 é um patamar ou uma coincidência.

Condições de entrada assumidas. Um documento por requisição, texto plano, sem *opinion mining* nem análise por aspecto, e **um único idioma declarado** (`pt-BR` na Azure, `pt` na AWS e no Google). O limite do Comprehend é de **5 KB, medido em bytes**, e não em caracteres: em UTF-8 cada caractere acentuado ocupa 2 bytes, de modo que 4.100 caracteres só cabem nos 5 KB enquanto no máximo cerca de 25% deles forem acentuados (em português corrente, com 4% a 6% de acentuados, o documento fica em torno de 4,2 KB). Textos fora dessa condição precisariam ser divididos, e a divisão mudaria a contagem de unidades. Os limites da Azure (5.120 caracteres) e do Google (1.000.000 de bytes) não são atingidos em nenhum dos comprimentos.

Fórmulas

```
AWS:      unidades = max(3, ceil(caracteres/100)) x 100.000 documentos
Azure:    registros = ceil(caracteres/1000) x 100.000 documentos
Google:   unidades = max(1, ceil(caracteres/1000)) x 100.000 documentos
```


O custo é progressivo por faixa: cada parcela do volume é cobrada ao preço da faixa em que cai — nunca o volume inteiro ao preço da última faixa.

Resultados (USD/mês, sem franquia)

Comprimento	Unidades cobradas AWS	AWS	Azure	Google
100 caracteres	300.000 (mínimo de 3/doc)	\$30,00	\$100,00	\$100,00
500 caracteres	500.000	\$50,00	\$100,00	\$100,00
1.200 caracteres	1.200.000	\$120,00	\$200,00	\$200,00
4.000 caracteres	4.000.000	\$400,00	\$400,00	\$400,00
4.100 caracteres	4.100.000	\$410,00	\$500,00	\$500,00

Análise de sentimento: custo de 100.000 documentos

Por comprimento do documento · AWS us-east-1 · Azure East US · Google global · USD · sem franquia · preços de 23/09/2026



O que os números mostram

O cenário revela um efeito que a tabela de preços isolada esconde: **para textos curtos, a granularidade da unidade importa mais que o preço unitário**. Um comentário de 100 caracteres consome 3 unidades de 100 caracteres na AWS, mas **uma unidade inteira de 1.000 caracteres** na Azure e no Google — pagando-se, nos dois casos, por 900 caracteres não enviados. O resultado é que a AWS cobra **30% do que cobram os concorrentes** nesse comprimento — uma redução de 70%, ou 3,3x mais barato.

A vantagem encolhe conforme o texto cresce e some perto de 4.000 caracteres — mas não só no ponto exato. Recalculando com as próprias funções do projeto para toda a vizinhança:

Comprimento	AWS	Azure	Google
3.900 caracteres	\$390,00	\$400,00	\$400,00
3.901 a 4.000 caracteres	\$400,00	\$400,00	\$400,00
4.001 caracteres	\$410,00	\$500,00	\$500,00
4.100 caracteres	\$410,00	\$500,00	\$500,00

O empate vale para toda uma janela de 100 caracteres — de 3.901 a 4.000 —, não apenas para 4.000 exato. A razão é aritmética: nesse trecho, `ceil(c/100)` (a regra da AWS) já chegou a 40 e só muda em 4.001, enquanto `ceil(c/1000)` (a regra de Azure e Google) permanece em 4 até 4.000 e só sobe em 4.001. As duas contagens colam nesse intervalo específico, não em um ponto isolado. O mesmo padrão se repete perto de cada múltiplo de 1.000 (por exemplo, 2.901 a 3.000, ou 1.901 a 2.000): é uma janela de 100 caracteres logo abaixo de cada múltiplo, não o múltiplo isolado.

Fora dessas janelas, a diferença volta — até cerca de 22% a mais na Azure e no Google na vizinhança de 4.000 caracteres. O que muda a partir daí é que a granularidade deixa de ser o único fator: passa a dividir espaço com as faixas de volume.

Isso tem consequência prática direta: **a escolha mais econômica depende do comprimento típico do texto da aplicação**. Para avaliações curtas de produto ou mensagens de chat, a diferença chega a 3,3 para 1; para documentos longos, cai para a casa de 0% a 22%, e só pode ser resolvida calculando com a distribuição real de comprimentos da aplicação.

Franquias

As três franquias existem, mas **não são a mesma coisa** e por isso não entram na comparação principal:

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	50.000 unidades/mês por API	Promocional: vale 12 meses a partir da primeira requisição	Sim, só nos 12 primeiros meses — abate a fatura da própria operação, na mesma conta e no mesmo tier
Azure	5.000 registros/mês	Tier F0 separado, compartilhado entre várias features do Azure Language	Não — é um recurso à parte, não um desconto no tier S usado no cenário
Google	5.000 unidades/mês	Faixa da própria tabela cobrada a \$0,00; permanente	Sim — é a primeira faixa da tabela que já está sendo aplicada

Regra adotada em todo o trabalho. A coluna `custo_usd_com_franquia` de `custos/resultados.csv` desconta **somente** as franquias que incidem sobre a operação comparada; a coluna `franquia_aplicada` registra a decisão linha por linha e `custos/franquias.csv` guarda a justificativa de cada caso. Abater o tier F0 da Azure de uma fatura do tier pago somaria duas coisas que a Microsoft cobra separadamente: o F0 é um **recurso à parte**, com cota e limites próprios, e não um desconto no recurso pago. Usá-lo exigiria dividir a carga entre dois recursos — uma hipótese de arquitetura que teria de ser definida e justificada, e que este cenário não adota.

Aplicada essa regra ao cenário de 100 caracteres: **\$25,00 na AWS** (e só durante os 12 primeiros meses), **\$100,00 na Azure** (sem abatimento) e **\$95,00 no Google** (permanente).

Leitura honesta da coluna do Google. Como a faixa de 0,00 USD é parte permanente da tabela on-demand, **a cobrança habitual do Google é \$95,00, não \$100,00**. O valor sem franquia é uma simulação criada para manter a comparação simétrica com AWS e Azure, e não a fatura esperada. Nas tabelas deste capítulo os dois números aparecem lado a lado justamente por isso. Como duas das três franquias são temporárias ou inaplicáveis, **a comparação principal usa os preços sem franquia**, por ser a única base que significa a mesma coisa nos três — um **cenário comparativo sem franquias**, não a fatura esperada de nenhum dos três (a do Google, em especial, costuma ser menor por causa da faixa permanente).

7. Síntese: vantagens, restrições e adequação por cenário

As três diferenças que mais pesam

1. O Google não entrega uma decisão, entrega um número. AWS e Azure devolvem uma classe pronta (`POSITIVE / positive`); o Google devolve `score` e `magnitude` e deixa para a aplicação definir onde ficam as fronteiras entre positivo, neutro e negativo. Isso não é detalhe de formato: é trabalho de produto transferido para quem integra, e uma decisão que precisa ser justificada e congelada antes de qualquer avaliação. Em compensação, dá controle a quem quer calibrar o limiar ao próprio domínio.

2. AWS e Azure rotulam texto ambíguo; o Google não — e as duas chegam lá por caminhos diferentes. Na AWS, `MIXED` é uma classe do modelo, com score próprio em `SentimentScore`, e pode sair de um documento de uma única frase. Na Azure, `mixed` é um rótulo **de documento**, composto pela regra oficial: ao menos uma sentença positiva e ao menos uma negativa. A consequência prática para quem integra é essa: a AWS distingue "opinião dividida" de "sem opinião" já em textos de uma frase; a Azure só produz esse rótulo quando o documento tem sentenças de sinais opostos, e sem score próprio para ele. No Google não há classe alguma — quem integra define os limiares.

3. Só a Azure distingue português do Brasil. `pt-BR` e `pt-PT` são códigos separados na Azure, contra um `pt` genérico na AWS e no Google. Para um produto brasileiro isso é atraente — mas **a documentação não promete resultado melhor**, e afirmar que produz seria extrapolar. É exatamente o tipo de hipótese que a Etapa 2 pode testar.

Custo: a granularidade da unidade domina em textos curtos

O cenário de 100.000 documentos mostrou que **a AWS cobra 30% do que cobram os concorrentes em textos de 100 caracteres** (\$30,00 contra \$100,00 — redução de 70%), porque cobra em unidades de 100 caracteres enquanto Azure e Google cobram uma unidade inteira de 1.000. A vantagem cai a zero na janela de 3.901 a 4.000 caracteres, onde os três empatam em \$400,00, mas volta em 4.001 (\$410,00 contra \$500,00): o empate vale para essa janela específica de 100 caracteres antes de cada múltiplo de 1.000, e não para documentos longos em geral.

Ou seja: **não existe "o mais barato" nesta categoria — existe o mais barato para o seu comprimento de texto.**

O risco que nenhuma tabela de preço mostra

A análise de sentimento da Azure tem **encerramento anunciado para 31/03/2029**, com migração recomendada para o Microsoft Foundry. Nenhum concorrente comparado tem aviso equivalente. Para um sistema que se espera manter por anos, isso é um custo futuro de migração que não aparece em nenhum cenário de preço.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Alto volume de textos curtos (avaliações, chat, comentários)	Amazon Comprehend	Unidade de 100 caracteres reduz o custo em 70% no cenário de 100 caracteres; MIXED sai com score próprio mesmo em textos de uma única frase
Necessidade de sentimento por sentença junto com o do documento	Azure Language	Entrega os dois níveis na mesma resposta
Restrição de saída de dados do ambiente próprio	Azure Language	Único dos três com contêiner Docker para execução local
Aplicação que quer calibrar o limiar ao próprio domínio	Cloud Natural Language	O score contínuo é matéria-prima, não uma decisão já tomada
Sistema com horizonte longo de manutenção	AWS ou Google	A oferta da Azure tem encerramento datado
Documentos longos (acima de ~4.000 caracteres)	Calcular com o comprimento real	O empate só vale na janela de 100 caracteres logo abaixo de cada múltiplo de 1.000 (ex.: 3.901–4.000); fora dela a AWS continua até ~22% mais barata

O que esta etapa não responde: qual dos três classifica melhor sentimento em português. Isso exige execução, gabarito e medição — é o objeto da Etapa 2.

4. Visão computacional: detecção de rótulos em imagem

- **Operação comparada:** detecção de rótulos (labels/tags) do conteúdo da mesma imagem, sem localização
- **Modo de chamada:** síncrono, uma imagem por chamada
- **Data da consulta às fontes:** 23/09/2026
- **Região de referência:** US East (`us-east-1` / `East US` / global no caso do Google)

1. Objetivo da categoria e caso de uso

Detecção de rótulos responde à pergunta "o que aparece nesta imagem?", devolvendo termos como *pessoa*, *carro* ou *praia* com um grau de confiança. O caso de uso típico é indexar e tornar pesquisável um acervo de imagens enviadas por usuários, alimentar filtros de catálogo ou fazer uma triagem inicial de conteúdo antes de revisão humana.

Escolheu-se a detecção de rótulos — e não detecção de objetos com caixas delimitadoras — porque é a operação com equivalente direto nos três provedores e a que produz saída mais comparável.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação comparada
AWS	Amazon Rekognition	<code>DetectLabels</code> , feature <code>GENERAL_LABELS</code>
Microsoft Azure	Azure Vision in Foundry Tools — Image Analysis	<i>Tag visual features</i> (Tags), via <code>Analyze Image</code>
Google Cloud	Cloud Vision API	Feature <code>LABEL_DETECTION</code> , via <code>images:annotate</code>

3. Comparação técnica

As tabelas abaixo comparam entradas, saídas, formas de acesso, autenticação, limites e avisos oficiais dos três serviços. O capítulo completo — com a fonte oficial de cada afirmação e as pendências de verificação — está em `etapal/visao.md`.

3.1 Entradas: formatos e limites

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Formatos aceitos	Apenas PNG e JPEG	v4.0: JPEG, PNG, GIF, BMP, WEBP, ICO, TIFF, MPO · v3.2: JPEG, PNG, GIF, BMP	Em <code>images:annotate</code> (o endpoint comparado): JPEG, PNG8, PNG24, GIF, GIF animado (só o primeiro quadro), BMP, WEBP, RAW, ICO. PDF e TIFF existem, mas por outro endpoint — ver nota abaixo

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Tamanho máximo	15 MB como objeto no Amazon S3; 5 MB quando enviada como bytes na requisição	v4.0: menos de 20 MB · v3.2: menos de 4 MB	20 MB por imagem; requisição JSON limitada a 10 MB
Dimensões	Mínimo 80×80 px; máximo 10.000 px de largura e altura para DetectLabels	Entre 50×50 e 16.000×16.000 px	Resolução recomendada de 640×480 px para LABEL_DETECTION
Origem da imagem	Objeto no Amazon S3 ou bytes na requisição	Bytes na requisição ou URL da imagem	Arquivo local em base64, URI do Cloud Storage (gs://) ou URL remota

O Cloud Vision aceita a maior variedade de formatos e o Rekognition a menor (só PNG e JPEG). Para um pipeline que recebe upload livre de usuários, isso significa que **a AWS exige uma etapa de conversão** que os outros dois dispensam em vários casos.

PDF e TIFF no Cloud Vision são outro caminho, não o mesmo. A lista oficial de formatos suportados inclui PDF e TIFF, mas eles **não** são aceitos pelo `images:annotate` usado nesta comparação: exigem o endpoint `files:annotate`, que trata o arquivo como documento de várias páginas. O `LABEL_DETECTION` está entre as features suportadas nesse endpoint, de modo que a capacidade existe — porém com fluxo, limites e condições próprios (entre eles, chaves de API não são aceitas em `files:annotate`). Misturar as duas coisas na mesma linha da tabela superestimaria a compatibilidade do endpoint comparado, e por isso os dois caminhos ficam separados aqui.

3.2 Saídas

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Campos por rótulo	<code>Name</code> , <code>Confidence</code> , <code>Parents</code> (hierarquia), <code>Aliases</code> (sinônimos), <code>Categories</code> , <code>Instances</code> (com <code>BoundingBox</code> quando aplicável)	Tags com nome e confiança	<code>mid</code> (identificador no Google Knowledge Graph), <code>description</code> , <code>score</code> , <code>topicality</code>
Escala da confiança	0 a 100	0 a 1	0 a 1

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Estrutura semântica	Hierarquia explícita: um rótulo traz seus rótulos-pai, apelidos e categoria	Lista plana de tags	<code>mid</code> permite ligar o rótulo a uma entidade do Knowledge Graph
Controle de quantidade	<code>MaxLabels</code> e <code>MinConfidence</code>	Parâmetros da chamada <code>Analyze</code>	<code>maxResults</code> (padrão 10 se omitido)
Filtros	<code>LabelInclusionFilters</code> , <code>LabelExclusionFilters</code> , <code>LabelCategoryInclusionFilters</code> , <code>LabelCategoryExclusionFilters</code>	—	—
Versão do modelo na resposta	<code>LabelModelVersion</code>	—	—

Três diferenças importam na integração:

1. **A escala de confiança não é a mesma.** A AWS usa 0–100 e os outros dois 0–1. Qualquer comparação ou limiar compartilhado exige normalização explícita.
2. **A AWS é a única que devolve taxonomia.** `Parents`, `Aliases` e `Categories` permitem agrupar rótulos sem manter um dicionário próprio, e os filtros de inclusão/exclusão permitem restringir a resposta no servidor. Nos outros dois isso fica por conta da aplicação.
3. **O Google é o único que devolve identificador estável** (`mid`) ligado ao Knowledge Graph, útil para associar rótulos a uma base de conhecimento em vez de comparar strings.

Os vocabulários de rótulos **não são compatíveis entre provedores**: nomes, granularidade e idioma dos termos diferem, e não há tabela oficial de equivalência. Comparar "quantos rótulos cada um acertou" exigiria um gabarito próprio — trabalho de avaliação prática, não desta etapa.

3.3 Formas de acesso, autenticação e configuração

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Acesso	API REST, AWS SDKs (Python, Java, .NET, Node.js, Ruby), AWS CLI	REST API (<code>aka.ms/vision-4-0-ref</code>) e client library SDK	REST (<code>POST https://vision.googleapis.com/v1/images:annotate</code>), gRPC, client libraries, <code>gcloud ml vision detect-labels</code>
Autenticação	Credenciais IAM; para ler imagem do S3, também permissão de leitura no bucket	Chave + endpoint do recurso <i>Azure Vision in Foundry Tools</i>	Application Default Credentials ou chave de API
Configuração mínima	Região + credenciais (+ bucket S3, se usar essa origem)	Criar o recurso em região suportada (East US está na lista)	Projeto com a API habilitada

A Azure é a única das três com **restrição de região documentada para a própria funcionalidade**: a página oficial lista as regiões em que o Image Analysis existe, e recursos criados fora delas não atendem à operação. AWS e Google não impõem essa barreira para a operação comparada.

3.4 Limites operacionais e de taxa

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Limite de requisições	TPS por operação e por região, ajustável via AWS Service Quotas; erros <code>ProvisionedThroughputExceededException</code> e <code>ThrottlingException</code> são documentados como reentráveis	Conforme o tier do recurso	Cotas por projeto
Recomendação oficial	Suavizar picos de tráfego (fila), configurar <i>retries</i> com <i>backoff</i> exponencial e <i>jitter</i>	—	—
Processamento em massa	Image Bulk Analysis: lotes de até 10.000 imagens, manifesto de até 50 MB	—	—

3.5 Situação do serviço (avisos oficiais)

Provedor	Aviso na documentação oficial
AWS	Nenhum aviso de descontinuação para <code>DetectLabels</code> .
Azure	"The Image Analysis 4.0 service in Azure Vision in Foundry Tools is deprecated and will be retired on September 25, 2028" , com guia de migração indicado. Funcionalidades da versão 4.0 em preview já foram encerradas antes: Custom Image Classification, Custom Object Detection, Product Recognition e a API Segment / remoção de fundo foram desativadas em 31/03/2025 .
Google	Nenhum aviso de descontinuação para <code>LABEL_DETECTION</code> .

Esse é o segundo serviço da Azure comparado neste trabalho com encerramento anunciado — o primeiro foi a análise de sentimento (31/03/2029). O histórico de funcionalidades já retiradas em 2025 reforça que a cadência de mudança da oferta de visão da Azure é mais alta que a dos concorrentes, o que é um fator de risco de manutenção para quem integra hoje.

4. Exemplos de código

Os três exemplos executam a **mesma operação** sobre a **mesma imagem**:

`exemplos/visao/aws_rekognition.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
return cliente.detect_labels(
    Image={"Bytes": bytes_imagem},
    MaxLabels=MAX_LABELS,
    MinConfidence=MIN_CONFIANCA,
    Features=["GENERAL_LABELS"],
)
```

`exemplos/visao/azure_image_analysis.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
resultado = cliente.analyze(
    image_data=bytes_imagem,
    visual_features=[VisualFeatures.TAGS],
)
```

`exemplos/visao/google_vision.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
resposta = cliente.label_detection(image=imagem, max_results=MAX_RESULTADOS)
```

Estado de validação: exemplos **ilustrativos, não executados pelo grupo**, adaptados da documentação oficial de cada provedor, conforme a seção 3 do enunciado. Nenhuma credencial está embutida: todos leem variáveis de ambiente.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Preço na primeira faixa
Amazon Rekognition	Por imagem processada (APIs do Grupo 2, onde está o <code>DetectLabels</code>)	\$0,0010 por imagem (até 1M de imagens/mês)
Azure Image Analysis	Por transação , cobrada a cada 1.000 (feature <code>Tag</code> pertence ao Grupo 1)	\$1,00 por 1.000 transações (até 1M/mês)
Cloud Vision API	Por unidade , onde cada feature aplicada a uma imagem conta como uma unidade	\$1,50 por 1.000 unidades (de 1.000 a 5M/mês)

Preços de **US East, em USD, consultados em 23/09/2026**, registrados em `custos/premissas.csv` . Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API*.

A regra do Cloud Vision confirma-se na página oficial: aplicar duas features à mesma imagem gera duas unidades cobradas. Como o cenário usa **uma única feature por imagem** (`LABEL_DETECTION`), a carga permanece equivalente entre os três. O enquadramento da feature `Tag` no Grupo 1 da Azure — e não no Grupo 2, mais caro na primeira faixa — também foi confirmado na página de preços, que lista `Tag` entre as features do Grupo 1.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

100.000 imagens por mês, uma chamada por imagem, com **uma única feature de detecção de rótulos** em cada. A quantidade é hipotética e declarada como tal, e é idêntica nos três provedores.


Restringir a uma feature por imagem não é detalhe: é o que mantém a carga comparável, já que o Cloud Vision cobra por feature aplicada e não por imagem.

Fórmulas

```
AWS:      100.000 imagens (1 unidade por imagem)
Azure:    100.000 transações (1 imagem com 1 feature = 1 transação)
Google:   100.000 unidades (1 feature x 1 imagem = 1 unidade)
```

Resultados (USD/mês)

Provedor	Unidades cobradas	Sem franquia	Com a franquia aplicável
AWS — Rekognition	100.000 imagens	\$100,00	\$99,00 (só nos 12 primeiros meses)
Azure — Image Analysis (Grupo 1)	100.000 transações	\$100,00	\$100,00 (o F0 não abate o tier pago)
Google — Cloud Vision	100.000 unidades	\$150,00	\$148,50 (faixa permanente da tabela)



O que os números mostram

Nesta categoria a comparação é mais simples que em NLP, porque **a unidade de cobrança é praticamente a mesma nos três** — uma imagem analisada. Não há efeito de granularidade a explorar: o que se compara é o preço direto.

AWS e Azure ficam empatados em \$100,00 no volume do cenário, e o Google fica **50% acima**, em \$150,00. Vale registrar que essa ordem não é estável em qualquer volume: as faixas têm degraus diferentes (a Azure desce para \$0,65/mil a partir de 1M de transações, a AWS para \$0,0008/imagem a partir de 1M de imagens, e o Google só desce para \$1,00/mil depois de 5M de unidades), de modo que um volume muito maior muda as distâncias relativas.

Franquias

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	1.000 imagens/mês	Promocional, 12 meses a partir da criação da conta	Sim, só nos 12 primeiros meses
Azure	5.000 transações/mês (limite de 20/minuto)	Tier F0 separado	Não — recurso à parte, não desconto no tier pago. O que de fato impede o F0 de sustentar o cenário é a cota mensal de 5.000 transações (5% das 100.000 necessárias); o limite de 20/minuto, isoladamente, processaria as 100.000 imagens em cerca de 83 horas, o que caberia num mês — não é ele o fator restritivo
Google	1.000 unidades/mês	Primeira faixa da tabela, permanente	Sim

Como a faixa de 0,00 USD do Google é permanente, **a cobrança habitual dele é \$148,50, não \$150,00**; o valor sem franquia é uma simulação para manter a comparação simétrica com AWS e Azure.

Regra adotada em todo o trabalho. A coluna `custo_usd_com_franquia` de `custos/resultados.csv` desconta **somente** as franquias que incidem sobre a operação comparada; a coluna `franquia_aplicada` registra a decisão linha por linha e `custos/franquias.csv` guarda a justificativa de cada caso. Abater o tier F0 da Azure de uma fatura do tier pago somaria duas coisas que a Microsoft cobra separadamente: o F0 é um **recurso à parte**, com cota e limites próprios, e não um desconto no recurso pago. Usá-lo exigiria dividir a carga entre dois recursos — uma hipótese de arquitetura que teria de ser definida e justificada, e que este cenário não adota.

7. Síntese: vantagens, restrições e adequação por cenário

O que separa as três ofertas

A AWS é a única que entrega taxonomia junto com o rótulo. `Parents`, `Aliases` e `Categories` permitem agrupar e filtrar rótulos sem manter um dicionário próprio, e os filtros de inclusão/exclusão rodam no servidor. Nos outros dois, essa camada fica por conta da aplicação.

O Google é o mais permissivo na entrada e o único com identificador estável. No endpoint comparado aceita RAW, WEBP, GIF, BMP e ICO além de PNG e JPEG — contra **apenas PNG e JPEG na AWS** —, o que elimina uma etapa de conversão em pipelines que recebem upload livre; PDF e TIFF também são suportados, mas pelo endpoint `files:annotate`, com fluxo próprio. E o campo `mid` liga cada rótulo a uma entidade do Knowledge Graph, em vez de obrigar comparação por string.

A Azure é a que exige mais atenção à região e ao calendário. É a única com lista fechada de regiões para a própria funcionalidade, e a única com **encerramento anunciado: o Image Analysis 4.0 sai de operação em 25/09/2028**. O histórico reforça o ponto: quatro funcionalidades em preview já foram desativadas em 31/03/2025.

Um detalhe que atravessa a integração dos três: **a escala de confiança não é a mesma** (0-100 na AWS, 0-1 nos outros dois), e os vocabulários de rótulos não têm equivalência oficial. Trocar de provedor aqui não é trocar de endpoint — é recalibrar limiares e remapear termos.

Custo: a categoria mais previsível das três

Como a unidade de cobrança é essencialmente a mesma nos três — uma imagem analisada — não há efeito de granularidade a explorar. No cenário de 100.000 imagens, **AWS e Azure empatam em \$100,00 e o Google fica 50% acima, em \$150,00**.

Essa ordem não vale para qualquer volume: os degraus de faixa são diferentes, e o Google só reduz o preço depois de 5 milhões de unidades, enquanto AWS e Azure já reduzem a partir de 1 milhão.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Pipeline com formatos heterogêneos de upload	Cloud Vision	Aceita RAW, WEBP, GIF, BMP e ICO no mesmo endpoint, e PDF/TIFF por <code>files:annotate</code> ; a AWS exigiria conversão para PNG/JPEG
Necessidade de agrupar rótulos por categoria ou hierarquia	Amazon Rekognition	Único que devolve <code>Parents</code> , <code>Aliases</code> e <code>Categories</code>
Integração com base de conhecimento	Cloud Vision	O <code>mid</code> dá identificador estável em vez de string
Sensibilidade a custo no volume analisado	AWS ou Azure	\$100,00 contra \$150,00 do Google em 100 mil imagens
Volume muito alto (acima de 1 milhão/mês)	Recalcular	Os degraus de faixa diferem e mudam a ordem
Sistema com horizonte longo de manutenção	AWS ou Google	O Image Analysis 4.0 da Azure encerra em 25/09/2028

O que esta etapa não responde: qual serviço produz rótulos mais corretos ou mais úteis. Sem gabarito e sem execução, isso não é afirmável.

5. Fala para texto: transcrição de áudio

- **Operação comparada:** transcrição assíncrona (em lote) do mesmo arquivo de áudio em português do Brasil
- **Modo de chamada:** assíncrono / lote — único modo oferecido pelos três para arquivos longos
- **Data da consulta às fontes:** 23/09/2026
- **Região de referência:** `us-east-1` (N. Virginia) na AWS e `East US` na Azure; no Google, `us-central1` (**Iowa**) — a tabela da Cloud Speech-to-Text V2 é regional e `us-central1` **não** é uma região US East. A diferença está declarada como limitação em vez de ser tratada como equivalência

1. Objetivo da categoria e caso de uso

Conversão de fala em texto transforma áudio gravado em transcrição pesquisável. O caso de uso típico é processar gravações de atendimento, reuniões ou conteúdo audiovisual para gerar legendas, permitir busca textual ou alimentar análises posteriores — inclusive análise de sentimento, o que liga esta categoria à primeira.

Por que o modo em lote e não o tempo real: transcrição em tempo real e em lote têm condições de uso, requisitos de formato e preços distintos. Comparar uma com a outra produziria números sem sentido. Os três provedores oferecem o modo em lote para arquivos armazenados, e é sobre ele que a comparação é feita.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação em lote	Operação em tempo real (fora da comparação)
AWS	Amazon Transcribe	<code>StartTranscriptionJob</code>	<code>StartStreamTranscription</code>
Microsoft Azure	Azure Speech in Foundry Tools	<code>Transcription_Create</code> (Speech to text REST API)	Reconhecimento em tempo real
Google Cloud	Cloud Speech-to-Text V2	<code>BatchRecognize</code>	<code>StreamingRecognize</code> ; <code>Recognize</code> para áudio < 60 s

3. Comparação técnica

As tabelas abaixo comparam entradas, saídas, formas de acesso, autenticação, limites e avisos oficiais dos três serviços. O capítulo completo — com a fonte oficial de cada afirmação e as pendências de verificação — está em `etapa1/fala.md`.

3.1 Entradas: formatos e origem do áudio

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Formatos em lote	AMR, FLAC, M4A, MP3, MP4, Ogg, WebM, WAV	WAV, MP3, OPUS/OGG, FLAC, WMA, AAC, ALAW em WAV, MULAW em WAV, AMR, WebM, SPEEX	Formatos de áudio suportados pela API v2
Formatos recomendados	FLAC ou WAV com PCM 16 bits	Formatos sem perda: WAV (PCM) e FLAC	—
Origem do arquivo	Obrigatoriamente um bucket do Amazon S3	URI público, URI com SAS, ou contêiner do Azure Blob Storage via <i>trusted Azure services</i> (identidade gerenciada)	Cloud Storage (gs://) para BatchRecogniz e
Canais de áudio	Mono e estéreo; mais de dois canais não é suportado	—	—
Taxa de amostragem	Opcional no lote; 8.000 Hz típico em telefonia e de 16.000 a 48.000 Hz em alta fidelidade	—	—

A Azure aceita a lista mais ampla de formatos e é a única das três que permite **URI público** como origem, dispensando armazenamento no próprio provedor. A AWS é a mais restritiva nesse ponto: o arquivo precisa estar no S3, o que acrescenta um passo de upload e uma configuração de permissão ao fluxo.

3.2 Saídas

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Formato	JSON	JSON	JSON

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Conteúdo mínimo	Transcrição em bloco (<code>transcripts</code>), detalhamento por palavra e pontuação (<code>items</code>) com tempo de início, fim e confiança, e segmentos de áudio (<code>audio_segments</code>)	Transcrição com metadados da execução	Transcrição com alternativas e confiança
Onde o resultado fica	Bucket S3 do cliente ou bucket gerenciado pelo serviço, com URI temporária válida por 15 minutos ; no bucket padrão, o resultado é apagado quando o job expira, em 90 dias	Contêiner de armazenamento, recuperado de forma assíncrona	Cloud Storage ou resposta da operação
Recursos adicionais	Diarização (separação de locutores), identificação de canal	Diarização (<code>diarizationEnabled</code> para dois locutores; <code>diarization</code> com <code>minCount</code> / <code>maxCount</code> para três ou mais, máximo abaixo de 36), identificação de idioma (<code>languageIdentification</code>), timestamps por palavra, modo de pontuação e filtro de profanidade	Diarização disponível no modelo <code>chirp_3</code>

O detalhe de retenção da AWS é operacionalmente relevante: quem usa o bucket padrão precisa baixar a transcrição antes de 90 dias, e a URI temporária expira em 15 minutos — se expirar, é preciso uma nova chamada `GetTranscriptionJob`.

3.3 Suporte ao português do Brasil

Provedor	Código	Cobertura
Amazon Transcribe	<code>pt-BR</code> (Português, Brasileiro) e <code>pt-PT</code> (Português)	<code>pt-BR</code> em lote e streaming; suporta transcrição de números, acrônimos, <i>redaction</i> e Call Analytics pós-chamada e em tempo real

Provedor	Código	Cobertura
Azure Speech	pt-BR (Portuguese, Brazil)	Suportado, inclusive com <i>fast transcription</i>
Cloud Speech-to-Text V2	pt-BR (Portuguese, Brazil)	Disponível nos modelos <code>chirp_3</code> , <code>long</code> , <code>short</code> , <code>telephony</code> e <code>telephony_short</code> ; O <code>chirp_3</code> acrescenta diarização

Diferença em relação à categoria de NLP: aqui os três provedores distinguem formalmente o português do Brasil. Na análise de sentimento, apenas a Azure faz essa distinção. Isso mostra que o suporte a variantes regionais não é uniforme nem dentro do mesmo provedor.

Escolha do modelo: Google e Azure expõem, a AWS não. O Google publica modelos nomeados e otimizados por tipo de áudio (`telephony`, `long`, `short`, `chirp_3`) e o desenvolvedor escolhe um deles no campo `model` da configuração. A Azure também aceita um campo `model` na criação da transcrição em lote, mas o que ele recebe é a **URI de um modelo**: um modelo base específico, um modelo de *custom speech* treinado pelo grupo, ou o **Whisper** da OpenAI hospedado no serviço; omitido o campo, usa-se o modelo base padrão do locale. São duas liberdades diferentes — o Google deixa escolher entre perfis prontos de áudio, a Azure deixa apontar para outro modelo, inclusive treinado. A AWS não expõe essa escolha na transcrição em lote padrão.

Uma ressalva documentada na Azure: identificação de idioma e modelo customizado **não se combinam** no lote — pedindo os dois, o serviço cai para os modelos base dos idiomas candidatos.

3.4 Formas de acesso, autenticação e configuração

Aspecto	Amazon Transcribe	Azure Speech	Cloud Speech-to-Text V2
Acesso	API REST, AWS CLI e SDKs (.NET, C++, Go, Java V2, JavaScript, PHP V3, Python/boto3, Ruby V3, Rust)	Speech to text REST API e Speech CLI	REST, gRPC e client libraries
Autenticação	Credenciais IAM, com permissão de leitura no bucket de origem e de escrita no de destino	Chave do recurso; para Blob Storage protegido, identidade gerenciada atribuída pelo sistema com papel <i>Storage Blob Data Reader</i>	Application Default Credentials
Fluxo	Inicia o job, consulta com <code>GetTranscriptionJob</code> , lê o resultado no S3	Três passos: localizar áudio → criar transcrição → obter resultados	Inicia a operação de longa duração e consulta até concluir

A Azure tem a configuração de segurança mais elaborada das três para o caso de armazenamento privado — exige habilitar identidade gerenciada no recurso de Speech e conceder papel específico na conta de armazenamento. É mais trabalho inicial, mas permite bloquear completamente o acesso externo ao armazenamento, algo que a documentação descreve passo a passo.

3.5 Latência de processamento e limites operacionais

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Agendamento	Fila de jobs opcional quando não é necessário processar tudo simultaneamente	Best-effort: em horário de pico, pode levar até 30 minutos para iniciar e até 24 horas para concluir	Operação de longa duração
Latência publicada	—	Percentil 90 abaixo de 6 horas , com fórmula de latência normalizada publicada ($\text{ProcessDuration} - \text{AudioLength}/5$, com o serviço processando a cerca de 5× o tempo real)	—
Recomendações de uso	—	Enviar cerca de 1.000 arquivos por requisição ; distribuir envios ao longo de horas; consultar status no máximo uma vez por minuto , sendo suficiente a cada 10 minutos	—
Limites de entrada publicados	Não localizados: a página de cotas não estava acessível na consulta	1 GB por arquivo de áudio; 1.000 arquivos por requisição de transcrição; 10.000 blobs por contêiner; 240 min por arquivo quando a diarização está ativada	Não localizados nas páginas consultadas para o BatchRecognize
Cota de requisições	Não localizada	600 requisições/minuto , compartilhadas com a <i>fast transcription</i> ; ajustável no tier S0 e indisponível no F0	Cotas por projeto

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Retenção do resultado	Bucket padrão: apagado quando o job expira, em 90 dias	timeToLiveHours obrigatório, de 6 horas a 31 dias	Cloud Storage ou resposta da operação

A Azure é a única das três que publica expectativa de latência e um método de cálculo para ela. Isso é transparência útil, mas também revela que o modo em lote da Azure **não é adequado a fluxos sensíveis a tempo**: a própria documentação admite picos de até 24 horas. Esse número descreve fila de processamento e não qualidade do reconhecimento.

3.6 Situação do serviço (avisos oficiais)

Nenhum dos três serviços desta categoria apresenta aviso de descontinuação nas páginas consultadas. É a única das três categorias deste trabalho em que isso ocorre — nas outras duas, a oferta da Azure tem encerramento anunciado.

4. Exemplos de código

Os três exemplos submetem o **mesmo áudio à mesma operação em lote**, com idioma `pt-BR`:

`exemplos/fala/aws_transcribe.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
cliente.start_transcription_job(
    TranscriptionJobName=nome_job,
    Media={"MediaFileUri": URI_AUDIO},
    MediaFormat="flac",
    LanguageCode=IDIOMA,
)
```

`exemplos/fala/azure_speech.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da adaptação:

```
corpo = {
    "contentUrls": [URL_AUDIO],
    "locale": IDIOMA,
    "displayName": "transcricao-exemplo-etapa1",
    "properties": {"wordLevelTimestampsEnabled": True},
}
resposta = requests.post(BASE, headers=CABECALHOS, json=corpo, timeout=30)
```

`exemplos/fala/google_speech_to_text.py` — trecho essencial. O arquivo completo, no link, traz a autenticação por variável de ambiente, o tratamento de erro, os limites do serviço e a fonte da

adaptação:

```
requisicao = cloud_speech.BatchRecognizeRequest(  
    recognizer=reconhecedor,  
    config=config,  
    files=[cloud_speech.BatchRecognizeFileMetadata(uri=URI_AUDIO)],  
    recognition_output_config=cloud_speech.RecognitionOutputConfig(  
        inline_response_config=cloud_speech.InlineOutputConfig(),  
    ),  
)  
  
operacao = cliente.batch_recognize(request=requisicao)
```

Estado de validação: exemplos **ilustrativos, não executados pelo grupo**, adaptados da documentação oficial, conforme a seção 3 do enunciado. Por serem operações assíncronas, cada exemplo mostra os três momentos do fluxo: envio, acompanhamento e obtenção do resultado. Nenhuma credencial está embutida.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Preço	Equivalente por minuto
Amazon Transcribe	Segundo de áudio , em incrementos de 1 segundo e sem mínimo	\$0,0001 por segundo, preço único sem faixas	\$0,006
Azure Speech (lote)	Hora de áudio	\$0,18 por hora	\$0,003
Cloud Speech-to-Text V2 (padrão)	Áudio processado, em incrementos de 1 segundo	\$0,016 por minuto (até 500 mil min/mês)	\$0,016
Cloud Speech-to-Text V2 (<i>dynamic batch</i>)	Áudio processado, em incrementos de 1 segundo	\$0,003 por minuto, preço único	\$0,003

Preços de **US East, em USD, consultados em 23/09/2026**, registrados em `custos/premissas.csv`. Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API*.

A granularidade do arredondamento é favorável em todos os três: AWS e Google cobram em incrementos de 1 segundo, e a AWS declara explicitamente não haver cobrança mínima. Ou seja, um áudio de 20 segundos não é cobrado como um minuto inteiro — o que era o risco desta categoria.

O Google tem dois preços para lote, e a diferença é de mais de 5x. O modo padrão custa \$0,016/min; o *dynamic batch*, descrito na documentação como processamento "com menor nível de urgência", custa \$0,003/min. Isso importa na comparação: o lote da Azure também é declaradamente

best-effort, com fila que pode chegar a 24 horas. **O par realmente comparável em urgência é Azure em lote x Google em dynamic batch** — e os dois custam exatamente o mesmo, \$0,003/min.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

10.000 minutos de áudio por mês (cerca de 167 horas) em português do Brasil, transcritos em lote. A quantidade é hipotética e declarada como tal, e é idêntica nos três provedores.

Condições de entrada assumidas, porque os três cobram por tempo de áudio e não por arquivo:

Premissa	Valor adotado	Por que importa
Canais	1 (mono)	Na AWS, até dois canais são cobrados pela duração total do áudio , sem dobrar o preço — a página de preços é explícita: "for a two-channel conversation, you only pay for the total audio duration". A diarização da Azure exige mono; na Azure, os canais processados são declarados em <code>properties.channels</code> , e o comportamento de cobrança por canal não foi verificado nas fontes consultadas. O cenário fixa um canal para manter a equivalência entre os três, não porque dois custassem mais na AWS
Idioma	pt-BR declarado , sem identificação automática de idioma	Identificação de idioma é recurso adicional nos três e, segundo a documentação da Azure, aumenta a latência do lote. A tabela da Azure ainda traz um medidor separado de <i>Speech to Text Enhanced Feature Audio</i> (\$0,30/h), fora do escopo deste cenário — quais recursos caem nele não foi verificado e não é afirmado aqui
Recursos adicionais	Nenhum — sem <i>redaction</i> , sem Call Analytics, sem vocabulário customizado além do padrão	Na AWS , diarização, vocabulário customizado, filtragem de vocabulário e identificação de idioma estão incluídos no preço padrão — a página de preços lista essas features como parte do que "this pricing includes". Nem todo recurso adicional é cobrado à parte nos três; isso não foi verificado para Azure e Google e não é afirmado aqui

Premissa	Valor adotado	Por que importa
Distribuição dos arquivos	Irrelevante para o custo, desde que nenhum arquivo estoure os limites (1 GB e, na Azure com diarização, 240 min)	Os três cobram por duração total, em incrementos de 1 s (AWS e Google) ou por hora (Azure); 10.000 minutos custam o mesmo em 100 arquivos de 100 min ou em 1.000 de 10 min
Custos excluídos	Armazenamento (S3, Blob Storage, Cloud Storage), transferência de dados, requisições de listagem e qualquer processamento posterior	O cenário compara apenas o preço da transcrição. A AWS obriga o áudio a estar no S3, o que acrescenta um custo de armazenamento que os outros dois podem dispensar (URI público na Azure) — esse custo não está nos \$60,00

Fórmulas


AWS: $10.000 \text{ min} \times 60 = 600.000 \text{ segundos} \times \$0,0001/\text{s}$
 Azure: $10.000 \text{ min} / 60 = 166,667 \text{ horas} \times \$0,18/\text{h}$
 Google: $10.000 \text{ min} \times \$0,016/\text{min}$ (padrão)
 $10.000 \text{ min} \times \$0,003/\text{min}$ (dynamic batch)

Resultados (USD/mês, sem franquia)

Provedor e modo	Unidades cobradas	Custo	Urgência declarada
Azure — Speech to text Batch (S1)	166,67 horas	\$30,00	<i>Best-effort</i> : até 24 h em pico
Google — dynamic batch	10.000 minutos	\$30,00	Menor urgência
AWS — Transcribe em lote	600.000 segundos	\$60,00	Fila opcional
Google — BatchRecognize padrão	10.000 minutos	\$160,00	Prioridade padrão

Transcrição em lote: custo de 10.000 minutos de áudio

pt-BR · AWS us-east-1 · Azure East US · Google us-central1 · USD · sem franquia · preços de 23/09/2026



O que os números mostram

Esta é a categoria com a **maior dispersão de preço das três**: do mais barato ao mais caro há um fator de **5,3×**, contra 1,5× em visão computacional.

Mas o número isolado engana, e é por isso que a coluna de urgência está na tabela. **Comparar os \$30,00 da Azure com os \$160,00 do Google padrão é comparar serviços com compromissos de tempo diferentes.** Colocados na mesma condição — processamento de menor urgência — Azure e Google empatam exatamente em \$30,00, e a AWS fica no dobro, \$60,00, sem oferecer um modo mais barato de menor urgência.

A leitura correta é, portanto:

- **Se a aplicação tolera fila longa** (transcrição noturna de gravações, processamento de acervo): Azure e Google *dynamic batch* empatam em \$30,00.
- **Se a aplicação não quer depender de uma janela declaradamente de baixa urgência**: AWS por \$60,00 e Google padrão por \$160,00.

Uma ressalva importante sobre prazo. Nenhum dos três publica prazo garantido de conclusão para o lote, e este trabalho não tem base para atribuir "previsibilidade" a nenhum deles. O que existe é assimetria de **informação** e de **oferta**: a Azure é a única que publica uma expectativa (p90 abaixo de 6 h, admitindo até 24 h em pico) e o Google é o único que separa a prioridade padrão do modo de menor urgência no próprio preço. A AWS não publica expectativa de prazo nem oferece modo mais barato — a fila de jobs é apenas uma opção de enfileiramento do cliente, e por si só não demonstra previsibilidade. Medir tempo real de conclusão é objeto da Etapa 2.

Este é o ponto do trabalho em que a análise econômica mais depende da análise técnica: sem a informação de fila da seção 3.5, o cenário produziria um ranking enganoso.

Franquias

Provedor	Franquia	Natureza	Aplicável a este cenário?
AWS	60 minutos/mês	Promocional, 12 meses	Sim, só nos 12 primeiros meses (\$59,64 em vez de \$60,00)
Azure	5 horas/mês	Tier F0; a página de preços declara a franquia para transcrição em tempo real	Não — ver abaixo
Google	—	Não localizada para a tabela Recognition da V2 na página consultada	Não — nada é descontado sem valor verificado

Por que a franquia da Azure não entra neste cenário. A tabela oficial de cotas do serviço registra, para *batch transcription*, "**Not available for F0**": a transcrição em lote simplesmente não existe no tier gratuito onde estão as 5 horas. Além disso, o medidor efetivamente cobrado no cenário é o **S1 Speech to Text Batch**, do tier pago. Descontar as 5 horas do F0 de uma fatura S1 misturaria dois tiers distintos, e por isso o custo da Azure permanece em **\$30,00** nas duas colunas de `custos/resultados.csv`.

Regra adotada em todo o trabalho. A coluna `custo_usd_com_franquia` de `custos/resultados.csv` desconta **somente** as franquias que incidem sobre a operação comparada; a coluna `franquia_aplicada` registra a decisão linha por linha e `custos/franquias.csv` guarda a justificativa de cada caso. Abater o tier F0 da Azure de uma fatura do tier pago somaria duas coisas que a Microsoft cobra separadamente: o F0 é um **recurso à parte**, com cota e limites próprios, e não um desconto no recurso pago. Usá-lo exigiria dividir a carga entre dois recursos — uma hipótese de arquitetura que teria de ser definida e justificada, e que este cenário não adota.

A franquia do Google **não foi localizada** para a V2 e por isso aparece como pendência, não como zero: a faixa de 60 minutos gratuitos que consta da página pertence às tabelas da API V1.

7. Síntese: vantagens, restrições e adequação por cenário

O que separa as três ofertas

A urgência é a variável escondida desta categoria. Os três chamam de "lote" coisas com compromissos de tempo diferentes: a Azure admite abertamente fila de até 24 horas em pico (com p90 abaixo de 6 h e uma fórmula publicada para estimar a latência), o Google separa o modo padrão do *dynamic batch* de menor urgência, e a AWS oferece fila apenas como opção. Qualquer comparação que ignore isso produz ranking errado.

A origem do áudio impõe arquitetura. A AWS **obriga** o arquivo a estar em um bucket S3. A Azure é a única que aceita **URI público**, dispensando armazenamento no provedor — e, no outro extremo, oferece o caminho mais elaborado de segurança, com identidade gerenciada e papel *Storage Blob Data Reader* para bloquear totalmente o acesso externo ao armazenamento.

Google e Azure expõem a escolha do modelo; a AWS não. No Google são perfis prontos por tipo de áudio (`chirp_3` , `long` , `short` , `telephony` , `telephony_short` , todos com `pt-BR` , e diarização no `chirp_3`). Na Azure, o campo `model` aponta para a URI de outro modelo — base, *custom speech* treinado pelo grupo ou Whisper —, o que é uma liberdade de natureza diferente: não escolher entre perfis, mas trocar o modelo. Na AWS a transcrição em lote padrão não oferece essa decisão.

Os três documentam diarização. A AWS a lista entre os recursos do lote, o Google a oferece no `chirp_3` e a Azure a configura por `diarizationEnabled` (dois locutores) ou `diarization` com `minCount` / `maxCount` (três ou mais, máximo abaixo de 36), com duas condições explícitas: canal mono e áudio de no máximo 240 minutos por arquivo.

Os três suportam `pt-BR` formalmente — diferente da categoria de NLP, onde só a Azure distingue a variante brasileira. E **nenhum dos três tem aviso de descontinuação**, o que faz desta a única categoria do trabalho sem risco de calendário.

Custo: maior dispersão das três categorias, mas só na aparência

Do mais barato ao mais caro há um fator de **5,3×** (\$30,00 contra \$160,00) — contra 1,5× em visão. Mas boa parte dessa distância desaparece quando se compara urgência equivalente:

- **Menor urgência:** Azure (\$30,00) e Google *dynamic batch* (\$30,00) empatam exatamente.
- **Prioridade padrão:** AWS (\$60,00) contra Google padrão (\$160,00).

A AWS ocupa uma posição intermediária peculiar: é o dobro do preço de menor urgência e **não oferece um modo mais barato** para quem tolera fila. Também não publica expectativa de prazo — nem a favor nem contra —, de modo que a comparação de tempo de conclusão entre os três fica em aberto nesta etapa.

Um alívio comum aos três: **o arredondamento é favorável**. AWS e Google cobram em incrementos de 1 segundo, e a AWS declara não haver cobrança mínima — o risco de um áudio de 20 segundos ser cobrado como um minuto inteiro não se concretizou em nenhum deles.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Processamento noturno ou de acervo , sem pressa	Azure ou Google dynamic batch	\$30,00 no cenário; empate exato
Não depender de uma janela declarada de baixa urgência	Amazon Transcribe (\$60,00) ou Google padrão (\$160,00)	Nenhum dos dois pede que se aceite fila de baixa prioridade para chegar ao preço — mas nenhum dos três publica prazo garantido de conclusão
Áudio já hospedado fora da nuvem do provedor	Azure	Única que aceita URI público como origem

Situação	Alternativa mais adequada	Por quê
Requisito de isolamento do armazenamento	Azure	Caminho documentado com identidade gerenciada e acesso externo bloqueado
Telefonia ou tipos específicos de áudio	Cloud Speech-to-Text V2	Tem perfil de modelo pronto para telefonia (telephony); a Azure também permite apontar para outro modelo via <code>model</code> , mas exige treinar ou hospedar esse modelo primeiro — o Google entrega o perfil pronto
Necessidade de diarização	Os três	AWS no lote, Google no <code>chirp_3</code> e Azure por <code>diarizationEnabled / diarization</code> — nesta última, com canal mono e no máximo 240 min por arquivo
Fluxo sensível a tempo	Nenhum dos modos em lote	Usar transcrição em tempo real, que tem preço e condições próprios

O que esta etapa não responde: qual serviço transcreve português do Brasil com menos erros. A taxa de erro exige execução e gabarito.

6. Síntese geral

As sínteses por categoria estão ao final de cada capítulo. Esta seção reúne o que atravessa as três.

6.1 Não há um vencedor, e o motivo é estrutural

Em nenhuma das três categorias um provedor domina em todos os critérios. Mais do que isso: **em duas das três, a ordem de preço depende de um parâmetro da própria aplicação**, e não do provedor.

Categoria	O parâmetro que decide	Efeito
NLP	Comprimento típico do texto	AWS cobra 30% dos concorrentes em textos de 100 caracteres; empata na janela de 3.901–4.000 caracteres, mas volta a ser mais barata a partir de 4.001 — o empate vale numa janela de 100 caracteres antes de cada múltiplo de 1.000, não num ponto isolado

Categoria	O parâmetro que decide	Efeito
Visão	Volume mensal	AWS e Azure empatam em 100 mil imagens; os degraus de faixa diferem acima de 1 milhão
Fala	Tolerância a fila de processamento	Azure e Google empatam em \$30,00 no modo de menor urgência; a AWS cobra \$60,00 sem exigir essa tolerância

Quem escolher um provedor a partir de uma tabela de preço isolada, sem fixar esses parâmetros, escolherá errado com frequência.

6.2 A unidade de cobrança pesa mais que o preço unitário

O achado mais transferível deste trabalho é que **a granularidade da unidade de cobrança pode importar mais do que o preço da unidade**.

Em análise de sentimento, Azure e Google cobram uma unidade inteira de 1.000 caracteres mesmo para um comentário de 100 caracteres — pagando-se por 900 caracteres nunca enviados. A AWS, cobrando em unidades de 100 caracteres, cobra 30% disso no mesmo cenário — uma redução de 70%. Os três têm preços unitários da mesma ordem de grandeza; o que separa é como contam.

Na transcrição de áudio, a mesma lógica trabalhou a favor de todos: os três cobram em incrementos de um segundo, e a AWS declara não haver cobrança mínima.

6.3 A Azure é a mais completa tecnicamente e a mais arriscada no calendário

A Azure aparece à frente em vários critérios técnicos: é a única com **94 idiomas** e distinção formal entre `pt-BR` e `pt-PT` em sentimento; a única com **contêiner Docker** para execução local; a única que aceita **URI público** como origem de áudio; a única que publica **expectativa de latência** do processamento em lote; e a que oferece o caminho mais elaborado de isolamento de armazenamento.

Em contrapartida, é a única dos três provedores com **encerramento anunciado em duas das três categorias comparadas**:

Serviço	Encerramento anunciado
Azure Language — análise de sentimento e opinion mining	31/03/2029
Azure Vision — Image Analysis 4.0	25/09/2028

Além disso, quatro funcionalidades do Image Analysis 4.0 em preview já foram desativadas em 31/03/2025. Nenhum serviço comparado da AWS ou do Google Cloud apresenta aviso equivalente nas páginas consultadas.

Esse é um custo que não aparece em cenário de preço nenhum: para um sistema com horizonte de manutenção de anos, escolher a Azure nessas duas categorias significa assumir uma migração com

data marcada.

6.4 O custo de troca é maior do que parece

Nenhuma das três categorias permite trocar de provedor apenas trocando o endpoint:

- **Sentimento:** a saída do Google é um número contínuo; a da AWS tem quatro classes, cada uma com score próprio; a da Azure tem quatro rótulos possíveis no documento mas só três scores, e `mixed` só aparece por composição das sentenças. Migrar exige redefinir a lógica de classificação, não só ler outro campo.
- **Visão:** as escalas de confiança diferem ($0-100 \times 0-1$) e os vocabulários de rótulos não têm tabela de equivalência oficial. Migrar exige recalibrar limiares e remapear termos.
- **Fala:** a origem do áudio é imposta de forma diferente (S3 obrigatório na AWS; URI público aceito na Azure; Cloud Storage no Google), o que atinge a arquitetura, não só o código de chamada.

6.5 As franquias gratuitas seguem regras diferentes de abatimento

As três nuvens anunciam "camada gratuita", mas cada uma abate o valor da fatura de um jeito diferente — em uma delas, a franquia às vezes nem se aplica à operação comparada:

Provedor	O que é	Entra no cenário?
AWS	Free Tier promocional, na mesma conta e no mesmo tier da operação	Sim, mas só nos 12 primeiros meses
Microsoft Azure	Tier F0 , um recurso separado do tier pago, com cota e limites próprios	Não — e na transcrição em lote o F0 nem oferece a operação
Google Cloud	Primeira faixa da própria tabela , cobrada a 0,00 USD	Sim, permanente

A consequência prática aparece no número: descontar as 5 horas gratuitas do F0 da Azure de uma fatura de transcrição em lote produziria \$29,10 em vez dos **\$30,00** corretos — um desconto que a Microsoft não concede, porque a operação não existe naquele tier. Por isso `custos/franquias.csv` registra, para cada franquia, se ela é aplicável ao cenário e por quê, e `custos/resultados.csv` carrega essa decisão na coluna `franquia_aplicada`.

Pela mesma razão, a comparação principal usa os preços **sem franquia**: é a única base que significa a mesma coisa nos três. Onde a franquia é permanente — Google em NLP e visão —, a cobrança habitual é a coluna com franquia, e isso está dito nos capítulos.

6.6 O que a documentação não permite concluir

A análise é **documental**. Ela não estabelece qual serviço classifica sentimento com mais acerto, qual rotula imagens de forma mais útil, ou qual transcreve português do Brasil com menos erros. Essas perguntas exigem execução, dados de teste, gabarito e medição — objeto da Etapa 2.

7. Limitações

Registradas para delimitar o alcance das conclusões:

- 1. Nenhum exemplo de código foi executado.** A seção 3 do enunciado permite isso nesta etapa. Consequentemente, não há neste relatório qualquer medição de latência, taxa de acerto, taxa de erro ou comportamento em produção.
- 2. As conclusões valem para a data e a região declaradas.** Preços de nuvem mudam. Todos os valores são de **23/09/2026, em USD**, com a fonte de cada um registrada em `custos/premissas.csv`. Uma consulta futura pode divergir, e a reprodução dos cálculos exige reverificar as premissas.
- 3. As regiões não são idênticas nas três nuvens.** AWS em `us-east-1` e Azure em `East US`; no Google, Natural Language e Vision têm preço global, e a Cloud Speech-to-Text V2 foi consultada em `us-central1 (Iowa)`, que é US Central. A comparação de custo de transcrição, portanto, não é entre três regiões equivalentes, e a diferença de preço entre regiões do Google não foi levantada.
- 4. As cargas dos cenários são hipotéticas.** 100.000 documentos, 100.000 imagens e 10.000 minutos de áudio são quantidades escolhidas pelo grupo para permitir comparação, não estimativas de uso real de nenhuma aplicação. O que garante a validade da comparação não é a quantidade em si, mas o fato de ser **idêntica entre provedores**.
- 5. Os resultados não se generalizam para outros volumes sem recálculo.** As faixas de preço têm degraus em pontos diferentes em cada provedor. A ordem observada em 100.000 imagens pode se inverter em 10 milhões.
- 6. Comparou-se uma operação por categoria.** Sentimento de documento, detecção de rótulos e transcrição em lote. Cada serviço oferece dezenas de outras operações, com preços e limites próprios, que não foram analisadas.
- 7. Informações não localizadas ficaram como pendência.** Especificamente:

Pendência	Onde
Tamanho máximo de arquivo, duração máxima de áudio e número de jobs simultâneos do Amazon Transcribe	Página de cotas não acessível na consulta
Franquia gratuita da tabela Recognition da Cloud Speech-to-Text V2	Não localizada; a faixa de 60 minutos consta das tabelas da V1
Valor padrão de <code>MinConfidence</code> do <code>DetectLabels</code>	Não localizado; o exemplo de código fixa o parâmetro explicitamente
Limite de tags por imagem no Azure Image Analysis	Não localizado nas páginas consultadas
Limites de tamanho e duração do <code>BatchRecognize</code> da Cloud Speech-to-Text V2	Não localizados nas páginas consultadas (os equivalentes da Azure foram localizados na tabela oficial de cotas)

Nenhuma dessas lacunas foi preenchida por estimativa.

8. A distinção pt-BR da Azure não foi testada. A documentação registra que a Azure distingue português do Brasil de português de Portugal, e que AWS e Google não. **Ela não afirma que isso produza melhor resultado em textos brasileiros**, e este relatório não o afirma. É uma hipótese verificável na Etapa 2.

8. Referências

Registro exigido pela seção 12 do enunciado (p. 5): "a pesquisa deverá utilizar prioritariamente a documentação oficial dos provedores, em especial a documentação das APIs/SDKs e as páginas oficiais de preços".

Como ler este arquivo. Cada fonte tem um identificador interno usado nos capítulos. O campo *afirmação sustentada* diz exatamente o que aquela página comprova — fontes não são listadas de forma decorativa. O campo *estado* usa: **verificado** (página acessada e conteúdo conferido na data indicada), **inacessível**, **informação não localizada** ou **precisa de confirmação**.

Todas as datas são datas reais de acesso. Todas as páginas são documentação oficial dos próprios provedores.

No PDF do relatório esta seção aparece de forma compacta (identificador, provedor, título, URL, data e estado). O campo *afirmação sustentada* de cada fonte — que registra exatamente o que aquela página comprova — está neste arquivo.

NLP / análise de texto

NLP-AWS-01 · AWS — Amazon Comprehend · consultado em 23/09/2026 · VERIFICADO
Sentiment — <https://docs.aws.amazon.com/comprehend/latest/dg/how-sentiment.html>

NLP-AWS-02 · AWS — Amazon Comprehend · consultado em 23/09/2026 · VERIFICADO
Guidelines and quotas — <https://docs.aws.amazon.com/comprehend/latest/dg/guidelines-and-limits.html>

NLP-AWS-03 · AWS — Amazon Comprehend · consultado em 23/09/2026 · VERIFICADO
Languages supported — <https://docs.aws.amazon.com/comprehend/latest/dg/supported-languages.html>

NLP-AZ-01 · Azure — Azure Language in Foundry Tools · consultado em 23/09/2026 · VERIFICADO
What is sentiment analysis and opinion mining in Azure Language service? — <https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/overview>

NLP-AZ-04 · Azure — Azure Language in Foundry Tools · consultado em 26/09/2026 · VERIFICADO
How to perform sentiment analysis and opinion mining — <https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/how-to/call-api>

NLP-AZ-02 · Azure — Azure Language in Foundry Tools · consultado em 23/09/2026 · VERIFICADO
Data limits for Language service features — <https://learn.microsoft.com/en-us/azure/ai-services/language-service/concepts/data-limits>

NLP-AZ-03 · Azure — Azure Language in Foundry Tools · consultado em 23/09/2026 · VERIFICADO
Sentiment Analysis and Opinion Mining language support — <https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/language-support>

NLP-GC-01 · Google Cloud — Cloud Natural Language API · consultado em 23/09/2026 · VERIFICADO

Analyzing Sentiment — <https://docs.cloud.google.com/natural-language/docs/analyzing-sentiment>

NLP-GC-02 · Google Cloud — Cloud Natural Language API · consultado em 23/09/2026 · VERIFICADO

Cloud Natural Language API v1beta1 Deprecation Notice — <https://cloud.google.com/natural-language/deprecation>

NLP-GC-03 · Google Cloud — Cloud Natural Language API · consultado em 23/09/2026 · VERIFICADO

Quotas and limits — <https://docs.cloud.google.com/natural-language/quotas>

NLP-GC-04 · Google Cloud — Cloud Natural Language API · consultado em 23/09/2026 · VERIFICADO

Language support — <https://docs.cloud.google.com/natural-language/docs/languages>

Visão computacional

VIS-AWS-01 · AWS — Amazon Rekognition · consultado em 23/09/2026 · VERIFICADO

Detecting labels in an image — <https://docs.aws.amazon.com/rekognition/latest/dg/labels-detect-labels-image.html>

VIS-AWS-02 · AWS — Amazon Rekognition · consultado em 23/09/2026 · VERIFICADO

Guidelines and quotas — <https://docs.aws.amazon.com/rekognition/latest/dg/limits.html>

VIS-AZ-01 · Azure — Azure Vision in Foundry Tools · consultado em 23/09/2026 · VERIFICADO

What is Image Analysis? — <https://learn.microsoft.com/en-us/azure/ai-services/computer-vision/overview-image-analysis>

VIS-GC-01 · Google Cloud — Cloud Vision API · consultado em 23/09/2026 · VERIFICADO

Detect labels — <https://docs.cloud.google.com/vision/docs/labels>

VIS-GC-03 · Google Cloud — Cloud Vision API · consultado em 26/09/2026 · VERIFICADO

Detect text and labels in files (PDF/TIFF) — <https://docs.cloud.google.com/vision/docs/file-small-batch>

VIS-GC-02 · Google Cloud — Cloud Vision API · consultado em 23/09/2026 · VERIFICADO

Supported images — <https://docs.cloud.google.com/vision/docs/supported-files>

Fala para texto

FAL-AWS-01 · AWS — Amazon Transcribe · consultado em 23/09/2026 · VERIFICADO

How Amazon Transcribe works — <https://docs.aws.amazon.com/transcribe/latest/dg/how-it-works.html>

FAL-AWS-02 · AWS — Amazon Transcribe · consultado em 23/09/2026 · VERIFICADO

Data input and output — <https://docs.aws.amazon.com/transcribe/latest/dg/how-input.html>

FAL-AWS-03 · AWS — Amazon Transcribe · consultado em 23/09/2026 · VERIFICADO

Supported languages — <https://docs.aws.amazon.com/transcribe/latest/dg/supported-languages.html>

FAL-AZ-01 · Azure — Azure Speech in Foundry Tools · consultado em 23/09/2026 · VERIFICADO

Batch transcription overview — <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/batch-transcription>

FAL-AZ-02 · Azure — Azure Speech in Foundry Tools · consultado em 23/09/2026 · VERIFICADO

Locate audio files for batch transcription — <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/batch-transcription-audio-data>

FAL-AZ-03 · Azure — Azure Speech in Foundry Tools · consultado em 23/09/2026 · VERIFICADO

Language and voice support — <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/language-support>

FAL-AWS-04 · AWS — Amazon Transcribe · consultado em 26/09/2026 · VERIFICADO
Amazon Transcribe pricing — <https://aws.amazon.com/transcribe/pricing/>

FAL-AZ-04 · Azure — Azure Speech in Foundry Tools · consultado em 26/09/2026 · VERIFICADO
Quotas and limits for Azure Speech — <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/speech-services-quotas-and-limits>

FAL-AZ-05 · Azure — Azure Speech in Foundry Tools · consultado em 26/09/2026 · VERIFICADO
Create a batch transcription — <https://learn.microsoft.com/en-us/azure/ai-services/speech-service/batch-transcription-create>

FAL-GC-01 · Google Cloud — Cloud Speech-to-Text V2 · consultado em 23/09/2026 · VERIFICADO
Transcription models — <https://docs.cloud.google.com/speech-to-text/v2/docs/transcription-model>

FAL-GC-03 · Google Cloud — Cloud Speech-to-Text V2 · consultado em 26/09/2026 · VERIFICADO
`BatchRecognizeFileResult` (referência da client library Python) — https://docs.cloud.google.com/python/docs/reference/speech/latest/google.cloud.speech_v2.types.BatchRecognizeFileResult

FAL-GC-02 · Google Cloud — Cloud Speech-to-Text V2 · consultado em 23/09/2026 · VERIFICADO
Supported languages — <https://docs.cloud.google.com/speech-to-text/v2/docs/speech-to-text-supported-languages>

Enunciado do trabalho

ID	Documento	Data de acesso	Afirmação sustentada	Estado
ENU-01	<code>pdfs/Computação em Nuvem - Trabalho I_ Comparação de Serviços de Inteligência Artificial em Nuvem.pdf</code> (5 páginas)	23/09/2026	Todas as exigências citadas em <code>etapa1/diagnostico.md</code> , com seção e página	verificado

Preços

Região **US East**, moeda **USD**, consulta em **23/09/2026**. Todos os valores estão em `custos/premissas.csv`, com a URL da fonte em cada linha.

Por que APIs de preço e não as páginas comerciais: as páginas de preço da Azure e do Google servem suas tabelas por JavaScript — o conteúdo estático exibe apenas `$-`. Em vez de recorrer a fonte secundária, os valores foram lidos das APIs públicas de preço mantidas pelos próprios provedores, que são a fonte oficial dos mesmos números.

PRE-AWS-01 · AWS — Amazon Comprehend · consultado em 23/09/2026 · VERIFICADO
AWS Price List API — <https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/comprehend/current/index.json>

PRE-AWS-02 · AWS — Amazon Comprehend · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://aws.amazon.com/comprehend/pricing/>

PRE-AWS-03 · AWS — Amazon Rekognition · consultado em 23/09/2026 · VERIFICADO
AWS Price List API — <https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/AmazonRekognition/current/index.json>

PRE-AWS-04 · AWS — Amazon Rekognition · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://aws.amazon.com/rekognition/pricing/>

PRE-AWS-05 · AWS — Amazon Transcribe · consultado em 23/09/2026 · VERIFICADO
AWS Price List API — <https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/transcribe/current/index.json>

PRE-AWS-06 · AWS — Amazon Transcribe · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://aws.amazon.com/transcribe/pricing/>

PRE-AZ-01 · Azure — Azure Language · consultado em 23/09/2026 · VERIFICADO
Azure Retail Prices API — <https://prices.azure.com/api/retail/prices> (serviceName `Foundry Tools`, região `eastus`)

PRE-AZ-02 · Azure — Azure Vision · consultado em 23/09/2026 · VERIFICADO
Azure Retail Prices API — <https://prices.azure.com/api/retail/prices>

PRE-AZ-03 · Azure — Azure Vision · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://azure.microsoft.com/en-us/pricing/details/computer-vision/>

PRE-AZ-04 · Azure — Azure Speech · consultado em 23/09/2026 · VERIFICADO
Azure Retail Prices API — <https://prices.azure.com/api/retail/prices>

PRE-AZ-05 · Azure — Azure Speech · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://azure.microsoft.com/en-us/pricing/details/speech/>

PRE-GC-01 · Google Cloud — Cloud Natural Language · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://cloud.google.com/natural-language/pricing>

PRE-GC-02 · Google Cloud — Cloud Vision · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://cloud.google.com/vision/pricing>

PRE-GC-03 · Google Cloud — Cloud Speech-to-Text V2 · consultado em 23/09/2026 · VERIFICADO
Pricing — <https://cloud.google.com/speech-to-text/pricing>

Fontes não oficiais consultadas e descartadas

Registradas por transparência: foram lidas durante a pesquisa, mas **não sustentam nenhuma afirmação** do trabalho.

Fonte	Motivo do descarte
Tópico "Analyze sentiment deprecation?" no fórum Google Developer (discuss.google.dev)	Um respondente afirma que a Cloud Natural Language API estaria "depreciada" em favor do Vertex AI. A afirmação não se confirma na documentação oficial: a página de <code>analyzeSentiment</code> não traz aviso de descontinuação (NLP-GC-01) e a única descontinuação oficial é a do <code>v1beta1</code> (NLP-GC-02). Fórum não é fonte oficial e a afirmação foi descartada.

Relatório montado automaticamente a partir dos arquivos do repositório em 29/09/2026 por `relatorio/montar_relatorio.py`. Para regerar: `uv run relatorio/montar_relatorio.py --html`.