

Comparação de Serviços de Inteligência Artificial em Nuvem

Etapa 1 — Análise Comparativa

Disciplina: Computação em Nuvem

Programa: Mestrado em Ciência da Computação — Universidade de Fortaleza (UNIFOR)

Integrantes:

- Davi Fonseca Passos
- Rafael Fonseca Pessoa
- Lucca Melo Nunes

Provedores analisados: Amazon Web Services · Microsoft Azure · Google Cloud

Região de referência: US East · **Moeda:** USD · **Preços consultados em:** 23/09/2026

1. Introdução

Este relatório apresenta a análise comparativa de serviços de inteligência artificial oferecidos por **Amazon Web Services (AWS)**, **Microsoft Azure** e **Google Cloud**, sob a perspectiva de um desenvolvedor que precisa escolher entre eles para incorporá-los a uma aplicação.

A perspectiva adotada é deliberadamente a de quem **consome** o serviço, e não a de quem estuda o modelo por trás dele. As perguntas que orientam cada capítulo são as de uma decisão de integração: o que o serviço faz, como se chama, o que aceita de entrada, o que devolve, como se autentica, que limites impõe, quanto custa e em que situação compensa.

Como este relatório foi construído

Toda afirmação técnica e todo preço vêm de **documentação oficial dos provedores**, consultada em **23 e 24 de setembro de 2026**, com URL e data registradas em `referencias/fontes.md`. Onde uma informação não foi localizada, ela aparece como **pendência declarada** — nunca preenchida por estimativa.

Duas decisões metodológicas merecem registro:

Os preços vieram das APIs públicas de preço dos provedores, não das páginas comerciais. As páginas de preço da Azure e do Google entregam suas tabelas por JavaScript, exibindo apenas `$-` no conteúdo estático. Em vez de recorrer a fontes secundárias, os valores foram obtidos da *AWS Price List API* e da *Azure Retail Prices API* — ambas públicas e mantidas pelos próprios provedores — e das tabelas servidas pela página de preços do Google.

Os exemplos de código não foram executados. A seção 3 do enunciado permite isso explicitamente nesta etapa, e cada arquivo declara esse estado. Nenhum resultado de execução, medição de latência ou taxa de acerto é apresentado neste relatório: tudo isso é objeto da Etapa 2.

Região, moeda e data

Parâmetro	Valor
Região de referência	US East — <code>us-east-1</code> (N. Virginia) / <code>East US</code> / <code>us-central1</code>
Moeda	USD
Data de consulta dos preços	23/09/2026

A região US East foi escolhida por ser a região de referência das três tabelas de preço e por ter as nove ofertas disponíveis. Duas das APIs do Google comparadas (Natural Language e Vision) têm **preço global, não regional** — o que está registrado nas premissas.

2. Seleção das categorias e critérios

O enunciado (seção 2) determina que a seleção "deverá privilegiar a relevância para o desenvolvimento de aplicações e a diversidade de funcionalidades", evitando "selecionar vários serviços pertencentes essencialmente ao mesmo domínio de aplicação".

O grupo selecionou **três categorias**, aplicando três critérios:

- 1. Diversidade de domínio de entrada.** As categorias tratam modalidades diferentes — **texto, imagem e áudio**. Isso evita o erro que o próprio enunciado adverte: analisar sentimento, entidades e frases-chave seria comparar três *funcionalidades do mesmo domínio* (processamento de linguagem natural), não três categorias distintas.
- 2. Relevância para quem integra IA a uma aplicação.** As três resolvem problemas correntes de produto — classificar opinião de usuários, indexar e moderar imagens, transcrever áudio — e todas são consumíveis por API ou SDK com modelos pré-treinados, sem treinar modelo próprio.
- 3. Existência de oferta concorrente nos três provedores.** O enunciado exige pelo menos dois provedores por categoria e recomenda incluir os três quando houver equivalência. Nas três categorias há oferta gerenciada equivalente na AWS, na Azure e no Google Cloud, de modo que **os três entram em todas as comparações**.

Categorias e serviços comparados

Categoria	AWS	Microsoft Azure	Google Cloud	Operação comparada
NLP / análise de texto	Amazon Comprehend	Azure Language in Foundry Tools	Cloud Natural Language API	Sentimento de documento
Visão computacional	Amazon Rekognition	Azure Vision in Foundry Tools	Cloud Vision API	Detecção de rótulos
Fala para texto	Amazon Transcribe	Azure Speech in Foundry Tools	Cloud Speech-to-Text V2	Transcrição em lote

Categorias consideradas e descartadas: **tradução automática** (domínio de entrada próximo demais de NLP), **análise de documentos/OCR** (sobreposição com visão computacional) e **modelos generativos** (comparação dominada pela escolha de modelo, com preços por token de alta volatilidade).

Nomenclatura atualizada

Durante a pesquisa constatou-se que **a** Microsoft reorganizou suas ofertas de IA sob a marca **Foundry Tools**. Os nomes usados neste relatório são os vigentes em setembro de 2026; os nomes anteriores (Azure AI Language, Text Analytics, Azure AI Vision, Azure AI Speech) aparecem entre parênteses na primeira ocorrência de cada capítulo.

Equivalência e seus limites

A comparação é entre serviços **concorrentes**, não idênticos. Três limites à equivalência foram identificados já na seleção e são retomados nos capítulos:

- O formato de saída do sentimento diverge nos três.** AWS retorna uma de quatro classes com scores; Azure retorna rótulo entre três classes com confiança, em nível de documento e sentença; o Google não retorna classe alguma, apenas `score` e `magnitude`.
- Os vocabulários de rótulos de imagem não têm equivalência oficial**, e as escalas de confiança diferem (0-100 na AWS, 0-1 nos demais).
- "Lote" significa compromissos de tempo diferentes** em cada provedor na transcrição de áudio, o que afeta diretamente a comparação de preço.

3. NLP / análise de texto: análise de sentimento

Operação comparada: sentimento em nível de documento, sobre o mesmo texto em português (`0 atendimento foi excelente.`) **Modo de chamada:** síncrono, um documento por chamada **Data da consulta às fontes:** 23/09/2026 **Região de referência:** US East (`us-east-1` / East US / global no caso do Google)

1. Objetivo da categoria e caso de uso

Análise de sentimento classifica a opinião predominante expressa em um texto. O caso de uso típico é processar avaliações de clientes, comentários de suporte ou menções em redes sociais para priorizar atendimento ou medir satisfação, sem que a equipe precise treinar um modelo próprio.

Todos os três provedores oferecem essa funcionalidade em modelos **pré-treinados**, acessíveis por chamada de API: o desenvolvedor envia texto e recebe uma avaliação de sentimento, sem etapa de treinamento, rotulagem ou hospedagem de modelo.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação síncrona de documento único
AWS	Amazon Comprehend	<code>DetectSentiment</code>
Microsoft Azure	Azure Language in Foundry Tools (antes Azure AI Language / Text Analytics)	Análise de sentimento via REST API ou client library
Google Cloud	Cloud Natural Language API (v1)	<code>analyzeSentiment</code>

Cada provedor também oferece modos adicionais, que **não** entram na comparação por não serem equivalentes em carga: `BatchDetectSentiment` (até 25 documentos) e `StartSentimentDetectionJob` (assíncrono) na AWS; requisições assíncronas em lote na Azure; processamento de textos longos no Google.

3. Comparação técnica

3.1 Funcionalidades, entradas e saídas

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Formato da saída	Uma classe entre <code>POSITIVE</code> , <code>NEGATIVE</code> , <code>NEUTRAL</code> e <code>MIXED</code> , mais <code>SentimentScore</code> com um score para cada uma das quatro classes	Rótulo <code>positive</code> , <code>neutral</code> ou <code>negative</code> , com scores de confiança de 0 a 1 para as três classes	Não retorna classe. Devolve <code>score</code> (de $-1,0$ a $+1,0$) e <code>magnitude</code> (intensidade acumulada, não normalizada)
Granularidade	Documento	Documento e sentença (ambos na mesma resposta)	Documento e sentença
Classe para texto ambíguo	<code>MIXED</code> é uma classe própria, distinta de <code>NEUTRAL</code>	Não há classe <code>mixed</code> na saída de documento; o rótulo sai do maior score	Não há classe; cabe ao desenvolvedor definir limiares
Codificação de entrada	UTF-8	Texto (string única por documento)	UTF-8
Tamanho máximo do documento	5 KB por documento na operação síncrona de sentimento	5.120 caracteres por documento (síncrono), medidos por <code>StringInfo.LengthInTextElements</code>	1.000.000 bytes de conteúdo; até 100.000 tokens por requisição
Documentos por requisição	1 (<code>DetectSentiment</code>); até 25 em <code>BatchDetectSentiment</code>	10 documentos por requisição em análise de sentimento	1 documento por requisição
Tamanho máximo da requisição	—	1 MB	—

O contraste mais importante para quem integra: **a AWS e a Azure entregam uma decisão pronta (uma classe), enquanto o Google entrega apenas um número contínuo.** Usar o Google exige que a aplicação defina os limiares que separam positivo, neutro e negativo — uma decisão de produto que os outros dois já tomam pelo desenvolvedor. Além disso, `magnitude` (Google) e `SentimentScore` (AWS) e confiança (Azure) são grandezas diferentes e não podem ser comparadas entre si.

3.2 Suporte a português

Provedor	Códigos aceitos	Total de idiomas na operação
Amazon Comprehend	pt (Português, sem distinção de variante)	12 idiomas, e o sentimento cobre todos eles
Azure Language	pt-BR (Português do Brasil) e pt-PT (Português de Portugal); pt também é aceito	94 códigos de idioma
Cloud Natural Language	pt (Português, sem distinção de variante)	16 idiomas na análise de sentimento

Diferença relevante para aplicações brasileiras: apenas a Azure distingue formalmente o português do Brasil do português de Portugal na análise de sentimento. AWS e Google tratam "português" como um único idioma. A documentação não afirma que essa distinção produza resultado melhor em textos brasileiros — isso seria uma conclusão experimental, fora do escopo desta etapa.

3.3 Formas de acesso, autenticação e configuração

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Acesso	API REST, AWS SDKs (Python/boto3, Java, .NET, Node.js, Ruby...), AWS CLI	REST API, client libraries (C#, Java, JavaScript, Python), contêiner Docker para execução local	REST (POST .../v1/documents:analyzeSentiment), gRPC, client libraries
Autenticação	Credenciais IAM (chave de acesso/secreto ou role), resolvidas pela cadeia padrão do SDK	Chave do recurso + endpoint próprios do recurso criado, ou Microsoft Entra ID	Conta de serviço com Application Default Credentials (GOOGLE_APPLICATION_CREDENTIALS) ou chave de API
Endpoint	Regional (comprehend.us-east-1.amazonaws.com)	Endpoint próprio do recurso, vinculado à região escolhida na criação	language.googleapis.com (global)
Configuração mínima	Região + credenciais	Criar um recurso <i>Azure Language in Foundry Tools</i> , obter chave e endpoint	Projeto com a API habilitada + credenciais

A Azure é a única das três que oferece **execução em contêiner local** da análise de sentimento, o que importa em cenários com restrição de saída de dados. Em contrapartida, é a única que exige criar previamente um recurso e administrar um par chave/endpoint específico dele.

3.4 Limites operacionais e de taxa

Aspecto	Amazon Comprehend	Azure Language	Cloud Natural Language
Limite de requisições	<i>Throttling</i> dinâmico: a AWS ajusta a vazão conforme a banda de processamento disponível, sem número fixo publicado para o modo síncrono	Depende do tier: S/Multi-service 1.000 req/s; S0/F0 100 req/s e 300 req/min	600 requisições/minuto e 800.000 requisições/dia
Regiões	13 regiões, incluindo US East (N. Virginia) e US East (Ohio); não há região no Brasil na lista publicada	Endpoint regional; East US disponível	API global
Previsibilidade de vazão	Baixa: não há cota publicada para planejar	Alta: cota explícita por tier	Alta: cota explícita

O *throttling* dinâmico da AWS é uma diferença prática relevante: não é possível dimensionar a aplicação a partir de um número publicado, e a própria documentação recomenda implementar limitação de taxa no cliente e ativar alertas de cobrança.

3.5 Situação do serviço (avisos oficiais)

Provedor	Aviso na documentação oficial
AWS	Nenhum aviso de descontinuação encontrado.
Azure	" Sentiment analysis and opinion mining retire from Azure Language on March 31, 2029 ", com recomendação de migrar cargas existentes e direcionar novos projetos ao Microsoft Foundry.
Google	Nenhum aviso de descontinuação na página do <code>analyzeSentiment</code> . A única descontinuação oficial da API é a da versão <code>v1beta1</code> , encerrada em 27/12/2019 , que não atinge a <code>v1</code> em uso.

Este é um critério de decisão concreto: escolher a análise de sentimento da Azure hoje significa assumir uma migração antes de **31/03/2029**.

4. Exemplos de código

Os três exemplos executam a **mesma operação** sobre o **mesmo texto**, e estão em:

- `exemplos/nlp/aws_comprehend.py`
- `exemplos/nlp/azure_language.py`
- `exemplos/nlp/google_natural_language.py`

Estado de validação: os três exemplos são **ilustrativos e não foram executados pelo grupo**. Foram adaptados da documentação oficial de cada provedor, conforme permitido pela seção 3 do enunciado ("Nesta etapa, os exemplos não precisam ter sido desenvolvidos ou executados pelo grupo"). Cada arquivo declara sua dependência, a fonte da adaptação e o mecanismo de autenticação. Nenhuma credencial está embutida no código: todos leem variáveis de ambiente.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Regra de contagem	Preço na primeira faixa
Amazon Comprehend	Unidade de 100 caracteres	<code>ceil(caracteres/100)</code> , com mínimo de 3 unidades (300 caracteres) por requisição	\$0,0001 por unidade (até 10M de unidades/mês)
Azure Language	Registro de texto de 1.000 caracteres	<code>ceil(caracteres/1000)</code> por documento	\$1,00 por 1.000 registros (até 0,5M de registros/mês)
Cloud Natural Language	Unidade de 1.000 caracteres Unicode	<code>ceil(caracteres/1000)</code> , com mínimo de 1 unidade por requisição	\$1,00 por 1.000 unidades (de 5 mil a 1M de unidades/mês)

Todos os preços acima são de **US East, em USD, consultados em 23/09/2026**, e estão em `custos/premissas.csv` com a URL da fonte. Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API* — ambas APIs públicas oficiais dos próprios provedores, usadas porque as páginas comerciais de preço entregam as tabelas por JavaScript.

A regra de contagem do Google foi confirmada pelo exemplo da própria página de preços: 800, 1.500 e 600 caracteres são cobrados como $1 + 2 + 1 = 4$ **unidades**, ou seja, arredondamento para cima com mínimo de uma unidade.

A diferença de unidade é o fator que mais afeta o custo comparado: **um texto curto de 100 caracteres consome 1 unidade na AWS (sujeita ao mínimo da requisição) e 1 unidade inteira de 1.000 caracteres na Azure e no Google**. O efeito disso sobre o custo real é calculado na Fase 4, com cenários de comprimento variável, e é exatamente por isso que o cenário usa textos de 100, 500, 1.200 e 4.000 caracteres.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

100.000 documentos por mês, submetidos um por chamada síncrona, em quatro comprimentos: **100, 500, 1.200 e 4.000 caracteres**. A quantidade é hipotética e declarada como tal; o que importa é que **é idêntica nos três provedores**, como exige a seção 4 do enunciado. Os quatro comprimentos existem justamente para expor o efeito do tamanho da unidade de cobrança.

Todos os comprimentos cabem nos limites de entrada dos três serviços (o menor limite relevante é o de 5 KB do Comprehend).


Fórmulas

AWS: unidades = $\max(3, \text{ceil}(\text{caracteres}/100)) \times 100.000$ documentos
Azure: registros = $\text{ceil}(\text{caracteres}/1000) \times 100.000$ documentos
Google: unidades = $\max(1, \text{ceil}(\text{caracteres}/1000)) \times 100.000$ documentos

O custo é progressivo por faixa: cada parcela do volume é cobrada ao preço da faixa em que cai — nunca o volume inteiro ao preço da última faixa.

Resultados (USD/mês, sem franquia)

Comprimento	Unidades cobradas AWS	AWS	Azure	Google
100 caracteres	300.000 (mínimo de 3/doc)	\$30,00	\$100,00	\$100,00
500 caracteres	500.000	\$50,00	\$100,00	\$100,00
1.200 caracteres	1.200.000	\$120,00	\$200,00	\$200,00
4.000 caracteres	4.000.000	\$400,00	\$400,00	\$400,00



O que os números mostram

O cenário revela um efeito que a tabela de preços isolada esconde: **para textos curtos, a granularidade da unidade importa mais que o preço unitário**. Um comentário de 100 caracteres consome 3 unidades de 100 caracteres na AWS, mas **uma unidade inteira de 1.000 caracteres** na Azure e no Google — pagando-se, nos dois casos, por 900 caracteres não enviados. O resultado é que a AWS custa **um terço** dos concorrentes nesse comprimento.

A vantagem encolhe conforme o texto cresce e **desaparece em 4.000 caracteres**, onde os três convergem para \$400,00. A partir daí, o que separa os provedores não é mais a granularidade, e sim as faixas de volume.

Isso tem consequência prática direta: **a escolha mais econômica depende do comprimento típico do texto da aplicação**. Para avaliações curtas de produto ou mensagens de chat, a diferença é de 3 para 1; para documentos longos, é irrelevante.

Franquias

As três franquias existem, mas **não são a mesma coisa** e por isso não entram na comparação principal:

Provedor	Franquia	Natureza
AWS	50.000 unidades/mês por API	Promocional: vale 12 meses a partir da primeira requisição
Azure	5.000 registros/mês	Tier F0 separado , compartilhado entre várias features do Azure Language; não é desconto no tier S
Google	5.000 unidades/mês	Faixa da própria tabela cobrada a \$0,00; permanente

Aplicadas ao cenário de 100 caracteres, reduzem o custo para \$25,00 (AWS), \$95,00 (Azure) e \$95,00 (Google) — valores na coluna `custo_usd_com_franquia` de `custos/resultados.csv`. Como só a do Google é permanente e as três têm regras distintas, **a comparação principal usa os preços sem franquia**, que é a situação de regime.

Reprodutibilidade

```
uv run custos/calcular_custos.py      # gera custos/resultados.csv (só stdlib)
uv run custos/verificar_calculos.py  # confere as contas à mão contra o programa
uv run custos/gerar_graficos.py      # gera os gráficos a partir do CSV
```

7. Síntese: vantagens, restrições e adequação por cenário

As três diferenças que mais pesam

1. O Google não entrega uma decisão, entrega um número. AWS e Azure devolvem uma classe pronta (`POSITIVE / positive`); o Google devolve `score` e `magnitude` e deixa para a aplicação definir onde ficam as fronteiras entre positivo, neutro e negativo. Isso não é detalhe de formato: é trabalho de produto transferido para quem integra, e uma decisão que precisa ser justificada e congelada antes de qualquer avaliação. Em compensação, dá controle a quem quer calibrar o limiar ao próprio domínio.

2. Só a AWS trata texto ambíguo como categoria. A classe `MIXED` existe apenas no Comprehend. Na Azure, o rótulo sai do maior score entre três classes; no Google, não há classe alguma. Para uma aplicação que precisa separar "opinião dividida" de "sem opinião", só um dos três oferece isso pronto.

3. Só a Azure distingue português do Brasil. `pt-BR` e `pt-PT` são códigos separados na Azure, contra um `pt` genérico na AWS e no Google. Para um produto brasileiro isso é atraente — mas **a documentação não promete resultado melhor**, e afirmar que produz seria extrapolar. É exatamente o tipo de hipótese que a Etapa 2 pode testar.

Custo: a granularidade da unidade domina em textos curtos

O cenário de 100.000 documentos mostrou que **a AWS custa um terço dos concorrentes em textos de 100 caracteres** (\$30,00 contra \$100,00), porque cobra em unidades de 100 caracteres enquanto Azure e Google cobram uma unidade inteira de 1.000. A vantagem some em 4.000 caracteres, onde os três convergem para \$400,00.

Ou seja: **não existe "o mais barato" nesta categoria — existe o mais barato para o seu comprimento de texto.**

O risco que nenhuma tabela de preço mostra

A análise de sentimento da Azure tem **encerramento anunciado para 31/03/2029**, com migração recomendada para o Microsoft Foundry. Nenhum concorrente comparado tem aviso equivalente. Para um sistema que se espera manter por anos, isso é um custo futuro de migração que não aparece em nenhum cenário de preço.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Alto volume de textos curtos (avaliações, chat, comentários)	Amazon Comprehend	Unidade de 100 caracteres torna o custo até 3× menor; MIXED ajuda em opinião dividida
Necessidade de sentimento por sentença junto com o do documento	Azure Language	Entrega os dois níveis na mesma resposta
Restrição de saída de dados do ambiente próprio	Azure Language	Único dos três com contêiner Docker para execução local
Aplicação que quer calibrar o limiar ao próprio domínio	Cloud Natural Language	O score contínuo é matéria-prima, não uma decisão já tomada
Sistema com horizonte longo de manutenção	AWS ou Google	A oferta da Azure tem encerramento datado
Documentos longos (acima de ~4.000 caracteres)	Indiferente no custo	Os três convergem; decidir por critério técnico

O que esta etapa não responde: qual dos três classifica melhor sentimento em português. Isso exige execução, gabarito e medição — é o objeto da Etapa 2.

8. Referências e pendências de verificação

Fontes usadas neste capítulo

Detalhamento completo em `referencias/fontes.md`.

ID	O que sustenta
NLP-AWS-01	Operações de sentimento, classes retornadas e estrutura de <code>SentimentScore</code>
NLP-AWS-02	Limites de tamanho por operação (5 KB síncrono, 25 documentos em lote) e regiões suportadas
NLP-AWS-03	Idiomas suportados: sentimento cobre todos os 12 idiomas, incluindo <code>pt</code>
NLP-AZ-01	Nome atual do serviço, aviso de encerramento em 31/03/2029, rótulos e granularidade, formas de acesso
NLP-AZ-02	Limites de dados: 5.120 caracteres por documento, 10 documentos por requisição, 1 MB por requisição, limites de taxa por tier, definição de registro de texto como 1.000 caracteres
NLP-AZ-03	Suporte a 94 idiomas, com <code>pt-BR</code> e <code>pt-PT</code> distintos
NLP-GC-01	Operação <code>analyzeSentiment</code> e ausência de aviso de descontinuação
NLP-GC-02	Descontinuação restrita à <code>v1beta1</code> (27/12/2019)
NLP-GC-03	Cotas: 1.000.000 bytes de conteúdo, 100.000 tokens, 600 req/min, 800.000 req/dia
NLP-GC-04	Idiomas com suporte a análise de sentimento, incluindo <code>pt</code>

Pendências

- **Preços não verificados** até esta data. As unidades de cobrança na seção 5 estão marcadas como "a confirmar" para AWS e Google; apenas a definição de registro de texto da Azure vem de fonte já consultada. Nenhum cálculo de custo é apresentado antes dessa verificação.

- A documentação da AWS **não publica cota fixa de requisições por segundo** para o modo síncrono; a comparação de vazão fica limitada a esse fato, sem número.
- O comportamento do `MIXED` da AWS e a ausência de classe equivalente nos outros dois é uma diferença **documental**. Qual serviço classifica melhor textos ambíguos em português é pergunta experimental, e só pode ser respondida na Etapa 2.

4. Visão computacional: detecção de rótulos em imagem

Operação comparada: detecção de rótulos (labels/tags) do conteúdo da mesma imagem, sem localização **Modo de chamada:** síncrono, uma imagem por chamada **Data da consulta às fontes:** 23/09/2026 **Região de referência:** US East (`us-east-1` / `East US` / global no caso do Google)

1. Objetivo da categoria e caso de uso

Detecção de rótulos responde à pergunta "o que aparece nesta imagem?", devolvendo termos como *pessoa*, *carro* ou *praia* com um grau de confiança. O caso de uso típico é indexar e tornar pesquisável um acervo de imagens enviadas por usuários, alimentar filtros de catálogo ou fazer uma triagem inicial de conteúdo antes de revisão humana.

Escolheu-se a detecção de rótulos — e não detecção de objetos com caixas delimitadoras — porque é a operação com equivalente direto nos três provedores e a que produz saída mais comparável.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação comparada
AWS	Amazon Rekognition	<code>DetectLabels</code> , feature <code>GENERAL_LABELS</code>
Microsoft Azure	Azure Vision in Foundry Tools — Image Analysis	<i>Tag visual features</i> (Tags), via <code>Analyze Image</code>
Google Cloud	Cloud Vision API	Feature <code>LABEL_DETECTION</code> , via <code>images:annotate</code>

3. Comparação técnica

3.1 Entradas: formatos e limites

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Formatos aceitos	Apenas PNG e JPEG	v4.0: JPEG, PNG, GIF, BMP, WEBP, ICO, TIFF, MPO · v3.2: JPEG, PNG, GIF, BMP	JPEG, PNG8, PNG24, GIF, GIF animado (só o primeiro quadro), BMP, WEBP, RAW, ICO, PDF, TIFF
Tamanho máximo	15 MB como objeto no Amazon S3; 5 MB quando enviada como bytes na requisição	v4.0: menos de 20 MB · v3.2: menos de 4 MB	20 MB por imagem; requisição JSON limitada a 10 MB
Dimensões	Mínimo 80×80 px; máximo 10.000 px de largura e altura para <code>DetectLabels</code>	Entre 50×50 e 16.000×16.000 px	Resolução recomendada de 640×480 px para <code>LABEL_DETECTION</code>
Origem da imagem	Objeto no Amazon S3 ou bytes na requisição	Bytes na requisição ou URL da imagem	Arquivo local em base64, URI do Cloud Storage (<code>gs://</code>) ou URL remota

O Cloud Vision aceita a maior variedade de formatos (inclusive PDF e RAW) e o Rekognition a menor (só PNG e JPEG). Para um pipeline que recebe upload livre de usuários, isso significa que **a AWS exige uma etapa de conversão** que os outros dois dispensam em vários casos.

3.2 Saídas

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Campos por rótulo	<code>Name</code> , <code>Confidence</code> , <code>Parents</code> (hierarquia), <code>Aliases</code> (sinônimos), <code>Categories</code> , <code>Instances</code> (com <code>BoundingBox</code> quando aplicável)	Tags com nome e confiança	<code>mid</code> (identificador no Google Knowledge Graph), <code>description</code> , <code>score</code> , <code>topicality</code>
Escala da confiança	0 a 100	0 a 1	0 a 1
Estrutura semântica	Hierarquia explícita: um rótulo traz seus rótulos-pai, apelidos e categoria	Lista plana de tags	<code>mid</code> permite ligar o rótulo a uma entidade do Knowledge Graph
Controle de quantidade	<code>MaxLabels</code> e <code>MinConfidence</code>	Parâmetros da chamada <code>Analyze</code>	<code>maxResults</code> (padrão 10 se omitido)
Filtros	<code>LabelInclusionFilters</code> , <code>LabelExclusionFilters</code> , <code>LabelCategoryInclusionFilters</code> , <code>LabelCategoryExclusionFilters</code>	—	—
Versão do modelo na resposta	<code>LabelModelVersion</code>	—	—

Três diferenças importam na integração:

1. **A escala de confiança não é a mesma.** A AWS usa 0–100 e os outros dois 0–1. Qualquer comparação ou limiar compartilhado exige normalização explícita.
2. **A AWS é a única que devolve taxonomia.** `Parents`, `Aliases` e `Categories` permitem agrupar rótulos sem manter um dicionário próprio, e os filtros de inclusão/exclusão permitem restringir a resposta no servidor. Nos outros dois isso fica por conta da aplicação.
3. **O Google é o único que devolve identificador estável** (`mid`) ligado ao Knowledge Graph, útil para associar rótulos a uma base de conhecimento em vez de comparar strings.

Os vocabulários de rótulos **não são compatíveis entre provedores**: nomes, granularidade e idioma dos termos diferem, e não há tabela oficial de equivalência. Comparar "quantos rótulos cada um acertou" exigiria um gabarito próprio — trabalho de avaliação prática, não desta etapa.

3.3 Formas de acesso, autenticação e configuração

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Acesso	API REST, AWS SDKs (Python, Java, .NET, Node.js, Ruby), AWS CLI	REST API (<code>aka.ms/vision-4-0-ref</code>) e client library SDK	REST (<code>POST https://vision.googleapis.com/v1/images:annotate</code>), gRPC, client libraries, <code>gcloud ml vision detect-labels</code>
Autenticação	Credenciais IAM; para ler imagem do S3, também permissão de leitura no bucket	Chave + endpoint do recurso <i>Azure Vision in Foundry Tools</i>	Application Default Credentials ou chave de API
Configuração mínima	Região + credenciais (+ bucket S3, se usar essa origem)	Criar o recurso em região suportada (East US está na lista)	Projeto com a API habilitada

A Azure é a única das três com **restrição de região documentada para a própria funcionalidade**: a página oficial lista as regiões em que o Image Analysis existe, e recursos criados fora delas não atendem à operação. AWS e Google não impõem essa barreira para a operação comparada.

3.4 Limites operacionais e de taxa

Aspecto	Amazon Rekognition	Azure Image Analysis	Cloud Vision API
Limite de requisições	TPS por operação e por região, ajustável via AWS Service Quotas; erros <code>ProvisionedThroughputExceededException</code> e <code>ThrottlingException</code> são documentados como reentráveis	Conforme o tier do recurso	Cotas por projeto
Recomendação oficial	Suavizar picos de tráfego (fila), configurar <i>retries</i> com <i>backoff</i> exponencial e <i>jitter</i>	—	—
Processamento em massa	Image Bulk Analysis: lotes de até 10.000 imagens, manifesto de até 50 MB	—	—

3.5 Situação do serviço (avisos oficiais)

Provedor	Aviso na documentação oficial
AWS	Nenhum aviso de descontinuação para <code>DetectLabels</code> .
Azure	"The Image Analysis 4.0 service in Azure Vision in Foundry Tools is deprecated and will be retired on September 25, 2028", com guia de migração indicado. Funcionalidades da versão 4.0 em preview já foram encerradas antes: Custom Image Classification, Custom Object Detection, Product Recognition e a API Segment / remoção de fundo foram desativadas em 31/03/2025 .
Google	Nenhum aviso de descontinuação para <code>LABEL_DETECTION</code> .

Esse é o segundo serviço da Azure comparado neste trabalho com encerramento anunciado — o primeiro foi a análise de sentimento (31/03/2029). O histórico de funcionalidades já retiradas em 2025 reforça que a cadência de mudança da oferta de visão da Azure é mais alta que a dos concorrentes, o que é um fator de risco de manutenção para quem integra hoje.

4. Exemplos de código

Os três exemplos executam a **mesma operação** sobre a **mesma imagem**:

- `exemplos/visao/aws_rekognition.py`
- `exemplos/visao/azure_image_analysis.py`
- `exemplos/visao/google_vision.py`

Estado de validação: exemplos **ilustrativos, não executados pelo grupo**, adaptados da documentação oficial de cada provedor, conforme a seção 3 do enunciado. Nenhuma credencial está embutida: todos leem variáveis de ambiente.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Preço na primeira faixa
Amazon Rekognition	Por imagem processada (APIs do Grupo 2, onde está o <code>DetectLabels</code>)	\$0,0010 por imagem (até 1M de imagens/mês)
Azure Image Analysis	Por transação , cobrada a cada 1.000 (feature <i>Tag</i> pertence ao Grupo 1)	\$1,00 por 1.000 transações (até 1M/mês)
Cloud Vision API	Por unidade , onde cada feature aplicada a uma imagem conta como uma unidade	\$1,50 por 1.000 unidades (de 1.000 a 5M/mês)

Preços de **US East, em USD, consultados em 23/09/2026**, registrados em `custos/premissas.csv`. Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API*.

A regra do Cloud Vision confirma-se na página oficial: aplicar duas features à mesma imagem gera duas unidades cobradas. Como o cenário usa **uma única feature por imagem** (`LABEL_DETECTION`), a carga permanece equivalente entre os três. O enquadramento da feature *Tag* no Grupo 1 da Azure — e não no Grupo 2, mais caro na primeira faixa — também foi confirmado na página de preços, que lista *Tag* entre as features do Grupo 1.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

100.000 imagens por mês, uma chamada por imagem, com **uma única feature de detecção de rótulos** em cada. A quantidade é hipotética e declarada como tal, e é idêntica nos três provedores.


Restringir a uma feature por imagem não é detalhe: é o que mantém a carga comparável, já que o Cloud Vision cobra por feature aplicada e não por imagem.

Fórmulas

AWS: 100.000 imagens (1 unidade por imagem)
Azure: 100.000 transações (1 imagem com 1 feature = 1 transação)
Google: 100.000 unidades (1 feature x 1 imagem = 1 unidade)

Resultados (USD/mês)

Provedor	Unidades cobradas	Sem franquia	Com franquia
AWS — Rekognition	100.000 imagens	\$100,00	\$99,00
Azure — Image Analysis (Grupo 1)	100.000 transações	\$100,00	\$95,00
Google — Cloud Vision	100.000 unidades	\$150,00	\$148,50



O que os números mostram

Nesta categoria a comparação é mais simples que em NLP, porque **a unidade de cobrança é praticamente a mesma nos três** — uma imagem analisada. Não há efeito de granularidade a explorar: o que se compara é o preço direto.

AWS e Azure ficam empatados em \$100,00 no volume do cenário, e o Google fica **50% acima**, em \$150,00. Vale registrar que essa ordem não é estável em qualquer volume: as faixas têm degraus diferentes (a Azure desce para \$0,65/mil a partir de 1M de transações, a AWS para

\$0,0008/imagem a partir de 1M de imagens, e o Google só desce para \$1,00/mil depois de 5M de unidades), de modo que um volume muito maior muda as distâncias relativas.

Franquias

Provedor	Franquia	Natureza
AWS	1.000 imagens/mês	Promocional, 12 meses a partir da criação da conta
Azure	5.000 transações/mês (limite de 20/minuto)	Tier F0 separado
Google	1.000 unidades/mês	Primeira faixa da tabela, permanente

Reprodutibilidade

```
uv run custos/calcular_custos.py      # gera custos/resultados.csv (só stdlib)
uv run custos/verificar_calculos.py   # confere as contas à mão contra o programa
uv run custos/gerar_graficos.py      # gera os gráficos a partir do CSV
```

7. Síntese: vantagens, restrições e adequação por cenário

O que separa as três ofertas

A AWS é a única que entrega taxonomia junto com o rótulo. `Parents`, `Aliases` e `Categories` permitem agrupar e filtrar rótulos sem manter um dicionário próprio, e os filtros de inclusão/exclusão rodam no servidor. Nos outros dois, essa camada fica por conta da aplicação.

O Google é o mais permissivo na entrada e o único com identificador estável. Aceita PDF, RAW, TIFF e mais — contra **apenas PNG e JPEG na AWS** — o que elimina uma etapa de conversão em pipelines que recebem upload livre. E o campo `mid` liga cada rótulo a uma entidade do Knowledge Graph, em vez de obrigar comparação por string.

A Azure é a que exige mais atenção à região e ao calendário. É a única com lista fechada de regiões para a própria funcionalidade, e a única com **encerramento anunciado: o Image Analysis 4.0 sai de operação em 25/09/2028**. O histórico reforça o ponto: quatro funcionalidades em preview já foram desativadas em 31/03/2025.

Um detalhe que atravessa a integração dos três: **a escala de confiança não é a mesma** (0–100 na AWS, 0–1 nos outros dois), e os vocabulários de rótulos não têm equivalência oficial. Trocar de provedor aqui não é trocar de endpoint — é recalibrar limiares e remapear termos.

Custo: a categoria mais previsível das três

Como a unidade de cobrança é essencialmente a mesma nos três — uma imagem analisada — não há efeito de granularidade a explorar. No cenário de 100.000 imagens, **AWS e Azure empatam em \$100,00 e o Google fica 50% acima, em \$150,00**.

Essa ordem não vale para qualquer volume: os degraus de faixa são diferentes, e o Google só reduz o preço depois de 5 milhões de unidades, enquanto AWS e Azure já reduzem a partir de 1 milhão.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Pipeline com formatos heterogêneos de upload	Cloud Vision	Aceita PDF, RAW, TIFF, WEBP e outros; a AWS exigiria conversão para PNG/JPEG
Necessidade de agrupar rótulos por categoria ou hierarquia	Amazon Rekognition	Único que devolve <code>Parents</code> , <code>Aliases</code> e <code>Categories</code>
Integração com base de conhecimento	Cloud Vision	O <code>mid</code> dá identificador estável em vez de string
Sensibilidade a custo no volume analisado	AWS ou Azure	\$100,00 contra \$150,00 do Google em 100 mil imagens
Volume muito alto (acima de 1 milhão/mês)	Recalcular	Os degraus de faixa diferem e mudam a ordem
Sistema com horizonte longo de manutenção	AWS ou Google	O Image Analysis 4.0 da Azure encerra em 25/09/2028

O que esta etapa não responde: qual serviço produz rótulos mais corretos ou mais úteis. Sem gabarito e sem execução, isso não é afirmável.

8. Referências e pendências de verificação

Fontes usadas neste capítulo

ID	O que sustenta
VIS-AWS-01	Operação <code>DetectLabels</code> , parâmetros, filtros e estrutura da resposta
VIS-AWS-02	Limites: 15 MB no S3, 5 MB em bytes, PNG e JPEG, dimensões mínima e máxima, orientações de TPS e tratamento de throttling
VIS-AZ-01	Nome atual do serviço, aviso de encerramento em 25/09/2028, funcionalidades retiradas em 31/03/2025, requisitos de entrada v4.0 e v3.2, disponibilidade regional
VIS-GC-01	Feature <code>LABEL_DETECTION</code> , endpoint, campos da resposta e <code>maxResults</code> padrão
VIS-GC-02	Formatos suportados, limite de 20 MB por imagem e 10 MB por requisição JSON, resolução recomendada

Pendências

- **Preços não verificados** até esta data; a seção 5 registra apenas as unidades a confirmar. Nenhum cálculo é apresentado antes disso.
- O valor padrão de `MinConfidence` do `DetectLabels` **não foi localizado** nas páginas consultadas; o exemplo de código define o parâmetro explicitamente para não depender do padrão.
- A Azure não publica, nas páginas consultadas, limite de tamanho de resposta ou número máximo de tags por imagem.
- Qual serviço produz rótulos mais corretos é pergunta **experimental** e não é respondida nesta etapa.

5. Fala para texto: transcrição de áudio

Operação comparada: transcrição assíncrona (em lote) do mesmo arquivo de áudio em português do Brasil **Modo de chamada:** assíncrono / lote — único modo oferecido pelos três para arquivos longos **Data da consulta às fontes:** 23/09/2026 **Região de referência:** US East (`us-east-1` / `East US` / `us-central1`)

1. Objetivo da categoria e caso de uso

Conversão de fala em texto transforma áudio gravado em transcrição pesquisável. O caso de uso típico é processar gravações de atendimento, reuniões ou conteúdo audiovisual para gerar legendas, permitir busca textual ou alimentar análises posteriores — inclusive análise de sentimento, o que liga esta categoria à primeira.

Por que o modo em lote e não o tempo real: transcrição em tempo real e em lote têm condições de uso, requisitos de formato e preços distintos. Comparar uma com a outra produziria números sem sentido. Os três provedores oferecem o modo em lote para arquivos armazenados, e é sobre ele que a comparação é feita.

2. Serviços comparados e operação equivalente

Provedor	Serviço	Operação em lote	Operação em tempo real (fora da comparação)
AWS	Amazon Transcribe	<code>StartTranscriptionJob</code>	<code>StartStreamTranscription</code>
Microsoft Azure	Azure Speech in Foundry Tools	<code>Transcription_Create</code> (Speech to text REST API)	Reconhecimento em tempo real
Google Cloud	Cloud Speech-to-Text V2	<code>BatchRecognize</code>	<code>StreamingRecognize</code> ; <code>Recognize</code> para áudio < 60 s

3. Comparação técnica

3.1 Entradas: formatos e origem do áudio

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Formatos em lote	AMR, FLAC, M4A, MP3, MP4, Ogg, WebM, WAV	WAV, MP3, OPUS/OGG, FLAC, WMA, AAC, ALAW em WAV, MULAW em WAV, AMR, WebM, SPEEX	Formatos de áudio suportados pela API v2
Formatos recomendados	FLAC ou WAV com PCM 16 bits	Formatos sem perda: WAV (PCM) e FLAC	—
Origem do arquivo	Obrigatoriamente um bucket do Amazon S3	URI público, URI com SAS, ou contêiner do Azure Blob Storage via <i>trusted Azure services</i> (identidade gerenciada)	Cloud Storage (<code>gs://</code>) para <code>BatchRecognize</code>
Canais de áudio	Mono e estéreo; mais de dois canais não é suportado	—	—
Taxa de amostragem	Opcional no lote; 8.000 Hz típico em telefonia e de 16.000 a 48.000 Hz em alta fidelidade	—	—

A Azure aceita a lista mais ampla de formatos e é a única das três que permite **URI público** como origem, dispensando armazenamento no próprio provedor. A AWS é a mais restritiva nesse ponto: o arquivo precisa estar no S3, o que acrescenta um passo de upload e uma configuração de permissão ao fluxo.

3.2 Saídas

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Formato	JSON	JSON	JSON
Conteúdo mínimo	Transcrição em bloco (<code>transcripts</code>), detalhamento por palavra e pontuação (<code>items</code>) com tempo de início, fim e confiança, e segmentos de áudio (<code>audio_segments</code>)	Transcrição com metadados da execução	Transcrição com alternativas e confiança
Onde o resultado fica	Bucket S3 do cliente ou bucket gerenciado pelo serviço, com URI temporária válida por 15 minutos ; no bucket padrão, o resultado é apagado quando o job expira, em 90 dias	Contêiner de armazenamento, recuperado de forma assíncrona	Cloud Storage ou resposta da operação
Recursos adicionais	Diarização (separação de locutores), identificação de canal	—	Diarização disponível no modelo <code>chirp_3</code>

O detalhe de retenção da AWS é operacionalmente relevante: quem usa o bucket padrão precisa baixar a transcrição antes de 90 dias, e a URI temporária expira em 15 minutos — se expirar, é preciso uma nova chamada `GetTranscriptionJob`.

3.3 Suporte ao português do Brasil

Provedor	Código	Cobertura
Amazon Transcribe	pt-BR (Português, Brasileiro) e pt-PT (Português)	pt-BR em lote e streaming; suporta transcrição de números, acrônimos, <i>redaction</i> e Call Analytics pós-chamada e em tempo real
Azure Speech	pt-BR (Portuguese, Brazil)	Suportado, inclusive com <i>fast transcription</i>
Cloud Speech-to-Text V2	pt-BR (Portuguese, Brazil)	Disponível nos modelos <code>chirp_3</code> , <code>long</code> , <code>short</code> , <code>telephony</code> e <code>telephony_short</code> ; o <code>chirp_3</code> acrescenta diarização

Diferença em relação à categoria de NLP: aqui os três provedores distinguem formalmente o português do Brasil. Na análise de sentimento, apenas a Azure faz essa distinção. Isso mostra que o suporte a variantes regionais não é uniforme nem dentro do mesmo provedor.

O Google é o único que **expõe a escolha do modelo** ao desenvolvedor na operação comparada, permitindo otimizar por tipo de áudio (telefonia, áudio longo, áudio curto). AWS e Azure não expõem essa escolha na transcrição padrão.

3.4 Formas de acesso, autenticação e configuração

Aspecto	Amazon Transcribe	Azure Speech	Cloud Speech-to-Text V2
Acesso	API REST, AWS CLI e SDKs (.NET, C++, Go, Java V2, JavaScript, PHP V3, Python/boto3, Ruby V3, Rust)	Speech to text REST API e Speech CLI	REST, gRPC e client libraries
Autenticação	Credenciais IAM, com permissão de leitura no bucket de origem e de escrita no de destino	Chave do recurso; para Blob Storage protegido, identidade gerenciada atribuída pelo sistema com papel <i>Storage Blob Data Reader</i>	Application Default Credentials
Fluxo	Inicia o job, consulta com <code>GetTranscriptionJob</code> , lê o resultado no S3	Três passos: localizar áudio → criar transcrição → obter resultados	Inicia a operação de longa duração e consulta até concluir

A Azure tem a configuração de segurança mais elaborada das três para o caso de armazenamento privado — exige habilitar identidade gerenciada no recurso de Speech e conceder papel específico na conta de armazenamento. É mais trabalho inicial, mas permite bloquear completamente o acesso externo ao armazenamento, algo que a documentação descreve passo a passo.

3.5 Latência de processamento e limites operacionais

Aspecto	Amazon Transcribe	Azure Speech (lote)	Cloud Speech-to-Text V2
Agendamento	Fila de jobs opcional quando não é necessário processar tudo simultaneamente	Best-effort: em horário de pico, pode levar até 30 minutos para iniciar e até 24 horas para concluir	Operação de longa duração
Latência publicada	—	Percentil 90 abaixo de 6 horas , com fórmula de latência normalizada publicada ($\text{ProcessDuration} - \text{AudioLength}/5$, com o serviço processando a cerca de 5× o tempo real)	—
Recomendações de uso	—	Enviar cerca de 1.000 arquivos por requisição ; distribuir envios ao longo de horas; consultar status no máximo uma vez por minuto , sendo suficiente a cada 10 minutos	—

A Azure é a única das três que publica expectativa de latência e um método de cálculo para ela. Isso é transparência útil, mas também revela que o modo em lote da Azure **não é adequado a fluxos sensíveis a tempo**: a própria documentação admite picos de até 24 horas. Esse número descreve fila de processamento e não qualidade do reconhecimento.

3.6 Situação do serviço (avisos oficiais)

Nenhum dos três serviços desta categoria apresenta aviso de descontinuação nas páginas consultadas. É a única das três categorias deste trabalho em que isso ocorre — nas outras duas, a oferta da Azure tem encerramento anunciado.

4. Exemplos de código

Os três exemplos submetem o **mesmo áudio à mesma operação em lote**, com idioma `pt-BR`:

- `exemplos/fala/aws_transcribe.py`
- `exemplos/fala/azure_speech.py`
- `exemplos/fala/google_speech_to_text.py`

Estado de validação: exemplos **ilustrativos, não executados pelo grupo**, adaptados da documentação oficial, conforme a seção 3 do enunciado. Por serem operações assíncronas, cada exemplo mostra os três momentos do fluxo: envio, acompanhamento e obtenção do

resultado. Nenhuma credencial está embutida.

5. Modelo de cobrança

Provedor	Unidade de cobrança	Preço	Equivalente por minuto
Amazon Transcribe	Segundo de áudio , em incrementos de 1 segundo e sem mínimo	\$0,0001 por segundo, preço único sem faixas	\$0,006
Azure Speech (lote)	Hora de áudio	\$0,18 por hora	\$0,003
Cloud Speech-to-Text V2 (padrão)	Áudio processado, em incrementos de 1 segundo	\$0,016 por minuto (até 500 mil min/mês)	\$0,016
Cloud Speech-to-Text V2 (<i>dynamic batch</i>)	Áudio processado, em incrementos de 1 segundo	\$0,003 por minuto, preço único	\$0,003

Preços de **US East, em USD, consultados em 23/09/2026**, registrados em `custos/premissas.csv`. Os da AWS vêm da *AWS Price List API* e os da Azure da *Azure Retail Prices API*.

A granularidade do arredondamento é favorável em todos os três: AWS e Google cobram em incrementos de 1 segundo, e a AWS declara explicitamente não haver cobrança mínima. Ou seja, um áudio de 20 segundos não é cobrado como um minuto inteiro — o que era o risco desta categoria.

O Google tem dois preços para lote, e a diferença é de mais de 5x. O modo padrão custa \$0,016/min; o *dynamic batch*, descrito na documentação como processamento "com menor nível de urgência", custa \$0,003/min. Isso importa na comparação: o lote da Azure também é declaradamente *best-effort*, com fila que pode chegar a 24 horas. **O par realmente comparável em urgência é Azure em lote x Google em dynamic batch** — e os dois custam exatamente o mesmo, \$0,003/min.

6. Cenário de custo, fórmulas, premissas e resultados

Carga do cenário

10.000 minutos de áudio por mês (cerca de 167 horas) em português do Brasil, transcritos em lote. A quantidade é hipotética e declarada como tal, e é idêntica nos três provedores.

Fórmulas


AWS:	$10.000 \text{ min} \times 60 = 600.000 \text{ segundos} \times \$0,0001/\text{s}$
Azure:	$10.000 \text{ min} / 60 = 166,667 \text{ horas} \times \$0,18/\text{h}$
Google:	$10.000 \text{ min} \times \$0,016/\text{min}$ (padrão)
	$10.000 \text{ min} \times \$0,003/\text{min}$ (dynamic batch)

Resultados (USD/mês, sem franquia)

Provedor e modo	Unidades cobradas	Custo	Urgência declarada
Azure — Speech to text Batch (S1)	166,67 horas	\$30,00	<i>Best-effort</i> : até 24 h em pico
Google — dynamic batch	10.000 minutos	\$30,00	Menor urgência
AWS — Transcribe em lote	600.000 segundos	\$60,00	Fila opcional
Google — BatchRecognize padrão	10.000 minutos	\$160,00	Prioridade padrão

Transcrição em lote: custo de 10.000 minutos de áudio

pt-BR · US East · USD · sem franquia · preços de 23/09/2026



O que os números mostram

Esta é a categoria com a **maior dispersão de preço das três**: do mais barato ao mais caro há um fator de **5,3×**, contra 1,5× em visão computacional.

Mas o número isolado engana, e é por isso que a coluna de urgência está na tabela. **Comparar os \$30,00 da Azure com os \$160,00 do Google padrão é comparar serviços com compromissos de tempo diferentes.** Colocados na mesma condição — processamento de menor urgência — Azure e Google empatam exatamente em \$30,00, e a AWS fica no dobro, \$60,00, sem oferecer um modo mais barato de menor urgência.

A leitura correta é, portanto:

- **Se a aplicação tolera fila longa** (transcrição noturna de gravações, processamento de acervo): Azure e Google *dynamic batch* empatam em \$30,00.
- **Se a aplicação precisa de prazo previsível**: a AWS entrega \$60,00 sem depender de janela de baixa urgência, enquanto o equivalente no Google custa \$160,00.

Este é o ponto do trabalho em que a análise econômica mais depende da análise técnica: sem a informação de fila da seção 3.5, o cenário produziria um ranking enganoso.

Franquias

Provedor	Franquia	Natureza
AWS	60 minutos/mês	Promocional, 12 meses
Azure	5 horas/mês	Tier F0; a página declara a franquia para transcrição em tempo real
Google	—	Não localizada para a tabela Recognition da V2 na página consultada

A franquia do Google **não foi localizada** para a V2 e por isso aparece como pendência, não como zero: a faixa de 60 minutos gratuitos que consta da página pertence às tabelas da API V1.

Reprodutibilidade

```
uv run custos/calcular_custos.py      # gera custos/resultados.csv (só stdlib)
uv run custos/verificar_calculos.py   # confere as contas à mão contra o programa
uv run custos/gerar_graficos.py      # gera os gráficos a partir do CSV
```

7. Síntese: vantagens, restrições e adequação por cenário

O que separa as três ofertas

A urgência é a variável escondida desta categoria. Os três chamam de "lote" coisas com compromissos de tempo diferentes: a Azure admite abertamente fila de até 24 horas em pico (com p90 abaixo de 6 h e uma fórmula publicada para estimar a latência), o Google separa o modo padrão do *dynamic batch* de menor urgência, e a AWS oferece fila apenas como opção. Qualquer comparação que ignore isso produz ranking errado.

A origem do áudio impõe arquitetura. A AWS **obriga** o arquivo a estar em um bucket S3. A Azure é a única que aceita **URI público**, dispensando armazenamento no provedor — e, no outro extremo, oferece o caminho mais elaborado de segurança, com identidade gerenciada e papel *Storage Blob Data Reader* para bloquear totalmente o acesso externo ao armazenamento.

Só o Google expõe a escolha do modelo. `chirp_3`, `long`, `short`, `telephony` e `telephony_short` estão disponíveis para `pt-BR`, com diarização no `chirp_3`. AWS e Azure não oferecem essa decisão na transcrição padrão.

Os três suportam `pt-BR` formalmente — diferente da categoria de NLP, onde só a Azure distingue a variante brasileira. E **nenhum dos três tem aviso de descontinuação**, o que faz desta a única categoria do trabalho sem risco de calendário.

Custo: maior dispersão das três categorias, mas só na aparência

Do mais barato ao mais caro há um fator de **5,3×** (\$30,00 contra \$160,00) — contra 1,5× em visão. Mas boa parte dessa distância desaparece quando se compara urgência equivalente:

- **Menor urgência:** Azure (\$30,00) e Google *dynamic batch* (\$30,00) empatam exatamente.
- **Prioridade padrão:** AWS (\$60,00) contra Google padrão (\$160,00).

A AWS ocupa uma posição intermediária peculiar: é o dobro do preço de menor urgência, mas **não oferece um modo mais barato** para quem tolera fila — e, em contrapartida, não obriga a aceitar janela de 24 horas para chegar ao preço competitivo.

Um alívio comum aos três: **o arredondamento é favorável**. AWS e Google cobram em incrementos de 1 segundo, e a AWS declara não haver cobrança mínima — o risco de um áudio de 20 segundos ser cobrado como um minuto inteiro não se concretizou em nenhum deles.

Adequação por cenário

Situação	Alternativa mais adequada	Por quê
Processamento noturno ou de acervo , sem pressa	Azure ou Google dynamic batch	\$30,00 no cenário; empate exato
Necessidade de prazo previsível sem pagar prêmio alto	Amazon Transcribe	\$60,00 sem depender de janela de baixa urgência; o equivalente no Google custa \$160,00
Áudio já hospedado fora da nuvem do provedor	Azure	Única que aceita URI público como origem
Requisito de isolamento do armazenamento	Azure	Caminho documentado com identidade gerenciada e acesso externo bloqueado
Telefonia ou tipos específicos de áudio	Cloud Speech-to-Text V2	Único que expõe a escolha do modelo (<code>telephony</code> , <code>long</code> , <code>short</code>)
Necessidade de diarização	AWS ou Google (<code>chirp_3</code>)	Ambos documentam separação de locutores
Fluxo sensível a tempo	Nenhum dos modos em lote	Usar transcrição em tempo real, que tem preço e condições próprios

O que esta etapa não responde: qual serviço transcreve português do Brasil com menos erros. A taxa de erro exige execução e gabarito.

8. Referências e pendências de verificação

Fontes usadas neste capítulo

ID	O que sustenta
FAL-AWS-01	Separação entre lote e streaming, operações <code>StartTranscriptionJob</code> e <code>StartStreamTranscription</code>
FAL-AWS-02	Formatos de mídia por modo, canais suportados, taxas de amostragem, estrutura da saída JSON, retenção no bucket padrão (90 dias) e URI temporária de 15 minutos
FAL-AWS-03	Códigos de idioma: <code>pt-BR</code> e <code>pt-PT</code> em lote e streaming, com recursos por idioma; SDKs disponíveis por modo
FAL-AZ-01	Fluxo em três passos da transcrição em lote, <code>Transcription_Create</code> , agendamento best-effort (até 30 min para iniciar, até 24 h para concluir), p90 abaixo de 6 h, recomendações de lote e de polling
FAL-AZ-02	Formatos e codecs aceitos no lote, origens de áudio (URI público, SAS, identidade gerenciada) e configuração de segurança do armazenamento
FAL-AZ-03	Suporte ao locale <code>pt-BR</code>
FAL-GC-01	Operações <code>Recognize</code> , <code>BatchRecognize</code> e <code>StreamingRecognize</code> ; modelos <code>chirp_3</code> , <code>chirp_2</code> e <code>telephony</code>
FAL-GC-02	Suporte a <code>pt-BR</code> nos modelos <code>chirp_3</code> , <code>long</code> , <code>short</code> , <code>telephony</code> e <code>telephony_short</code> , com diarização no <code>chirp_3</code>

Pendências

- **Preços não verificados** até esta data; as unidades da seção 5 estão marcadas como "a confirmar".
- A página de cotas do Amazon Transcribe **não foi acessível** na consulta de 23/09/2026; por isso, **tamanho máximo de arquivo, duração máxima de áudio e número de jobs simultâneos não estão registrados** para a AWS. Essa lacuna está declarada em vez de preenchida por estimativa.
- Limites numéricos equivalentes (tamanho e duração máximos) não foram localizados nas páginas consultadas da Azure e do Google para a operação em lote.
- Qual serviço transcreve português do Brasil com menos erros é pergunta **experimental**, não respondida nesta etapa.

6. Síntese geral

As sínteses por categoria estão ao final de cada capítulo. Esta seção reúne o que atravessa as três.

6.1 Não há um vencedor, e o motivo é estrutural

Em nenhuma das três categorias um provedor domina em todos os critérios. Mais do que isso: **em duas das três, a ordem de preço depende de um parâmetro da própria aplicação**, e não do provedor.

Categoria	O parâmetro que decide	Efeito
NLP	Comprimento típico do texto	AWS custa 1/3 dos concorrentes em textos de 100 caracteres e empata em 4.000
Visão	Volume mensal	AWS e Azure empatam em 100 mil imagens; os degraus de faixa diferem acima de 1 milhão
Fala	Tolerância a fila de processamento	Azure e Google empatam em \$30,00 no modo de menor urgência; a AWS cobra \$60,00 sem exigir essa tolerância

Quem escolher um provedor a partir de uma tabela de preço isolada, sem fixar esses parâmetros, escolherá errado com frequência.

6.2 A unidade de cobrança pesa mais que o preço unitário

O achado mais transferível deste trabalho é que **a granularidade da unidade de cobrança pode importar mais do que o preço da unidade**.

Em análise de sentimento, Azure e Google cobram uma unidade inteira de 1.000 caracteres mesmo para um comentário de 100 caracteres — pagando-se por 900 caracteres nunca enviados. A AWS, cobrando em unidades de 100 caracteres, custa um terço no mesmo cenário. Os três têm preços unitários da mesma ordem de grandeza; o que separa é como contam.

Na transcrição de áudio, a mesma lógica trabalhou a favor de todos: os três cobram em incrementos de um segundo, e a AWS declara não haver cobrança mínima.

6.3 A Azure é a mais completa tecnicamente e a mais arriscada no calendário

A Azure aparece à frente em vários critérios técnicos: é a única com **94 idiomas** e distinção formal entre `pt-BR` e `pt-PT` em sentimento; a única com **contêiner Docker** para execução local; a única que aceita **URI público** como origem de áudio; a única que publica **expectativa de latência** do processamento em lote; e a que oferece o caminho mais elaborado de isolamento de armazenamento.

Em contrapartida, é a única dos três provedores com **encerramento anunciado em duas das três categorias comparadas**:

Serviço	Encerramento anunciado
Azure Language — análise de sentimento e opinion mining	31/03/2029
Azure Vision — Image Analysis 4.0	25/09/2028

Além disso, quatro funcionalidades do Image Analysis 4.0 em preview já foram desativadas em 31/03/2025. Nenhum serviço comparado da AWS ou do Google Cloud apresenta aviso equivalente nas páginas consultadas.

Esse é um custo que não aparece em cenário de preço nenhum: para um sistema com horizonte de manutenção de anos, escolher a Azure nessas duas categorias significa assumir uma migração com data marcada.

6.4 O custo de troca é maior do que parece

Nenhuma das três categorias permite trocar de provedor apenas trocando o endpoint:

- **Sentimento:** a saída do Google é um número contínuo, a da AWS tem quatro classes e a da Azure tem três com granularidade de sentença. Migrar exige redefinir a lógica de classificação.
- **Visão:** as escalas de confiança diferem (0–100 × 0–1) e os vocabulários de rótulos não têm tabela de equivalência oficial. Migrar exige recalibrar limiares e remapear termos.
- **Fala:** a origem do áudio é imposta de forma diferente (S3 obrigatório na AWS; URI público aceito na Azure; Cloud Storage no Google), o que atinge a arquitetura, não só o código de chamada.

6.5 O que a documentação não permite concluir

A análise é **documental**. Ela não estabelece qual serviço classifica sentimento com mais acerto, qual rotula imagens de forma mais útil, ou qual transcreve português do Brasil com menos erros. Essas perguntas exigem execução, dados de teste, gabarito e medição — objeto da Etapa 2.

7. Limitações

Registradas para delimitar o alcance das conclusões:

1. **Nenhum exemplo de código foi executado.** A seção 3 do enunciado permite isso nesta etapa. Consequentemente, não há neste relatório qualquer medição de latência, taxa de acerto, taxa de erro ou comportamento em produção.
2. **As conclusões valem para a data e a região declaradas.** Preços de nuvem mudam. Todos os valores são de **US East, em USD, consultados em 23/09/2026**, com a fonte de cada um registrada em `custos/premissas.csv`. Uma consulta futura pode divergir, e a reprodução dos cálculos exige reverificar as premissas.
3. **As cargas dos cenários são hipotéticas.** 100.000 documentos, 100.000 imagens e 10.000 minutos de áudio são quantidades escolhidas pelo grupo para permitir comparação, não estimativas de uso real de nenhuma aplicação. O que garante a validade da comparação não é a quantidade em si, mas o fato de ser **idêntica entre provedores**.
4. **Os resultados não se generalizam para outros volumes sem recálculo.** As faixas de preço têm degraus em pontos diferentes em cada provedor. A ordem observada em 100.000 imagens pode se inverter em 10 milhões.

5. Comparou-se uma operação por categoria. Sentimento de documento, detecção de rótulos e transcrição em lote. Cada serviço oferece dezenas de outras operações, com preços e limites próprios, que não foram analisadas.

6. Informações não localizadas ficaram como pendência. Especificamente:

Pendência	Onde
Tamanho máximo de arquivo, duração máxima de áudio e número de jobs simultâneos do Amazon Transcribe	Página de cotas não acessível na consulta
Franquia gratuita da tabela Recognition da Cloud Speech-to-Text V2	Não localizada; a faixa de 60 minutos consta das tabelas da V1
Valor padrão de <code>MinConfidence</code> do <code>DetectLabels</code>	Não localizado; o exemplo de código fixa o parâmetro explicitamente
Limite de tags por imagem no Azure Image Analysis	Não localizado nas páginas consultadas

Nenhuma dessas lacunas foi preenchida por estimativa.

7. A distinção `pt-BR` da Azure não foi testada. A documentação registra que a Azure distingue português do Brasil de português de Portugal, e que AWS e Google não. **Ela não afirma que isso produza melhor resultado em textos brasileiros**, e este relatório não o afirma. É uma hipótese verificável na Etapa 2.

8. Referências

Registro exigido pela seção 12 do enunciado (p. 5): "a pesquisa deverá utilizar prioritariamente a documentação oficial dos provedores, em especial a documentação das APIs/SDKs e as páginas oficiais de preços".

Como ler este arquivo. Cada fonte tem um identificador interno usado nos capítulos. O campo *afirmação sustentada* diz exatamente o que aquela página comprova — fontes não são listadas de forma decorativa. O campo *estado* usa: **verificado** (página acessada e conteúdo conferido na data indicada), **inacessível**, **informação não localizada** ou **precisa de confirmação**.

Todas as datas são datas reais de acesso. Todas as páginas são documentação oficial dos próprios provedores.

NLP / análise de texto

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmção sustentada	Estado
NLP-AWS-01	AWS — Amazon Comprehend	Sentiment — https://docs.aws.amazon.com/comprehend/latest/dg/how-sentiment.html	23/09/2026	Operações <code>DetectSentiment</code> , <code>BatchDetectSentiment</code> e <code>StartSentimentDetectionJob</code> ; classes <code>POSITIVE</code> , <code>NEGATIVE</code> , <code>MIXED</code> e <code>NEUTRAL</code> ; resposta com <code>SentimentScore</code> contendo um score por classe; documentos em UTF-8	verificado
NLP-AWS-02	AWS — Amazon Comprehend	Guidelines and quotas — https://docs.aws.amazon.com/comprehend/latest/dg/guidelines-and-limits.html	23/09/2026	Tamanho máximo de 5 KB por documento nas operações de sentimento (síncrona e assíncrona); 5 KB e 25 documentos por requisição nas operações em lote; <i>throttling</i> dinâmico sem cota publicada no modo síncrono; 13 regiões suportadas, incluindo US East (N. Virginia) e sem região no Brasil	verificado
NLP-AWS-03	AWS — Amazon Comprehend	Languages supported — https://docs.aws.amazon.com/comprehend/latest/dg/supported-languages.html	23/09/2026	12 idiomas suportados, com <code>pt</code> (Português) entre eles e sem distinção de variante; o recurso <i>Sentiment</i> cobre todos os idiomas suportados (diferente de <i>Targeted sentiment</i> , restrito ao inglês)	verificado
NLP-AZ-01	Azure — Azure Language in Foundry Tools	What is sentiment analysis and opinion mining in Azure Language service? — https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/overview	23/09/2026	Nome atual do serviço; aviso oficial de encerramento em 31/03/2029 com recomendação de migrar para o Microsoft Foundry; rótulos <code>positive</code> / <code>neutral</code> / <code>negative</code> com confiança de 0 a 1; sentimento em nível de documento e de sentença; acesso por REST API, client library (C#, Java, JavaScript, Python) e contêiner Docker; autenticação por chave + endpoint	verificado
NLP-AZ-02	Azure — Azure Language in Foundry Tools	Data limits for Language service features — https://learn.microsoft.com/en-us/azure/ai-services/language-service/concepts/data-limits	23/09/2026	"A text record is measured as 1000 characters" (unidade de cobrança); 5.120 caracteres por documento no modo síncrono; 125.000 caracteres e 25 documentos no assíncrono; 1 MB por requisição; 10 documentos por	verificado

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmção sustentada	Estado
				requisição na análise de sentimento ; limites de taxa por tier (S/Multi-service 1.000 req/s; S0/F0 100 req/s e 300 req/min)	
NLP-AZ-03	Azure — Azure Language in Foundry Tools	Sentiment Analysis and Opinion Mining language support — https://learn.microsoft.com/en-us/azure/ai-services/language-service/sentiment-opinion-mining/language-support	23/09/2026	94 códigos de idioma na análise de sentimento, com pt-BR (Português do Brasil) e pt-PT (Português de Portugal) como entradas distintas; pt também aceito	verifi
NLP-GC-01	Google Cloud — Cloud Natural Language API	Analyzing Sentiment — https://docs.cloud.google.com/natural-language/docs/analyzing-sentiment	23/09/2026	Operação <code>analyzeSentiment</code> ; saída com <code>score</code> e <code>magnitude</code> ; ausência de aviso de descontinuação na página oficial da operação	verifi
NLP-GC-02	Google Cloud — Cloud Natural Language API	Cloud Natural Language API v1beta1 Deprecation Notice — https://cloud.google.com/natural-language/deprecation	23/09/2026	Única descontinuação oficial registrada é a da versão <code>v1beta1</code> , encerrada em 27/12/2019; não atinge a <code>v1</code>	verifi
NLP-GC-03	Google Cloud — Cloud Natural Language API	Quotas and limits — https://docs.cloud.google.com/natural-language/quotas	23/09/2026	Conteúdo de até 1.000.000 bytes; até 100.000 tokens por requisição; 600 requisições/minuto e 800.000 requisições/dia	verifi
NLP-GC-04	Google Cloud — Cloud Natural Language API	Language support — https://docs.cloud.google.com/natural-language/docs/languages	23/09/2026	16 idiomas na análise de sentimento, incluindo <code>pt</code> (Português), sem distinção de variante	verifi

Visão computacional

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmção sustentada
VIS-AWS-01	AWS — Amazon Rekognition	Detecting labels in an image — https://docs.aws.amazon.com/rekognition/latest/dg/labels-detect-labels-image.html	23/09/2026	Operação DetectLabels; entrada por o Amazon S3 ou bytes da imagem; parâmetros MaxLabels, MinConfidence, Features (GENERAL_LABELS, IMAGE_PROPERTIES) e com filtros de inclusão/exclusão; resposta com Name, Confidence, Parents, Aliases, Categories, Instances com BoundingBox e LabelModelVersion
VIS-AWS-02	AWS — Amazon Rekognition	Guidelines and quotas — https://docs.aws.amazon.com/rekognition/latest/dg/limits.html	23/09/2026	Imagem de até 15 MB como objeto no formato bytes na requisição; apenas PNG máximo de 10.000 px de largura e altura; DetectLabels; mínimo de 80 px; orientado para ProvisionedThroughputExceededException com retry, backoff exponencial e jitter; Image Bulk Analysis lotes de até 10.000 imagens
VIS-AZ-01	Azure — Azure Vision in Foundry Tools	What is Image Analysis? — https://learn.microsoft.com/en-us/azure/ai-services/computer-vision/overview-image-analysis	23/09/2026	Aviso oficial: Image Analysis 4.0 descontinuado, encerramento em 25/09/2028 ; funcionalidades de previsão em 31/03/2025 (Custom Image Classification, Custom Object Detection, Product Recommendation, Segment/remoção de fundo); funciona com visual features nas versões 4.0 e 3.2; e v4.0 (JPEG, PNG, GIF, BMP, WEBP, ICO, < 20 MB; 50×50 a 16.000×16.000 px) (JPEG, PNG, GIF, BMP; < 4 MB); East US regiões suportadas
VIS-GC-01	Google Cloud — Cloud Vision API	Detect labels — https://docs.cloud.google.com/vision/docs/labels	23/09/2026	Feature LABEL_DETECTION via POST https://vision.googleapis.com/v1/images:annotate ; entrada por base64, URI do Cloud Storage remota; resposta com mid, description (0 a 1) e topicality; maxResults padrão
VIS-GC-02	Google Cloud — Cloud Vision API	Supported images — https://docs.cloud.google.com/vision/docs/supported-files	23/09/2026	Formatos JPEG, PNG8, PNG24, GIF, GIF (primeiro quadro), BMP, WEBP, RAW, IC TIFF; até 20 MB por imagem e 10 MB por requisição JSON; resolução recomendada 640×480 px para LABEL_DETECTION

Fala para texto

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmção sustentada	Estado
FAL-AWS-01	AWS — Amazon Transcribe	How Amazon Transcribe works — https://docs.aws.amazon.com/transcribe/latest/dg/how-it-works.html	23/09/2026	Separação entre lote (<code>StartTranscriptionJob</code> , arquivos no Amazon S3) e streaming (<code>StartStreamTranscription</code>); suporte a recursos e idiomas difere entre os dois modos	verificado
FAL-AWS-02	AWS — Amazon Transcribe	Data input and output — https://docs.aws.amazon.com/transcribe/latest/dg/how-input.html	23/09/2026	Formatos em lote (AMR, FLAC, M4A, MP3, MP4, Ogg, WebM, WAV) e em streaming (FLAC, Ogg Opus, PCM); recomendados FLAC e WAV PCM 16 bits; suporte a um ou dois canais apenas; taxas de 8.000 Hz a 48.000 Hz; saída JSON com <code>transcripts</code> , <code>items</code> (tempo e confiança por palavra) e <code>audio_segments</code> ; no bucket padrão, URI temporária válida por 15 minutos e resultado apagado quando o job expira, em 90 dias	verificado
FAL-AWS-03	AWS — Amazon Transcribe	Supported languages — https://docs.aws.amazon.com/transcribe/latest/dg/supported-languages.html	23/09/2026	pt-BR (Portuguese, Brazilian) e pt-PT suportados em lote e streaming; pt-BR com transcrição de números, acrônimos, <i>redaction</i> e Call Analytics pós-chamada e em tempo real; SDKs disponíveis por modo	verificado
FAL-AZ-01	Azure — Azure Speech in Foundry Tools	Batch transcription overview — https://learn.microsoft.com/en-us/azure/ai-services/speech-service/batch-transcription	23/09/2026	Transcrição em lote pela Speech to text REST API com <code>Transcription_Create</code> ; fluxo assíncrono em três passos; agendamento <i>best-effort</i> , podendo levar até 30 min para iniciar e até 24 h para concluir em horário de pico; latência de percentil 90 inferior a 6 h , com fórmula $\text{ProcessDuration} - \text{AudioLength}/5$; recomendação de ~1.000 arquivos por requisição e polling no máximo 1x/minuto	verificado
FAL-AZ-02	Azure — Azure Speech in	Locate audio files for batch transcription — https://learn.microsoft.com/en-us/azure/ai-services/speech-service/batch-transcription-audio-data	23/09/2026	Formatos e codecs aceitos (WAV, MP3, OPUS/OGG, FLAC, WMA, AAC, ALAW e MULAW em WAV, AMR,	verificado

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmação sustentada	Estado
	Foundry Tools			WebM, SPEEX); origens: URI público, URI com SAS ou contêiner do Blob Storage via identidade gerenciada com papel <i>Storage Blob Data Reader</i> ; campos <code>contentUrls</code> e <code>contentContainerUrl</code>	
FAL-AZ-03	Azure — Azure Speech in Foundry Tools	Language and voice support — https://learn.microsoft.com/en-us/azure/ai-services/speech-service/language-support	23/09/2026	Locale pt-BR (Portuguese, Brazil) suportado em speech to text	verificado
FAL-GC-01	Google Cloud — Cloud Speech-to-Text V2	Transcription models — https://docs.cloud.google.com/speech-to-text/v2/docs/transcription-model	23/09/2026	Reconhecimento síncrono (áudio < 60 s), em lote (<code>BatchRecognize</code> , arquivos no Cloud Storage) e streaming; modelos <code>chirp_3</code> , <code>chirp_2</code> e <code>telephony</code>	verificado
FAL-GC-02	Google Cloud — Cloud Speech-to-Text V2	Supported languages — https://docs.cloud.google.com/speech-to-text/v2/docs/speech-to-text-supported-languages	23/09/2026	pt-BR (Portuguese, Brazil) suportado nos modelos <code>chirp_3</code> , <code>long</code> , <code>short</code> , <code>telephony</code> e <code>telephony_short</code> ; diarização disponível no <code>chirp_3</code>	verificado

Enunciado do trabalho

ID	Documento	Data de acesso	Afirmação sustentada	Estado
ENU-01	pdfs/Computação em Nuvem - Trabalho I_ Comparação de Serviços de Inteligência Artificial em Nuvem.pdf (5 páginas)	23/09/2026	Todas as exigências citadas em <code>etapa1/diagnostico.md</code> , com seção e página	verificado

Preços

Região **US East**, moeda **USD**, consulta em **23/09/2026**. Todos os valores estão em `custos/premissas.csv` , com a URL da fonte em cada linha.

Por que APIs de preço e não as páginas comerciais: as páginas de preço da Azure e do Google servem suas tabelas por JavaScript — o conteúdo estático exibe apenas \$- . Em vez de recorrer a fonte secundária, os valores foram lidos das APIs públicas de preço mantidas pelos próprios provedores, que são a fonte oficial dos mesmos números.

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmação sustentada	E
PRE-AWS-01	AWS — Amazon Comprehend	AWS Price List API — https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/comprehend/current/index.json	23/09/2026	USE1 - DetectSentiment : \$0,0001 por unidade até 10M; \$0,00005 de 10M a 50M; \$0,000025 acima de 50M. publicationDate 2026-09-11	v
PRE-AWS-02	AWS — Amazon Comprehend	Pricing — https://aws.amazon.com/comprehend/pricing/	23/09/2026	Unidade de 100 caracteres com mínimo de 3 unidades (300 caracteres) por requisição ; franquia de 50.000 unidades/mês por API durante 12 meses	v
PRE-AWS-03	AWS — Amazon Rekognition	AWS Price List API — https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/AmazonRekognition/current/index.json	23/09/2026	USE1-Group2 - AsyncImagesProcessed : \$0,0010/imagem até 1M; \$0,0008 de 1M a 5M; \$0,0006 de 5M a 35M; \$0,00025 acima. publicationDate 2026-09-11	v
PRE-AWS-04	AWS — Amazon Rekognition	Pricing — https://aws.amazon.com/rekognition/pricing/	23/09/2026	DetectLabels pertence às APIs do Grupo 2 ; franquia de 1.000 imagens/mês por 12 meses	v
PRE-AWS-05	AWS — Amazon Transcribe	AWS Price List API — https://pricing.us-east-1.amazonaws.com/offers/v1.0/aws/transcribe/current/index.json	23/09/2026	USE1 - TranscribeAudio : \$0,0001 por segundo, preço único sem faixas (equivale a \$0,006/min). publicationDate 2026-09-11	v
PRE-AWS-06	AWS — Amazon Transcribe	Pricing — https://aws.amazon.com/transcribe/pricing/	23/09/2026	Cobrança em incrementos de 1 segundo, sem mínimo ; franquia de 60 min/mês por 12 meses	v
PRE-AZ-01	Azure — Azure Language	Azure Retail Prices API — https://prices.azure.com/api/retail/prices (serviceName Foundry Tools , região eastus)	23/09/2026	Standard Text Records : \$1,00 por 1.000 registros até 0,5M; \$0,75 de 0,5M a 2,5M; \$0,30 de 2,5M a 10M; \$0,25 acima	v

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmação sustentada	E
PRE-AZ-02	Azure — Azure Vision	Azure Retail Prices API — https://prices.azure.com/api/retail/prices	23/09/2026	Image Analysis Group 1 Transactions : \$1,00 por 1.000 até 1M; \$0,65 de 1M a 10M; \$0,60 de 10M a 100M; \$0,40 acima	v
PRE-AZ-03	Azure — Azure Vision	Pricing — https://azure.microsoft.com/en-us/pricing/details/computer-vision/	23/09/2026	A feature Tag pertence ao Grupo 1 (o Grupo 2 reúne Describe, Read, Caption e Dense Captions); franquia F0 de 5.000 transações/mês, 20/minuto	v
PRE-AZ-04	Azure — Azure Speech	Azure Retail Prices API — https://prices.azure.com/api/retail/prices	23/09/2026	S1 Speech to Text Batch : \$0,18 por hora (equivale a \$0,003/min); S1 Speech To Text em tempo real: \$1,00/hora	v
PRE-AZ-05	Azure — Azure Speech	Pricing — https://azure.microsoft.com/en-us/pricing/details/speech/	23/09/2026	Franquia F0 de 5 horas de áudio por mês em transcrição em tempo real	v
PRE-GC-01	Google Cloud — Cloud Natural Language	Pricing — https://cloud.google.com/natural-language/pricing	23/09/2026	Sentiment Analysis: 0 a 5.000 unidades gratuitas; \$1,00 por 1.000 de 5 mil a 1M; \$0,50 de 1M a 5M; \$0,25 acima. Unidade de 1.000 caracteres Unicode, arredondada para cima , conforme o exemplo oficial (800 + 1.500 + 600 caracteres = 4 unidades)	v
PRE-GC-02	Google Cloud — Cloud Vision	Pricing — https://cloud.google.com/vision/pricing	23/09/2026	Label Detection: primeiras 1.000 unidades/mês gratuitas; \$1,50 por 1.000 de 1.001 a 5M; \$1,00 acima de 5M. Cada feature aplicada a uma imagem conta como uma unidade	v
PRE-GC-03	Google Cloud — Cloud Speech-to-Text V2	Pricing — https://cloud.google.com/speech-to-text/pricing	23/09/2026	Recognition Standard: \$0,016/min até 500 mil; \$0,010 de 500 mil a 1M; \$0,008 de 1M a 2M; \$0,004 acima.	v

ID	Provedor / serviço	Título e URL	Data de acesso	Afirmação sustentada	E
				Dynamic Batch Recognition: \$0,003/min , descrito como processamento de menor urgência. Cobrança em incrementos de 1 segundo	

Fontes não oficiais consultadas e descartadas

Registradas por transparência: foram lidas durante a pesquisa, mas **não sustentam nenhuma afirmação** do trabalho.

Fonte	Motivo do descarte
Tópico "Analyze sentiment deprecation?" no fórum Google Developer (discuss.google.dev)	Um respondente afirma que a Cloud Natural Language API estaria "depreciada" em favor do Vertex AI. A afirmação não se confirma na documentação oficial: a página de <code>analyzeSentiment</code> não traz aviso de descontinuação (NLP-GC-01) e a única descontinuação oficial é a do <code>v1beta1</code> (NLP-GC-02). Fórum não é fonte oficial e a afirmação foi descartada.

Relatório montado automaticamente a partir dos arquivos do repositório em 24/09/2026 por `relatorio/montar_relatorio.py`. Para regerar: `uv run relatorio/montar_relatorio.py --html`.